



25548202



同濟大學

TONGJI UNIVERSITY

博士学位论文

(学术学位)

**智能网联环境下
基于奖励的交通需求管理方案优化**

姓 名：肖琳

学 号：2110195

学 院：交通学院

学科门类：工学

一级学科：交通运输工程

二级学科：交通运输规划与管理

研究方向：交通运输规划与管理

指导教师：孙剑 教授

联合培养单位：

二〇二五年七月



同濟大學
TONGJI UNIVERSITY

A dissertation submitted to
Tongji University in partial fulfillment of the requirements for
the degree of Doctor of Engineering

**Incentive-Based Travel Demand Management
Scheme Optimization in Connected and
Automated Environments**

Candidate: Lin Xiao

Student Number: 2110195

School/Department: College of Transportation

Categories: Engineering

First-level Discipline: Transportation Engineering

Second-level Discipline: Transportation Planning,
Design, and Management

Research Fields: Transportation Planning, Design,
and Management

Supervisor: Prof. Jian Sun

July 2025



25548202

智能网联环境下基于奖励的交通需求管理方案优化

肖琳

同济大学



摘要

智能网联汽车（Connected Automated Vehicles, CAVs）通过车联网技术实现实时信息共享，并可依托云控平台协同优化出行选择。因此，CAVs 技术有望重塑现有出行模式，推动交通系统由传统人工驾驶车辆（Human-driven Vehicles, HVs）自利行为自发形成的用户均衡状态，向系统最优状态转变，从而有效缓解交通拥堵。现有研究发现在 CAVs 与 HVs 共存的智能网联环境中，仅调控 CAVs 即可推动系统向全局最优状态演进。然而，该调控过程将导致部分个体效用受损，难以实现帕累托最优。为此，本文聚焦探索基于奖励的交通需求管理（Incentive-based Travel Demand Management, IBTDM）策略，通过经济手段对利益受损个体进行效用补偿，以充分发挥 CAVs 缓解拥堵的潜力。

然而，设计适应智能网联环境的 IBTDM 策略仍面临如下挑战：**①理性行为建模约束多且形式复杂，求解难度大。**IBTDM 具有非强制性，其效能受个体出行选择与全局约束（预算、宣传成本、渗透率等）联合影响。即使是理性 CAVs 和 HVs 的出行选择，也涉及奖励干预下的行为调整与相应出行成本的权衡，该过程受到 IBTDM 全局约束影响，增加了建模求解难度。**②逐日非理性行为难预测。**非理性 HVs 因有限理性特征（如锚定效应、损失规避等）在奖励干预下行为呈现不确定性，且往往具有个体差异的逐日演化路径，预测难度大。**③异质主体行为耦合演化引发奖励方案实施效能波动，增加方案优化复杂性。**HVs 通过 IBTDM 信息反馈及个体感知调整行为，CAVs 则具备多模态感知和出行策略自适应调整能力。异质主体在不同认知下的选择相互影响，形成行为耦合演化模式，导致奖励效能不稳定，进而增加 IBTDM 方案优化的复杂性。

为应对上述挑战，鉴于改变出发时间 IBTDM 策略的行为引导潜力及其对智能网联环境的适应性，本研究聚焦于高峰通勤情境下的逐日出发时间选择行为，旨在优化适应智能网联环境的 IBTDM 方案，从而为多行为维度的 IBTDM 策略提供建模方法支持与方案设计参考。在智能网联环境中，出行者可依据主体属性和认知能力划分为四类：理性 CAVs、理性 HVs、非理性 HVs 和非理性 CAVs。本研究依次考察三类主体（鉴于理性 CAVs 与 HVs 在完全信息下的行为逻辑相同，故将其归并为同一研究类别）在奖励影响下的出发时间选择机制，并据此优化奖励方案：首先通过理论建模解析理性 CAVs 和 HVs 出发时间选择行为，推理性假设下的时变奖励方案；其次采用长时交互实验和问卷调查方法，采集数据并构建非理性 HVs 出发时间选择行为预测模型；最后引入非理性 CAVs 的出



发时间选择特征，构建集成三类主体的多智能体仿真平台，优化智能网联环境下基于主体类型的奖励策略。具体而言，本论文的研究内容包括：

1.基于理性框架，构建理性 CAVs 和 HVs 出发时间选择行为模型，并求解多维约束条件下的时变奖励方案。首先，基于经典单瓶颈模型，解析理性 CAVs 和 HVs 在奖励影响下的出发时间选择；其次，优化奖励预算在宣传成本（决定渗透率）和激励成本（引导个体行为）之间的配置结构；最后，量化出发时间偏移成本对个体出发时间选择的影响，推导预算、渗透率全局约束（由预算配置决定）下基于出发时间偏移量的最优奖励方案。结果表明，在智能网联环境下，宣传资源应优先配置给单位宣传成本较低的 CAVs 群体，且最优奖励方案取决于单位出发时间偏移成本与行驶时间成本的相对关系。该框架为后续非理性模式下的出发时间选择分析及智能网联环境下的奖励方案优化提供了理论基础。

2.通过多维度数据分析，构建非理性 HVs 逐日出发时间选择行为预测模型。首先，依托高德地图在苏州（具有 IBTDM 项目实施经验）开展大规模问卷调查，获取非理性 HVs 多样化奖励策略偏好数据集，识别其关键影响因素；其次，设计长时多轮次交互实验，获取非理性 HVs 逐日出发时间选择数据，揭示出发时间选择演化规律及驱动因素。最后，采用 Transformer 架构构建非理性 HVs 出发时间选择行为预测模型。结果表明，该模型在逐日出发时间预测准确度上相较于传统基准模型（如 LSTM 和神经网络）提升 35%以上，为智能网联环境下奖励方案优化提供行为建模支撑。

3.引入非理性 CAVs 逐日出发时间选择特征，构建异质主体出发时间选择行为仿真模型，实现基于主体类型的奖励方案仿真优化。系统整合理性 CAVs 和 HVs 智能体、非理性 HVs 智能体、非理性 CAVs 智能体，基于 Agent 仿真方法再现智能网联系统的博弈复杂性和系统演化过程。基于所研发的仿真系统，研究评估理性假设下奖励方案的实施效果和异质主体表现，进而提出基于智能增强的奖励方案仿真优化方法，通过自适应学习实现了融合 IBTDM 专家经验与智能算法的方案优化。结果表明，在较小出行者规模的智能网联环境中，基于主体类型的优化奖励方案改变了理性假设奖励方案在高峰期末段实施高额奖励的模式，与理性假设方案相比，其系统总延误降低 60%以上，预算投资回报率提升近 5 倍。

综上所述，本研究构建了智能网联环境下的奖励优化框架，为设计实现系统帕累托改进的奖励优化方案提供了方法论支撑。成果在提升 IBTDM 交通治理效能方面具有重要理论意义和实用价值。

关键词：交通系统，基于奖励的交通需求管理，出行行为，瓶颈模型，实验室实验；出发时间，系统优化



ABSTRACT

Connected Automated Vehicles (CAVs) enable real-time information sharing through vehicular communication technologies and can coordinate travel decisions via centralized cloud-based control platforms. As such, CAVs have the potential to reshape existing travel patterns, shifting the traffic system from a user equilibrium driven by self-interested Human-driven Vehicles (HVs) toward a system-optimal state, thereby alleviating congestion. Existing studies suggest that in mixed traffic environments where CAVs and HVs coexist, regulating only CAVs can guide the system toward global optimality. However, such regulation may reduce the utility of certain individuals, making it difficult to achieve Pareto optimality. To address this issue, this study focuses on developing an Incentive-Based Travel Demand Management (IBTDM) strategy, which compensates disadvantaged individuals through economic incentives, thereby unlocking the full congestion-mitigation potential of CAV technology.

However, designing IBTDM strategies suitable for connected and autonomous environments still faces several key challenges: ① **Complex and numerous constraints in rational travel behavior modeling, leading to high solution difficulty.** IBTDM is non-mandatory, and its effectiveness is jointly constrained by individual travel choice and global factors such as budget, promotion cost, and penetration. Even for rational CAVs and HVs, travel choice entail the trade-off between behavioral adjustments under incentive interventions and the associated travel costs. This process is influenced by the global constraints of IBTDM, adding to the complexity of modeling and solution. ② **Difficulty in predicting day-to-day irrational behavior.** Irrational HVs exhibit behavioral uncertainty under incentive interventions due to their irrational characteristics—such as anchoring effects and loss aversion—and follow individually diverse, day-to-day evolving patterns. ③ **Instability in incentive effectiveness due to coupled behavioral evolution among heterogeneous travelers, increasing optimization difficulty.** HVs adjust behaviors based on feedback from IBTDM and individual perception, while CAVs employ multimodal sensing and adaptive responses. The choices made by heterogeneous agents under different cognitive processes influence one another, forming a behaviorally coupled evolutionary pattern, which leads to instability in the effectiveness of incentives and further increases the

complexity of optimizing IBTDM strategies.

To address the aforementioned challenges, this study focuses on day-to-day departure time choices during peak commuting periods, leveraging the behavioral guidance potential and adaptability of departure-time-based IBTDM strategies in connected and automated environments. The research aims to design IBTDM schemes suited to connected and autonomous environments, thereby providing modeling support and design insights for the multi-dimensional behavioral strategies. Within such environments, travelers can be classified into four categories based on their attributes and cognitive capacities: rational CAVs, rational HVs, irrational HVs, and irrational CAVs. This study investigates the travel choice mechanisms of three categories of travelers (grouped rational CAVs and HVs together due to their shared decision logic under complete information) under the influence of incentive schemes, and accordingly optimizes a differentiated incentive scheme: First, theoretical modeling is used to analyze the travel behaviors of rational travelers, leading to the derivation of a theoretically optimal time-varying incentive scheme. Second, data are collected through long-term interactive experiments and surveys to identify key factors influencing the travel choices of irrational HVs. Finally, the departure time choice behavior of irrational CAVs is incorporated to build a multi-agent simulation platform integrating three types of agents, aiming to optimize type-specific incentive strategies in connected and autonomous conditions. Specifically, the main research components of this study include:

1. Developing a rational framework to construct travel choice behavior model for rational CAVs and HVs and derive the time-varying incentive scheme under multi-dimensional constraints. Initially, departure time choice behavior under incentives is analyzed using the classical single-bottleneck model. Subsequently, the mapping relationship between heterogeneous promotion costs and penetration rates for rational CAVs and HVs is considered, and the allocation of the incentive budget between promotion costs and reward costs is optimized. Finally, the effect of departure time offsets on individual travel choices is further quantified, promotion cost and the optimal time-varying incentive scheme is derived based on the magnitude of departure time behavioral adjustments, subject to budget and penetration constraints. The results suggest that, in connected and autonomous environments, promotional resources should be prioritized for CAVs with lower unit promotion costs, and that the optimal incentive scheme is determined by the relative costs of departure time shifts and travel time. This

rational framework provides a theoretical foundation for subsequent analyses of irrational departure time behavior and the optimization of incentive strategies in connected and autonomous systems.

2. Constructing a predictive model of day-by-day dynamic travel choice behaviors for irrational HVs through multi-dimensional data analysis. First, a large-scale questionnaire survey is conducted in Suzhou relying on Gaode Map to collect data on differentiated incentive strategy acceptance, and the key factors influencing heterogeneous preferences among irrational HVs are identified. Subsequently, a long-term, multi-round interaction experiment is designed to collect day-to-day travel choice data from irrational HVs, revealing the evolution patterns of departure time decisions and their driving factors. Finally, a Transformer-based departure time choice behavior prediction model for irrational HVs is constructed, achieving over 35% improvement in day-to-day departure time prediction accuracy compared to traditional baseline models (e.g., LSTM and neural networks), providing essential behavioral modeling support for optimizing incentive scheme in connected and autonomous environments.

3. Developing a simulation model capturing the behaviors of heterogeneous travelers by introducing day-to-day behaviors of irrational CAVs, and optimizing differentiated incentive scheme. The simulation system is developed by integrating rational CAV/HV agents, irrational HV agents, and irrational CAV agents to reproduce the behavioral complexity and evolutionary dynamics of a connected and autonomous traffic system. Based on the developed simulation system, the implementation effects of rational-assumption-based schemes and the heterogeneous performance are evaluated across heterogeneous agents. A simulation optimization method leveraging intelligent augmentation for differentiated incentive schemes is proposed, achieving scheme optimization through an adaptive learning mechanism that integrates human experience with intelligent algorithms. Simulation results indicate that, under the small-scale connected and autonomous conditions, the optimized type-specific incentive scheme deviates from the conventional rational strategy of offering high incentives at peak period end, achieving over a 60% reduction in total system delay, and nearly a fivefold improvement in return on budget investment compared to rational-assumption-based scheme.

In summary, this study develops a incentive optimization framework tailored to connected and autonomous environments, providing methodological support for



Abstract

designing incentive schemes that achieve system-level Pareto improvements. The findings offer both theoretical insights and practical value for enhancing the effectiveness of IBTDM-based traffic governance.

Key Words: Transportation system, Incentive-based travel demand management, travel behavior, bottleneck model, laboratory experiments, departure time, system optimization



目录

第 1 章	引言.....	1
1.1	课题来源.....	1
1.2	研究背景.....	1
1.3	研究目标与意义.....	5
1.3.1	研究目标.....	5
1.3.2	研究意义.....	6
1.4	论文研究内容与结构.....	7
1.4.1	研究内容.....	7
1.4.2	技术路线与论文结构.....	10
第 2 章	文献综述.....	13
2.1	概述.....	13
2.2	IBTDM 有效性及理性 CAVs 和 HVs 奖励方案设计.....	13
2.2.1	IBTDM 实证有效性验证.....	13
2.2.2	理性 CAVs 和 HVs 的奖励方案优化设计.....	15
2.3	非理性 HVs 出行选择特征分析.....	16
2.4	智能网联环境下异质主体出行选择理论及仿真建模.....	20
2.4.1	基于理论的异质主体出行选择建模.....	20
2.4.2	基于仿真的异质主体出行选择建模.....	22
2.5	综合评述.....	23
第 3 章	理性 CAVs 和 HVs 出发时间选择行为建模与奖励方案优化.....	25
3.1	概述.....	25
3.1.1	问题背景.....	25
3.1.2	经典瓶颈模型.....	27
3.2	奖励预算配置方案优化.....	29
3.2.1	同质单位宣传成本下的预算分配.....	29
3.2.2	CAVs 和 HVs 异质单位宣传成本下的预算分配.....	32
3.3	个体动态出发时间选择机制与奖励方案优化.....	37
3.3.1	基于出发时间偏移量的个体出发时间选择机制.....	38
3.3.2	基于出发时间偏移量的奖励方案.....	42
3.3.3	奖励方案对比分析.....	49
3.4	本章小结.....	52
第 4 章	非理性 HVs 出发时间选择行为分析与建模.....	55
4.1	概述.....	55



目录

4.2 基于问卷调查的多样化奖励策略偏好分析.....	57
4.2.1 非理性 HVs 多样化奖励策略偏好数据集.....	57
4.2.2 非理性 HVs 奖励策略接受度的影响因素分析.....	62
4.3 基于长时交互实验的出发时间选择逐日演化分析.....	68
4.3.1 长时交互实验室实验设计.....	68
4.3.2 奖励方案长时逐日效果分析.....	74
4.3.3 非理性 HVs 个体差异表现及影响因素分析.....	78
4.3.4 出行行为长时逐日演化分析.....	86
4.4 非理性 HVs 逐日出发时间选择预测模型.....	89
4.4.1 数据模型构建与编码.....	89
4.4.2 不同方法效果对比.....	91
4.5 本章小结.....	92
第5章 异质主体出发时间选择行为仿真与奖励方案优化.....	93
5.1 概述.....	93
5.2 异质主体出发时间选择行为仿真建模.....	95
5.3 基于多智能体仿真的奖励方案效能评估.....	99
5.3.1 异质主体出发时间选择模式与仿真有效性验证.....	100
5.3.2 智能网联环境下奖励方案实施效果.....	103
5.3.3 较大规模交通需求场景下的奖励方案实施效果.....	107
5.4 基于主体类型的奖励方案仿真优化.....	108
5.4.1 基于智能增强的奖励方案仿真优化.....	108
5.4.2 优化奖励方案案例结果分析.....	114
5.4.3 预算约束下的优化奖励方案.....	119
5.5 本章小结.....	125
第6章 结论与展望.....	127
6.1 主要研究成果.....	127
6.2 研究创新点与贡献.....	129
6.3 研究不足与展望.....	130
参考文献.....	133
致谢.....	143
个人简历、在读期间发表的学术成果.....	144



第1章 引言

1.1 课题来源

本课题来源于：

1. 科技创新 2030-“新一代人工智能”重大项目（2022ZD0115602）：交通系统全息感知与可计算模型构建，2022-2025
2. 国家自然科学基金杰出青年基金(52125208)：交通系统建模与优化，2021-2025

1.2 研究背景

智能网联汽车（Connected Automated Vehicles, CAVs）作为通信、计算和人工智能深度融合的创新载体，为解决交通拥堵难题提供了创新方案。在传统交通系统中，人工驾驶车辆（Human-driven Vehicles, HVs）的利己性出行行为往往导致系统形成用户均衡（User Equilibrium, UE）状态，造成交通资源的低效配置^[1]。CAVs 通过车联网技术实现实时信息共享，并依托集中式中央云控平台优化出行选择，从而重塑出行行为模式，有望推动交通系统由 UE 状态向系统最优（System Optimal, SO）状态转变^[2]。研究表明，理想条件下 SO 模式较 UE 模式可有效缓解甚至完全消除系统拥堵^[3, 4]。

在自动驾驶技术发展的长期过渡阶段，交通系统将维持 HVs 和 CAVs 共存的智能网联交通环境^[5]。大量研究表明，在此环境中，即便缺乏全局调控能力，仅对 CAVs 子集实施协同调控，依然可以提升交通系统运行效能，使系统整体趋近于 SO 状态^[6, 7]。美国密歇根大学 Yafeng Yin 教授以及亚利桑那大学 Yi-Chang Chiu 教授的研究表明，在 CAVs 市场渗透率较低时，交通系统也可实现接近 SO 的运行状态^[8, 9]。然而在上述研究中，基于 CAVs 的系统优化往往需要部分用户放弃个体最优出行选择，进而引发系统效益提升与个体利益受损之间的矛盾^[10]。换言之，仅依靠 CAVs 技术实现的系统最优状态并非帕累托最优^[11]。该矛盾将削弱用户对 CAVs 系统规划选择的信任度和满意度，制约系统整体优化效能。

为缓解这一矛盾，引入经济杠杆（主要包含奖励与惩罚两种形式）成为必要手段。其中，惩罚性措施如限时通行、拥堵收费等^[12]，应用较为广泛，但在出行公平性与公众接受度方面存在显著局限^[13]。相较而言，基于奖励的交通需求管理（Incentive-based Travel Demand Management, IBTDM）具有制度优势和应用潜

力：其通过经济奖励引导个体调整出行行为，实现交通需求的时空优化配置，实施阻力小、公众接受度高，在全球范围内获得广泛关注并取得显著成效^[14]。

在智能网联环境中，CAVs 具有可预测、可调控特性^[15]，IBTDM 可基于此量化其出行成本，并为因系统调控而成本增加的个体提供差异化补偿，实现系统调控目标与个体最优选择的匹配，能够有效引导 CAVs 选择及提升用户对调控建议的遵从度。同时，IBTDM 采用奖励促进 HVs 行为趋于稳定的系统优化状态，避免其对 CAVs 系统调控的干扰，充分发挥 CAVs 的技术优势。综上，IBTDM 能够化解制约 CAVs 系统最优调控目标的矛盾，提升智能网联交通系统运行效能。

因此本文聚焦于智能网联环境下的 IBTDM 优化研究。该环境核心特征在于：一方面，存在多类型主体，如传统 HVs 与依托网联通信与协同优化算法的 CAVs；另一方面，不同主体在信息可得性、出行选择逻辑上存在显著差异^[16]。若忽视上述差异，奖励将缺乏针对性，导致资源配置低效、行为偏离系统目标。因此研究结合主体属性（CAVs/HVs）和认知能力（完全理性/非理性）构建正交分类体系，提出适应智能网联环境的行为异质性建模方法，具体而言：（1）**主体属性维度**：将主体划分为 CAVs 和 HVs。CAVs 出行行为由优化算法生成，并通过云控系统推荐供用户确认；HVs 依赖自主选择。（2）**认知能力维度**：将主体明确区分为理性和非理性主体。理性主体实质上指完全理性个体，在完全信息与充分认知下进行效用最大化选择。非理性主体实为非完全理性个体，在信息不完全或认知受限条件下基于自身判断做出主观最优选择，其行为偏离效用最大化，但并非随机或无序行为。为简化表述，研究后续称之为理性主体与非理性主体。在该分类框架下，通过 IBTDM 调控异质主体，提升交通运行效能构思如图 1.1 所示。




图 1.1 IBTDM 与 CAVs 协作提升交通系统运行效能构思

为了提高 CAVs 用户对出行选择的满意度与依从性以及系统公平性,云控平台可采用以个体利益优先的出行选择原则,并通过协同优化出行行为与 IBTDM 行为诱导提高整体系统效能。此时,在构建的正交分类框架中:1) 理性 CAVs 和理性 HVs 在完全信息下的出行选择逻辑相同,故统一归类为“理性 CAVs 和 HVs”;2) 非理性 HVs 基于个体感知与 IBTDM 反馈,采用启发式规则进行经验性选择;3) 非理性 CAVs 具备群体内部通信能力,即能够与其他 CAVs 共享出行计划、交通状态等关键出行信息,然而其无法直接感知 HVs 群体的真实出行选择,需依赖有限观测数据进行推理。在此基础上,非理性 CAVs 结合通信能力与推理结果,采用协同优化算法做出兼顾建议可行性与出行成本的类人化选择(如基于大语言模型)。最终主体被划分为三类——理性 CAVs 和 HVs,非理性 HVs,非理性 CAVs。通过调节三类主体在交通系统中的占比,可适应不同发展阶段和组成结构的交通场景需求。

现有研究分别从面向理性主体的出行行为建模及奖励方案设计^[17-19]、非理性 HVs 在奖励干预下的单次行为个体差异性分析^[20-22]以及理性 CAVs-HVs 出行选择理论及仿真建模^[5, 6, 23, 24]等维度展开,为面向智能网联环境的 IBTDM 设计提供了初步框架和实践探索。然而,现有研究仍存在局限性,限制了其在智能网联背景下的适用性与优化潜力:一方面,理性与非理性主体在奖励影响下的出行选择行为建模分析普遍基于静态框架——即仅表征个体的单次选择——难以适应逐日博弈、信息不完全与反馈滞后的动态环境;另一方面,现有研究聚焦于理性主体均衡状态建模及奖励方案设计,缺乏对非理性行为扰动及其在逐日群体行为演化中传播机制的刻画,难以支撑理性与非理性主体共存系统的奖励设计。为突破上述瓶颈,本研究从两方面着力提升 IBTDM 对智能网联环境的适应性:一是完善理性与非理性主体在奖励影响下的动态出行选择行为模型;二是鉴于理论模型难以处理动态反馈和非理性扰动的局限性,构建适应异质主体动态交互环境的奖励方案仿真优化方法。面临的若干关键科学问题如图 1.2 所示。




图 1.2 研究涉及的关键科学问题



(1) 理性 CAVs 与 HVs 出行选择行为建模及奖励方案优化

作为柔性治理工具，智能网联环境下 IBTDM 效能受个体出行选择与全局约束（IBTDM 项目面临的预算、渗透率等限制条件）联合影响。个体层面，主体在奖励影响下的出行选择机制直接决定了奖励调节效能；全局层面，有限预算及其异质主体间的分配（包括宣传与激励成本配置），内生性地决定了 IBTDM 策略的市场渗透率，从而形成策略实施的刚性边界。针对智能网联环境中出行选择机制明确、奖励调控效能可量化的理性 CAVs 和 HVs，构建出行行为模型并求解奖励方案，是智能网联环境下奖励优化的基础。该研究的核心难点在于：如何基于行为调整与成本映射关系，建立奖励强度与个体行为之间的量化模型，即出行选择行为模型；并构建个体及全局因素与奖励效能的量化映射关系，通过协调 IBTDM 全局资源配置（激励成本、异质渗透率）与个体奖励强度实现方案优化。

(2) 非理性 HVs 出行选择行为逐日演化建模

在智能网联环境中，非理性 HVs 呈现非理性出行选择特征，与理性主体出行选择机制存在显著差异。当 CAVs 精确选择与非理性 HVs 不确定性行为在时空维度产生干涉时，奖励机制可能诱发非预期的交通拥堵。因此，需要进一步探究非理性 HVs 的出行行为选择机制和动态演化特征。在高峰通勤重复出行选择场景中，该问题的复杂性呈现在两个维度上：在日内出行选择维度，非理性 HVs 在奖励影响下的出行选择表现出显著的不确定性和个体差异性，且此出行选择模式随奖励类型呈现系统性变化，传统效用理论难以解释这一复杂特征。在逐日动态演化层面，重复博弈情境中观察到的非理性 HVs 认知适应过程，既存在个体内部的认知动态演化，又表现出个体间的差异化演化路径，传统动态模型准确刻画此过程。因此，构建非理性 HVs 出行选择预测模型，量化特定奖励策略下的出行选择行为和长时演化规律，是智能网联环境下 IBTDM 方案优化亟待突破的难点之一。

(3) 基于异质主体出行行为耦合演化的奖励方案仿真优化

在由完整异质主体（理性/非理性 HVs 与 CAVs）构成的智能网联环境中，奖励方案的仿真优化面临着全新挑战：1）非理性出行选择重塑系统均衡：非理性 HVs 受非理性（如锚定效应、损失规避）驱动，表现出个体差异性，非理性 CAVs 通过算法进行选择并持续迭代策略。非理性行为增加了博弈复杂性和动态性，提升了行为仿真建模和优化求解难度。2）非对称认知架构下的出行选择耦合演化导致奖励效能不稳定：理性主体基于全知视角优化选择，非理性 HVs 通过 IBTDM 系统反馈在有限认知下调整行为，而非理性 CAVs 则具备多模态环境感知和适应能力。在此非对称认知架构下，“出行选择-状态更新-信息反馈”循环导致个体选择形成耦合演化过程，引发系统状态不稳定，增加了奖励方案效能



评估和优化难度。3) 奖励方案优化必须纳入预算限制、奖励形式、渗透率等结构性知识,以确保策略的现实可行性与合理性。针对上述挑战,建立能够刻画异质主体认知差异与出行选择耦合演化规律的仿真建模框架,评估奖励方案长时效能;在此基础上,发展具备环境适应性、结构可行性与帕累托改进能力的高效奖励方案优化方法,是智能网联环境下 IBTDM 的方案优化的核心难点。

为应对上述挑战,本研究重点解决以下问题:一是 CAVs 与 HVs 在奖励影响下的出行行为建模与特征解析;二是智能网联环境下的异质主体出行行为逐日演化仿真;三是面向异质主体的时变奖励机制的优化设计,为引导智能网联系统向最优状态演进、缓解系统拥堵提供理论基础和方法支撑。

1.3 研究目标与意义

1.3.1 研究目标

IBTDM 策略的管控目标可分为四类:1) 改变出行路线;2) 改变出发时间;3) 改变出行方式;4) 取消出行。其中,改变出发时间策略因其易于实施且效果显著,已成为当前应用最广泛、形式最多样的 IBTDM 策略类型^[25],并有望在未来交通管理中占据主导地位。例如, Metropia 作为典型实践项目,已吸引逾 10 万用户参与,在优化出发时间选择的同时实现了商业化盈利^[26],进一步证明改变出发时间策略的应用价值和可行性。此外,相较于改变出行路径等 IBTDM 策略,改变出发时间策略在智能网联环境中具有较强的适应性:出发时间选择具有“一次性”特征,CAVs 和 HVs 可在出行前充分理解奖励机制与反馈信息,完成选择,从而提升行为调控效能;该类策略对 CAVs 技术(如车际通信、实时计算、环境感知)及实时信息采集、响应的依赖性低,适应智能网联系统发展初期且稳定性强,并可作为高技术依赖型 IBTDM 策略(如改变出行路径)研究的起点和基础。

因此,本研究聚焦通勤场景下的逐日出发时间选择行为,旨在求解智能网联环境下实现系统帕累托改进的 IBTDM 方案,以充分发挥 CAVs 和 IBTDM 协作调控出发时间选择、推动交通系统向最优状态演进的潜力,并为改变出行路径、改变出行方式等 IBTDM 策略设计及融合实施提供理论模型支撑与方案设计参考。

具体而言,研究力图实现以下研究目标:

(1) 解析理性 CAVs 和 HVs 出发时间选择机制并求解适用奖励方案:基于瓶颈模型,针对出发时间选择行为,解析智能网联环境中的理性 HVs 和 CAVs 出行成本结构及其在奖励影响下的出发时间选择机制;构建数学模型求解总奖励预算在激励成本与异质宣传成本之间的最优分配方案;在预算配置关系约束下,推



导考虑原始出发时间特征的最优时变奖励方案。

(2) **分析非理性 HVs 逐日动态出发时间选择机制**：开展问卷调查和长时实验室实验，系统考察非理性 HVs 在奖励影响下的逐日动态出发时间选择特征及其影响因素，识别高依从度群体以优化 IBTDM 宣传策略；构建非理性 HVs 出发时间选择预测模型，揭示其选择模式及逐日演化规律，为智能网联环境下的奖励方案设计提供实证依据和行为建模支撑。

(3) **构建智能网联环境三类主体逐日出发时间选择仿真框架并优化奖励方案**：综合上述理性主体和非理性 HVs 在奖励影响下的出发时间选择机制研究，引入非理性 CAVs 出发时间选择特征，构建包含智能网联环境中全体出行者（理性/非完全理性 CAVs 和 HVs）的多智能体仿真框架，表征逐日重复博弈场景下的复杂出发时间选择行为，量化评估奖励方案长时实施效能；在此基础上，求解具有智能网联环境适应性、结构可行性与帕累托改进能力的自适应的奖励方案。

1.3.2 研究意义

本研究在提升 IBTDM 交通治理水平和 CAVs 系统优化效能方面具有显著的理论价值与实践意义，为智能网联环境下的交通治理提供新方案，有助于推动交通系统向智能化、可持续发展。具体如下：

(1) 有助于提升 IBTDM 交通治理效果，保障其可持续运营。首先，考虑异质主体在奖励影响下的出行选择差异，设计针对性出发时间干预机制，有助于减少高峰时段出行密度，并提升预算投资回报率与行为干预有效性，为缓解常态化拥堵和提升交通基础设施时空利用效率提供创新路径。此外，基于个体在奖励影响下的出行行为特征分析，有助于识别 IBTDM 目标群体，为提升用户留存率及实现 IBTDM 可持续运营提供理论支撑与实证依据。

(2) 有助于提升 CAVs 的出行行为调控效能。一方面，研究所构建的 IBTDM 方案，使 CAVs 提供的系统最优出行选择同时实现个体效用最大化，有助于提高用户对 CAVs 建议的满意度和依从度。另一方面，研究揭示的 HVs 出行行为选择特征，为 CAVs 算法设计提供行为依据，使 CAVs 策略设计更契合 HVs 的成本评估模式，从而提升用户对 CAVs 的接受度。

(3) 有助于为智能网联环境下多维度 IBTDM 策略设计提供方法基础和实践指导。一方面，研究构建的多类型出行者的异质性出发时间选择模型及基于仿真的奖励优化机制，具有通用性，其模型框架依托于出发时间“一次性”选择行为特征，可作为离散多次出行选择建模的基础模块，进而应用于路径诱导等 IBTDM 设计场景，为相关策略设计提供方法支持。同时，研究提出的基于主体类型的奖励方案，为路径诱导和出行方式转换等 IBTDM 策略制定提供奖励形式



与具体方案参考。另一方面，改变出发时间策略所体现的时变特性为多时段路径诱导与方式引导等提供时空协同优化的新思路，可作为多维度 IBTDM 融合实施的重要切入点——基于出行选择的时间依赖性，整合多维度 IBTDM 策略（如改变出发时间调整、改变出行路线、改变出行方式），构建综合化、智能化需求管理体系，提升系统效能。例如，可基于路径拥堵程度动态调整出发时间奖励强度。

（4）有助于形成 IBTDM-CAVs 协作优化框架，为智能网联交通治理政策的制定提供方法指导。一方面，通过优化个体出行选择与系统运行效能的一致性关系，为智能网联环境下的交通管理政策设计提供全新思路和科学依据。另一方面，研究提出的异质主体行为建模技术及管理方案动态优化的融合人类与人工智能优势的智能增强方法，适用于数据驱动、精准施策的智慧交通治理模式，对交通系统智能化、绿色化、可持续化转型具有重要意义。此外，研究还为 IBTDM 与 CAVs 的深度协作融合提供新路径：通过设计奖励机制引导 CAVs 向绿色共享模式演进，提升其商业化可行性，同时利用 CAVs 感知与协同优势，使得 IBTDM 推广成本更低、反馈周期更短、控制精度更高，推动政策和技术的良性互动。

1.4 论文研究内容与结构

1.4.1 研究内容

鉴于改变出发时间策略的行为引导优势及其对智能网联环境的适应性，本研究聚焦于逐日早高峰通勤出发时间选择问题，基于智能网联环境中的主体分类，依次考察理性 CAVs 和 HVs、非理性 HVs、非理性 CAVs 三类群体的在奖励影响下的出发时间选择行为规律，以此优化 IBTDM 奖励方案。首先，为确定全局约束、个体出发时间选择与奖励强度的量化映射关系，考虑到理性 CAVs 和 HVs 出发时间选择机制明确、奖励调控效果可量化，研究采用数学建模方法解析其奖励影响下的出发时间选择机制并量化奖励效能，求解最优时变奖励方案；其次，鉴于非理性 HVs 在出发时间选择中表现出高度个体差异与复杂性，难以通过规则化方式建模，研究引入数据驱动方法，基于问卷及长时交互实验数据探究非理性 HVs 出发时间选择特征及逐日演化规律；最后，考虑当前 CAVs 尚未广泛部署，现实中难以低成本、低风险地观测异质主体交互行为，且传统建模方法在刻画多主体交互及行为演化、非理性特征方面存在局限，难以支持奖励方案在智能网联环境中的长时效能评估，研究综合理性主体与非理性 HVs 的出发时间选择机制，并引入非完全信息下的 CAVs 行为特征，构建多智能体仿真框架，以模拟多主体交互过程，并采用智能增强的仿真优化方法，实现智能网联环境奖励方案的适应

性优化。研究构建的异质主体选择行为模型及仿真优化框架可进一步推广至出行路径、出行方式等选择行为的建模研究，所提出的基于主体分类的时变奖励机制设计，也为智能网联环境下多行为维度 IBTDM 策略的形式设计与时空融合实施提供新的理论视角与管理思路，从而提升 IBTDM 在智能网联环境下的管控水平。主要研究内容如图 1.3 所示：




图 1.3 研究内容定位

(1) 针对理性 CAVs 和 HVs 的出发时间选择行为建模与奖励方案优化

理性 CAVs 和理性 HVs 在完全信息、完备认知下实现效用最大化的出发时间选择。研究针对智能网联环境中的理性 HVs 和 CAVs，刻画其奖励影响下的出发时间选择机制，从奖励预算分配和奖励方案优化两个维度对现有奖励策略进行系统性改进。该研究成果为后续探究内容（2）非理性 HVs 在奖励影响下的出发时间选择机制分析提供基准方案与理论框架，为内容（3）智能网联环境下的奖励方案优化提供理性主体行为模型。

基于 Vickrey 经典瓶颈模型^[4]，刻画智能网联环境中的理性主体早高峰的出发时间选择行为，采用出行时间成本、计划延误成本与奖励表征出行者广义成本，求解理性出行者的均衡状态。

围绕奖励预算在宣传成本（用于获取项目用户）与激励成本（用于激励用户调整出发时间选择）之间的优化分配问题，研究以最小化总行驶时间为目标函数，以宣传成本为决策变量，构建考虑总奖励预算约束的数学规划模型，求解同质（单 HVs）和异质（HVs 和 CAVs）行驶时间成本和单位宣传成本情况下的激励成本和宣传成本的最优分配方案。

将出行者的出发时间偏移成本纳入广义出行成本函数，构建考虑出行惯性的扩展行为模型。运用反证法及数学推导方法，解析出行者在奖励影响下的原始出发时间及出发时间调整模式，据此刻画出行选择机制及优化在总预算分配关系（决定渗透率、激励成本）下考虑出发时间改变幅度的奖励方案。



(2) 针对非理性 HVs 的出发时间选择行为分析与建模

非理性 HVs 基于个体感知与 IBTDM 反馈信息, 采用启发式规则进行经验性选择, 其出发时间选择偏离效用最大化, 但仍呈现有限理性特征。研究针对智能网联环境中的非理性 HVs, 从多样化奖励策略偏好和特定奖励策略下的出发时间选择逐日演化两个维度探究其在奖励影响下的出发时间选择机制, 识别其影响因素, 进一步构建非理性 HVs 出发时间选择预测模型。该行为模型将作为内容(3)中智能网联环境下异质主体建模的关键组成部分, 为智能网联环境下的奖励方案优化奠定行为建模基础。

鉴于实验室环境下探究在多样化奖励策略下的行为选择规律存在场景构建复杂、长期实验成本高昂及样本量不足等问题, 本研究采用问卷调查与实验室实验相结合的方法: 通过问卷获取大样本多样化策略偏好数据, 通过实验室实验精确追踪特定奖励策略下的出发时间选择行为选择演化, 从而保证数据可靠性。

首先, 依托高德地图平台在苏州(该地区具有 IBTDM 项目实施经验)开展大规模问卷调查, 获取国内首个涵盖非理性 HVs 奖励策略偏好的高质量数据集, 构建以社会人口统计学特征和出行属性为解释变量、奖励方案接受度为响应变量的结构方程模型 (Structural Equation Model, SEM), 识别高接受度用户群体的显著影响因素, 为针对出行模式和出发时间的奖励项目筛选目标用户提供实证依据。

其次, 开展为期 31 天的动态交互实验(含 10 天无奖励对照期和 21 天奖励干预期), 采集非理性 HVs 在基于理性假设的奖励方案下的出发时间选择数据, 量化分析非理性 HVs 在奖励策略影响下的出发时间选择模式, 运用面板分析、聚类分析等方法识别具有高参与度和行为依从性的潜在优质用户及其影响因素。

基于上述数据, 本研究进一步构建非理性 HVs 在奖励影响下的出发时间选择预测模型。通过比较神经网络 (Neural Network, NN)、长短期记忆网络 (Long Short-Term Memory, LSTM) 和 Transformer 三种深度学习架构的预测精度, 最终选择具有最强时序特征捕捉能力的 Transformer 模型, 建立融合奖励策略和交互机制影响的非理性 HVs 出发时间选择行为预测模型。

(3) 异质主体出发时间选择行为仿真与基于主体类型的奖励方案优化

非理性 CAVs 依托群体内部通信并对 HVs 行为进行推理, 采用协同优化算法, 提出兼顾建议可行性与出行成本的类人化出发时间选择建议。研究综合考虑上述(1)(2)中的理性主体、非理性 HVs 在奖励影响下的出发时间选择机制, 进一步引入非理性 CAVs 出发时间选择行为特征, 构建多智能体仿真框架, 评估奖励方案实施效能和不同主体表现差异, 并优化适用于智能网联环境的奖励方案。

首先, 鉴于大语言模型在语义表征、处理非结构化交通信息(如模糊环境反馈、不确定他车意图)方面的优势, 及其在多智能体协同中的良好扩展性, 研究



采用大语言模型来表征非完全信息下的非理性 CAVs 出发时间选择。基于此，构建多智能体仿真框架，仿真框架包含三类异质智能体——理性 CAVs 和 HVs 智能体、非理性 CAVs 智能体以及非理性 HVs 智能体，从而再现智能网联环境下的交互关系和系统演化过程，评估奖励方案的长时效能。

应用该仿真系统，定量评估不同智能体构成比例下理性假设奖励方案的实施效能，揭示三类智能体出发时间选择和交互适应模式等方面的差异，并评估智能体自身出行成本表现和对整体交通系统效能的影响。

基于仿真分析结果，研究进一步提出融合专家经验与智能算法的智能增强（Intelligence Augmentation, IA）仿真优化方法，求解智能网联环境下基于主体类型的奖励方案。根据不同类型主体在奖励作用下的异质出发时间选择特征，分别设计对应奖励方案，并采用基函数方法实现参数降维；构建双层优化框架，上层模型以系统总延误最小化为目标，下层模型通过多智能体仿真平台输出系统效能指标，为上层优化提供反馈；结合贝叶斯优化算法，持续学习历史仿真数据并预测趋势，指导参数优化方向，最终在预算约束下求解最优奖励参数及奖励方案，实现交通拥堵缓解效益的最大化。

1.4.2 技术路线与论文结构

本论文的技术路线如图 1.4 所示。章节划分如下：

第1章 引言

分析本论文的研究背景和研究需求，确定研究目标，阐明研究意义，并确定主要研究内容与技术路线。

第2章 文献综述

分别从 IBTDM 实证有效性验证和理论奖励方案设计，非理性 HVs 的出行选择特征分析以及智能网联环境下异质主体建模与管理方案研究三个方面对现有研究做梳理分析。

第3章 理性 CAVs 和 HVs 出发时间选择行为建模与奖励方案优化

本章对应于研究内容（1）智能网联环境中针对理性 HVs 和 CAVs 的出发时间选择行为建模与奖励方案优化。首先，构建面向理性出行者（包含部分 HVs 和 CAVs）的广义出行成本结构和出发时间选择行为模型；基于此出发时间选择机制，以最小化总行驶时间为目标，求解宣传成本与激励成本之间的最优奖励预算分配方案；然后，将出行者的原始出发时间纳入理性出行者的广义出行成本函数，求解系统的均衡状态演变和以最小化总行驶时间的最优奖励方案。本章构建的理性主体行为分析框架为后续探究非理性主体出发时间选择机制及智能网联环境下的 IBTDM 方案提供理论支撑与理性行为建模基础。



第4章 非理性 HVs 出发时间选择行为分析与建模

本章对应于研究内容（2）智能网联环境中针对非理性 HVs 奖励影响下的出发时间选择行为分析与建模。智能网联环境中的非理性 HVs 的出发时间选择具有不确定性和复杂性，与理性主体存在显著区别，为此需进一步明确非理性 HVs 在奖励影响下的出发时间选择机制。通过问卷调查与实验室实验相结合的方式，系统探究非理性 HVs 对不同奖励形式与管控目标（出行模式及出发时间）的奖励策略的偏好以及其关键影响因素，识别高依从度用户群体的典型特征，基于第3章的预算分配框架，为宣传成本约束下的推广策略细化提供用户筛选标准和宣传方式优化依据。基于上述数据，构建融合奖励机制与交互影响的基于 Transformer 的时序行为预测模型，为后续智能网联环境中非理性 HVs 智能体的出发时间选择行为建模提供可靠的技术路径，从而支撑智能网联场景下奖励策略评估与优化。

第5章 异质主体出发时间选择行为仿真与奖励方案优化

本章对应于研究内容（3）智能网联环境中基于多智能体仿真的奖励方案优化。首先，构建多智能体仿真框架，整合三类异质主体——理性 HVs 和 CAVs 智能体、非理性 CAVs 智能体以及非理性 HVs 智能体，评估现有奖励方案在智能网联环境下的实施效果和不同主体的表现差异。基于分析结果，采用智能增强的仿真优化思路，基于先验知识明确奖励形式、参数和约束，构建双层优化框架，并通过贝叶斯优化算法求解最小化延误的奖励方案。上述方法有助于提高 IBTDM 对智能网联环境的适应性，发挥 IBTDM 与 CAV 协作优化交通系统运行效能的作用。

第6章 结论与展望

总结论文的研究成果与创新点，阐述论文的研究不足，分析后续研究方向与问题，提出研究展望。



25548202

第1章 引言




图 1.4 技术路线



第2章 文献综述

2.1 概述

本研究聚焦智能网联环境下基于奖励的交通需求管理的策略设计问题,以推动交通系统向最优状态演进。在智能网联环境中,主体基于属性和认知能力可划分为三类——理性 CAVs 和 HVs,非理性 HVs 和非理性 CAVs。基于此,研究需要考量三个核心问题:(1) 智能网联环境下理性 CAVs 和 HVs 出行选择行为建模与方案设计,(2) 非理性 HVs 的非理性出行选择机制探究,(3) 智能网联环境下的面向异质主体的耦合演化建模。为系统解决上述问题,本章将按照如下结构展开论述:2.2 节介绍了基于奖励的交通需求管理的制度优势、应用效果和面向理性主体的奖励方案设计进展,2.3 节梳理了非理性 HVs 的出行选择机制研究;2.4 节回顾了智能网联环境下异质主体行为理论及仿真建模研究,2.5 节总结了各个问题的研究不足、可改进空间和本论文的研究方向。

2.2 IBTDM 有效性及理性 CAVs 和 HVs 奖励方案设计

近年来,CAVs 的快速发展为缓解拥堵带来了新的潜力——通过中央云控平台实现出行选择优化,推动交通系统从用户均衡向系统最优转变。然而,系统优化带来的整体效益提升与个体利益损失矛盾,制约着 CAVs 的系统优化效果。

传统惩罚性交通需求管理措施,以及提高 CAVs 效能的针对性措施如建设 CAVs 专用车道^[27]等,均存在实施成本高、用户满意度低等局限性。IBTDM 作为一种创新型的交通治理方式,具有显著的制度优势:其通过经济奖励弥补个体因系统优化而损失的效用,实现个体效用最大化和系统最优目标的一致性,从而消解制约 CAVs 系统最优调控目标的矛盾。

基于此,本节将首先总结典型 IBTDM 实践应用,明确其在行为调控、缓解系统拥堵方面的有效性和制度优势;继而系统梳理 IBTDM 方案设计的数学模型与方法论研究进展,为优化适用于智能网联环境的 IBTDM 方案提供建模基础。

2.2.1 IBTDM 实证有效性验证

目前为止已有许多成功的 IBTDM 应用,证实了 IBTDM 策略通过经济激励调控出行需求分布、缓解交通拥堵方面的可行性和应用潜力。

荷兰于 2006 年开展的错峰实验“Spitsmijden”^[28],通过给予不同形式的奖



励,如现金、奖券、礼品等,鼓励出行者主动错开高峰出行。该实验证实了奖励可以激励出行者选择改变其出发时间或者出行方式,从而缓解高峰期交通拥堵。

斯坦福大学实施的“INSTANT”实验^[29]通过经济奖励措施引导出行者向非高峰时段转移,从而优化交通流分布。实验结果表明,该策略将参与者通勤时间从基准值 71 分钟缩减至 54 分钟,验证了奖励缓解高峰拥堵的有效性。此外,新加坡^[30]、日本^[31]、德国^[32]、澳大利亚^[33]等地也通过地铁及公交票价减免政策的应用示范与实证研究,证明了奖励在诱导出行方式改变的有效性。

而随着移动应用技术的发展,智能手机能够实时采集用户出行数据、传递交通信息并给予个人奖励^[34,35],为 IBTDM 的实施提供了重要支持。Metropia 以手机 APP 为管理载体及数据收集工具,以礼品卡为奖励方式,鼓励小汽车错峰、拼车出行,观察到高峰小时出行减少了 13%^[25]。

表 2.1 系统梳理了现有 IBTDM 实证研究的主要成果。现有 IBTDM 项目通过经济激励,诱导出行者改变出发时间、出行方式或者减少出行,在行为引导有效性和拥堵缓解效果两个维度均表现出显著的政策效能。

表 2.1 IBTDM 社会实验及应用示范总结

针对行为	名称	国家/城市	规模	奖励方式	项目时长	效果
出发时间	CAPRI ^[36]	美国 斯坦福大学	4000	停车优惠券/ 免费球票/现 金	2012-2014	35%高峰出行者转 移至非高峰出行
出发时间	Spitsmijden ^[37,38]	荷兰	340	2-7 欧元/天 或智能手机	2006 年一 期实验	高峰出行量减少 50%
出发时间	INSINC ^[39]	新加坡	--	现金抽奖/早 7:45 前错 峰票价	2012 年至 今	实施前 6 个月内 10%高峰出行者转 移至高峰前出行
出发时间	BART Perks ^[40]	美国旧金山	18000 人	积分	2016 为期 六个月	实施期间高峰出 行减少 10.9%
出发时间/ 拼车出行	Metropia ^[26]	美国	>10 万	礼品卡	2012 年至 今	高峰小时出行减 少 13%
出行方式	AMORE	美国 Tucson		积分、出行 补贴	2017	个体出行减少 60%
出行方式	Way to go	美国西雅图	86 个家 庭	现金奖励	2000-2002	减少了 27%的行 驶里程
出行方式	Bella Mossa ^[41]	意大利 博洛尼亚	15000 人	积分	2017 年为 期六个月	个体出行减少 7.7%
出行方式	Flex Pass	加州伯克利	392 人	现金奖励	2015 为期 3 月	停车需求减少 4.2%
取消出行	Driveless ^[42]	美国 佛罗里达州	约 200 人	现金奖励	2012 年	参与者 VMT 平均 减少 16%



我国 IBTDM 市场潜力巨大。以北京 IncenTrip 项目为例,其数据采集与试点工作已取得初步成效^[43]。特别是在“双碳”战略推动下,碳普惠平台和个人碳账户等创新机制为 IBTDM 本土化实践提供了重要参考^[44]。此外,各种出行服务商推出的动态定价策略亦可被认为是一种变相的 IBTDM 手段,如百度地图的绿色出行红包、高德实时公交奖励等。

上述国内外的应用实践和实证效果表明,IBTDM 在未来智能交通系统中具有广阔的应用潜力和前景。

2.2.2 理性 CAVs 和 HVs 的奖励方案优化设计

现有 IBTDM 应用中的奖励方案设计大多基于被动反馈的试错法^[45],调控效果存在显著滞后性。为提升 IBTDM 的行为调控效能,充分发挥其在智能网联环境中与 CAVs 技术协作以推动系统优化的潜力,亟需构建精细化的奖励机制。

数学建模与优化是设计精细化奖励方案的有效方法。已有文献通过理论建模方法系统研究了现行交通环境下的精细化拥堵定价问题。Pigou^[46]在 1920 年即开创性地提出了拥堵收费的概念,并给出了无约束下的静态第一最优收费方案。沿着 Pigou 的技术路线,现在国内外的研究已经从第一最优扩展至第二最优(考虑诸如指定收费路段及收费设备安装成本等约束)^[47],从静态问题拓展至动态问题^[48, 49],从单瓶颈模型^[50]拓展到多瓶颈网络模型^[51, 52]。

然而在实际操作中,奖励政策面临着许多惩罚政策中不需要考虑的技术挑战与市场约束,奖励方案相比于收费方案则更为复杂,例如项目还需考虑其特有的总奖励预算、渗透率、宣传成本等特殊市场约束,可行域自由度明显较多,因此,惩罚政策的相关结论无法直接套用至奖励政策。

近年来,学术界围绕出行选择机制明确、奖励调控效果可量化的理性主体,对其精细化奖励方案优化设计问题开展了系统性的研究工作。

目前研究主要聚焦在以改变小汽车通勤出发时间为靶向目标的奖励策略。Rouwendal 等^[17]比较了具有弹性需求的不同管理策略(包括通行费,收费和奖励)之间的相对效率,并得出结论,奖励可以作为缓解拥堵的第二好方法,在收费制度不被接受的情况下,可以很大程度的缓解拥堵问题;并基于经典 Vickrey 瓶颈模型^[53, 54],研究了在弹性需求且无约束条件下的最优时变奖励形式,研究结果表明最优时变奖励呈“V 型”分布,即极限拥堵高峰时刻奖励为 0;而远离极端拥堵时刻时,奖励水平不断增大。通过“V 型”奖励,可鼓励原本在高峰时段出行的通勤者改在远离高峰时段出行,有效降低排队长度。Chakraborty 等^[55]考虑到给定的奖励预算,将奖励曲线制定为线性,并试图估算给定奖励模式的收益。但是没有得出最优奖励曲线。类似地,Wu 等^[56]提出了一个双层规划模型来评估奖



励对出行者出发时间选择的影响,上层规划的目标函数为最小化系统总行驶时间,下层规划为确定性用户均衡,通过求解模型得到奖励应在高峰期的“肩膀处”达到最高水平,且高峰期保持最低水平。这和 Cohen^[57]及 Arnott^[54, 58, 59]等提出的最优收费概念是镜像的。Sun 等^[18]在原有约束的基础上额外考虑了预算、市场渗透率、用户异质性问题,得出结论预算不足或者渗透率不足的情况下,时变的奖励曲线形状呈“U”型;奖励会优先作用于单位行驶时间成本高的通勤者,单位行驶时间成本低的通勤者同样能因为拥堵缓解而使得成本下降。Wu 等^[19]考虑了弹性需求对 IBTDM 方案的影响,以充分辨析奖励方案与传统收费方案的差别。

在出行模式转型方面,信息技术的快速发展和智能手机的广泛普及催生了拼车服务的迅猛发展。这种新兴的共享出行模式已成为城市交通方式革新的重要路径^[60, 61]。在拼车领域的研究仍存在明显空白。Brownstone 等早在 1990 年代就论证了经济激励对促进拼车参与的有效性^[62]。此外,Agatz 等^[63]指出,政府补贴是提升拼车系统效能的有效工具。在相关理论研究中,李梦等^[64]构建了共乘出行条件下的用户均衡交通分配模型,其研究假设共乘司机和乘客均可获得额外出行奖励。此外,孙剑等^[65, 66]将 IBTDM 拓展至拼车场景,求解了针对拼车行为的奖励方案,丰富了其应用维度。

此外,相对于出发时间及出行模式,出行路径在实际情况中难以进行操作及定量分析,因此在理论方面目前仍没有相关文献研究基于奖励的交通网络建模。

国内缓解城市拥堵的策略主要聚焦于公共交通的发展,通过财政补贴引导出行者选择公共交通出行方式^[67, 68]。在此政策导向下,国内对基于奖励的交通需求管理的研究路径与国外有所差异,现有研究多集中在优化补贴方法与补贴机制,以提升公共交通补贴效率^[69-71]。此外,鼓励拼车也是缓解交通拥堵的重要手段之一^[72, 73]。努尔飞叶·吐鲁洪将奖励引入到拼车领域,提出了基于停车奖励机制的私人小客车合乘理念。

上述奖励方案设计侧重于从个体在奖励影响下的出行选择机制入手,而忽视了全局约束与奖励策略的联合优化;此外,针对出发时间调控的时变奖励方案设计未能充分发挥预算的激励效能,导致行为调节效果有限。因此,现有方案在实际应用中面临效果不理想和资源配置失当的问题,亟需进一步优化与改进。

2.3 非理性 HVs 出行选择特征分析

在智能网联环境中,存在非理性 HVs,其行为常偏离传统的效用最大化理论^[74]。在奖励措施影响下,非理性 HVs 的出行行为不仅受经济因素驱动,还受到认知偏差、社会规范和心理偏好等非理性因素的显著影响,呈现出复杂的个体差



异性和不确定性特征。因此,基于理性假设的出行选择机制和奖励方案,往往难以有效应对智能网联交通系统中的实际复杂情形。

为了准确刻画智能网联环境中的异质出行选择模式,并优化奖励方案,需要进一步探究非理性 HVs 面对奖励措施时的出行选择机制,提升奖励方案设计的针对性和有效性。

通过分析非理性 HVs 在奖励影响下的出行选择数据,可揭示用户特征与出行选择、奖励实施效能之间的内在关联,进而为非理性 HVs 的出行选择机制建模和 IBTDM 优化设计提供理论支持与科学依据。

当前相关研究主要采用三类数据采集方法:问卷调查法、实验室实验法和实地观察法,以下将分别介绍这三类方法的研究进展。

(1) 问卷调查

问卷调查方法(包含陈述偏好调查 SP 和揭示偏好调查 RP)能够高效获取大样本群体的出行态度和行为特征,有效捕捉受访者在 IBTDM 策略下的个体差异性出行选择模式及其关键影响因素,在非理性 HVs 出行选择机制研究中展现出独特优势。

鉴于交通需求管理策略下非理性 HVs 的出行选择高度依赖于其策略接受度^[75], IBTDM 策略接受度成为评估非理性 HVs 的出行选择模式和奖励效能的关键指标。现有文献对交通需求管理策略的接受度方面进行了广泛研究,早期主要关注惩罚性 TDM 策略的公众接受度,包括拥堵定价^[76,77]、碳税^[78]以及车牌限制政策^[79,80]等。秦焕美等^[81]则基于调查数据,比较了奖励与惩罚对小汽车出行行为选择的影响,并得出结论,奖励在激励出行者错峰出行上效果更好,收费在促使出行者放弃汽车出行上效果更好。

随着研究深入,学者们逐渐转向对 IBTDM 策略下非理性 HVs 的出行选择模式和影响因素的探讨。在社会经济学属性影响方面,Bueno 等^[82]研究表明,在雇主福利计划背景下,驾驶资格和居住区位交通可达性对通勤方式选择具有显著影响,家庭收入则不具有显著影响。Lin 等^[83]的研究进一步揭示了高收入群体对个人碳交易和碳税方案表现出显著的选择倾向。Bulteau 等^[84]对居住在巴黎地区的工人进行了代表性抽样调查,考虑了一系列社会人口、社会经济和环境变量,研究了经济和心理激励对促进拼车通勤的重要意义。

除社会经济特征外,出行特征变量(包括出行模式、目的和出发时间等)同样对出行选择产生显著影响。Cools 等^[85]的研究表明,在恶劣天气下的出行行为可能更为多变,且具有自由出行目的的个体表现出更强的时间弹性。

进一步研究发现,心理认知因素和社会环境变量对 IBTDM 策略的接受度具有系统性影响。Lowe 等^[86]验证了享乐动机、社会影响和时间可靠性等变量对拼



车行为意向的显著正向预测作用。Si 等^[87]证实态度倾向、环境关注度、感知有用性、奖励强度和个人创新性等心理维度对碳普惠制度参与意愿具有显著的解释效力。

(2) 实验室实验

虽然问卷调查具有较高可操作性,但无法真实的模拟出行场景,在了解非理性 HVs 意图和思维上的效果往往不佳。实验室实验方法通过仿真方法,能够有效模拟和解析奖励策略下受试者之间的博弈行为和出行选择的逐日演化过程,成为一种高可靠性、高效率的数据收集手段^[88],是研究非理性 HVs 面向奖励的出行选择行为特征及影响因素的重要方法。

在对出行行为的实验研究中,出行路径选择实验开展最为广泛^[89, 90]。Chorus^[91]设计出行者在六种出行情景下进行二元路径选择,旨在探究了风险规避和后悔厌恶对出行选择惯性的影响,实验数据证实了二者是出行选择惯性的共同决定因素。通过对比两组受试者在不同信息下的路径选择行为,并以 BPR(Bureau of Public Roads)函数计算出成本, Lida^[92]等探究了出行经验对受试者改变路径选择的影响。以多轮重复选择代表逐日出行,实验发现受试者在重复的路径选择过程中并未达到理论的均衡。

此外,对出发时间选择的研究大部分基于经典瓶颈模型及其拓展模型^[4, 93],目的在于探究高峰时期人们的出行行为。Lu^[94]等基于瓶颈模型设计了出发时间选择实验,探究交通系统的不确定性对出行者出发时间选择的影响,并结合实验数据提出了关于出发时间选择的强化模型。实验设计两组不同的实验方案,一组反馈系统出行信息,另一组仅反馈个人出行信息,令受试者在 16 个离散的出发时间中进行 150 轮重复选择模拟每日出行,最终得到的结论包括:提供完整的出行信息能有效减少出行者成本和风险系数,平均成本低(高)的出行者倾向于选择早(晚)出发等。通过设计不同的出行场景,如不同的反馈信息、出行者数量和交通条件, Han 等^[95]进行六组实验,每组包含 120 轮重复实验,探究早高峰的出发时间选择行为。实验结果表明,不同实验设置下的集计行为理论上都接近 UE,并且信息反馈对个体行为的影响远大于对系统的影响。

为评估交通管理措施的可行性和实施效果,研究者在对出行行为的实验研究中加入道路收费、可交易信用机制、奖励等策略。Anderson 等^[96]通过一个二元选择实验,开展了完全市场博弈的收费实验,发现最优收费下的系统效能得到有效提升。Aziz 等^[97]首次在实验中引入在线互动机制,探究人们在交易市场下的出行行为,同时包括了出行路径和出发时间选择。实验提出个人流动碳津贴(PMCA)的方案,设置用户使用碳信用出行,碳信用可以在模拟的拍卖市场上购买或出售信用。分析表明,中低收入群体对非工作出行的碳成本增加更敏感。针对受试者



的多样性, Tian 等^[98]在对可交易路票市场的研究中, 招募了不同地区、职业、年龄的受试者, 并设计了虚拟智能体模拟背景交通流, 研究了在不同供需条件下, 可交易路票能否快速收敛至均衡。

在奖励策略方面, Rey 等^[99]对基于抽奖的奖励方案进行了实验经济学研究。研究发现, 这种奖励措施的有效性与对出发时间变更结果的预期和个人对风险的态度有关。Tian 等^[100]通过开展实验室实验, 研究了非理性 HVs 对收费策略和奖励策略的倾向性, 揭示了损失规避风险偏好等非理性行为及其影响。

(3) 实地调查方法

实地调查方法通过真实场景下的行为观测, 能够获取出行者最为真实的出行选择数据, 为评估非理性 HVs 的出行选择特征和影响因素提供了最为可靠的支撑。

Shen 等^[22]基于金县地铁拼车奖励基金项目的数据发现, 货币奖励对鼓励单人驾驶者拼车的效果因社会人口特征和判断因素的不同而存在显著差异。Tian 等^[101]基于 Metropia APP 采集用户出行数据及社会经济学特征数据。低收入更愿意在奖励下改变出行行为。性别方面, 男性比女性更倾向于改变出发行为, 可能的原因是女性的行程更受家务和托儿的限制。Arian 等^[21]基于 Metropia 实证数据研究发现, 奖励措施的效果因用户的出行行为原因和预定的出发时间而异。奖励措施可能需要根据一天中的时间和出行目的进行定制。研究结果强调, 娱乐、办事和工作出行是早上高峰时段对奖励措施最敏感的出行目的。然而, 在晚高峰时段, 为其他出行、办事和上学成为最敏感的出行目的。Lemp 等^[20]基于 2000 年旧金山湾区出行调查数据, 研究表明, 具有不同出行目的的出行者在出发、到达时间方面表现出不一致的灵活性。因此, 为不同的出行目的提供相同金额的奖励可能无效或效率不高。

考虑到上述研究中揭示的非理性 HVs 面对奖励措施时的个体差异性出行选择模式, 奖励机制设计应当具备个体层面的适应性特征。然而, 现有文献对精细化乃至个性化奖励方案的研究仍相对匮乏, 仅有少数开创性研究对此进行了探索。Azevedo 等^[102]创新性研究提出了一种基于代币的动态奖励机制, 该机制针对不同出行选择(包括路线选择、出行方式和共享乘车等)实施差异化奖励, 并根据个体出行历史数据动态调整奖励策略。Zhu 等^[103]则开发了一个智能个性化推荐系统, 该系统通过分析用户历史出行数据和既定偏好, 在二元选择情境中生成定制化奖励方案; 当用户做出行为响应后, 系统会实时更新个人偏好模型, 从而动态优化奖励策略以最大化行为干预效果。Javaudin 等^[104]构建了一个基于社会福利最大化的个性化奖励框架, 该框架在严格预算约束条件下, 通过整合个体选择



集和偏好特征生成最优奖励方案。理论分析表明该方案具有近似最优性，大规模仿真实验进一步验证了其在促进出行方式转变和降低碳排放方面的显著效果。

2.4 智能网联环境下异质主体出行选择理论及仿真建模

为制定适应智能网联环境的 IBTDM 方案，实现对异质主体行为的有效引导与调控，有必要探究 CAVs 与 HVs 在出行选择机制差异及其相互作用关系，分析奖励策略下的交通系统均衡状态演化。

然而，鉴于当前 CAVs 尚未实现大规模部署，其运行效果受限于技术成熟度、基础设施适配性及政策环境等多重因素，在现实交通系统中直接观测异质主体行为或评估 IBTDM 方案的实施效果不仅成本高昂，且操作难度较大。在此背景下，理论建模与交通仿真成为研究异质主体系统个体选择和系统状态的重要方式。

据此，本节将分别总结已有理论建模及仿真建模方法，旨在为刻画异质交通主体间复杂行为互动及其对政策的响应机制提供建模基础，进而为智能网联环境下奖励方案的设计与优化提供理论支持与方法参考。

2.4.1 基于理论的异质主体出行选择建模

理论建模方法能够从微观行为决策层面揭示个体的出行选择及其对策略的响应规律，进而为交通系统的宏观调控提供理论支撑。

已有研究探讨了在先进交通信息系统（Advanced Traffic Information System, ATIS）策略下混合交通环境的均衡状态，这些研究基于 ATIS 框架，对异质主体的 UE 与 SO 行为进行了基础性分类，并通过逐日演化分析及非理性假设的突破，为 CAVs 与 HVs 共存环境下的异质主体建模及均衡状态研究奠定了重要理论基础。Van Vuren 等^[105]率先建立了混合交通均衡框架，将出行者区分为 ATIS 引导的合作型（SO 导向）和非合作型（UE 导向）两类。后续研究^[106]进一步细化非合作用户分类，提出 UE 用户（配备 ATIS）与随机用户均衡（Stochastic User Equilibrium, SUE）用户（未配备 ATIS）的二元划分。相比之下，Yang^[107]提出了相反的行为假设：ATIS 使用者可能表现出非合作特性，而 SUE 原则反而适用于未配备 ATIS 的出行者。该研究建立了信息不对称与出行成本之间的动态关联机制，证明信息缺失导致的成本增加将内生驱动 SUE 用户采纳 ATIS 系统，从而形成 ATIS 市场渗透率与信息效益之间的反馈循环。在此基础上，Yang 等^[108]创新性地引入价格调控机制，论证了通过优化 ATIS 服务定价可实现系统总成本最小化的控制目标。Zhou 等^[109]开发了一个面向混合 UE/SUE 流模式的逐日路径演变模型，并保证了模型的收敛性。Klein 等^[110]则从行为经济学视角切入，提出非理



性假设下的出行者出行选择框架，其中部分合作型出行者愿意接受 ATIS 推荐路径以实现社会最优配置。

而对于 CAVs 和 HVs 共存的智能网联系统中，当前学术界聚焦于均衡状态建模，并利用 CAV 可控性优化混合交通管理。Chen 等^[111]通过构建混合整数双层规划模型，优化设计了通用交通网络中的 CAV 区域，以改善整个网络效能。研究假设 CAV 在区域内遵循 SO 原则，而在区域外则保持 UE 行为。Bagloee 等^[112]假定 CAV 遵循 SO 路径选择原则，HVs 遵循 UE 路径选择原则，并考虑道路通行能力、弹性需求等约束，求解混合交通均衡状态。Zhang 等^[6]提出了一种最优比率控制方案 (Optimal Ratio Control Scheme, ORCS)，受控的 CAV 遵循 SO 策略，而 HVs 则保持 UE 行为模式。研究结果表明，在 CAV 车辆相对较少的情况下，整个交通系统可实现接近 SO 的水平。Chen 等^[8]进一步求解了实现系统最优所需的最小 CAV 控制比率。Li 等^[23]探讨了中央智能体在混合交通系统中的调控机制，其中 HVs 遵循 SUE 路径选择逻辑，而 CAVs 车队则完全由中央代理优化控制，以最小化系统总成本。研究分析了不同控制策略对混合均衡状态的影响，揭示了 CAV 渗透率如何调节系统效能与稳定性之间的关系。Wang 等^[113]提出一种多类交通分配模型，将交互中的不对称性以及 CAV 的节能性纳入成本函数考量。Guo 等^[5]构建了动态双层框架以刻画 HVs 与 CAVs 的行为及交互机制——下层模型遵循瞬时动态用户均衡 (Instantaneous Dynamic User Equilibrium, IDUE) 原则描述 HVs 的路径选择行为，上层模型则采用动态系统最优 (Dynamic System Optimal, DSO) 原则优化 CAVs 的路径决策。郝威等^[114]将 CAVs 在通信能力、时间价值等方面的特性纳入出行成本，提出了面向智能网联系统的自动驾驶专用车道部署方案。

值得注意的是，现有研究逐渐关注到 CAVs 在追求系统最优目标时可能引发的个体效用损失问题。为解决这一矛盾，学者们提出了限制效用受损的 CAVs 规模的优化策略，为平衡个体利益与系统效能提供了更具可行性的解决方案。Guo 等^[115]在非理性用户均衡 (Boundedly Rational User Equilibrium, BRUE) 假设下，创新性地提出仅对特定 CAVs 子集实施中央路径优化管理的控制方法。Amirgholy 等^[116]开发了一种面向异构交通流 (HV, AV, 及 CAV) 的最优车道管理框架，通过动态调节 CAV 编队规模，成功应用于旧金山市区走廊及核心路网的交通优化问题。此外，Chellapilla 等^[117]构建了一个多目标优化模型，在 SO 和 UE 之间寻求一种折中方案，并有效提升交通网络利用率。最后，现有研究也开始探索通过交通需求管理策略协调 CAVs 与 HVs 的效用均衡关系。Liang 等^[118]通过设计针对 HVs 的拥堵收费方案调节 HVs 的出行成本，以协调 CAVs 与 HVs 的个体效用，提升整体网络效能，然而这不可避免地面临着 HVs 用户满意度低的局限性。



Zhang 等^[119]为弥补 CAVs 的出行效用损失,提出了一种路径控制与补贴的协同优化机制,对因路径控制而遭受效用损失的出行者将提供经济补偿,但该研究仍局限于理性、静态框架,难以适应真实智能网联环境。

综上所述,现有对智能网联环境的异质主体建模主要基于理性假设,未能充分考量主体的博弈逐日演化机制;现有管控策略在解决 CAVs 效用损失问题上也表现出明显的局限性。因此,仍需进一步探索能够刻画主体行为复杂性的建模框架,以及设计更有效的优化调控策略。

2.4.2 基于仿真的异质主体出行选择建模

相较于理论建模在简化假设下难以真实刻画逐日出行选择中异质主体交互的局限,基于仿真的建模方法利用交通仿真工具,在微观和中观层面复现交通流动态及个体交互过程^[120],在刻画异质主体交通流演化过程时,具有更高的精度与现实适应性。

Hu 等^[121]开发了一个基于仿真的动态交通分配 (Simulation-based Dynamic Traffic Assignment Model, SBDTA) 框架,处理混合交通流下四类车辆(小汽车、公交车、摩托车与卡车)在四种分配规则(预设路径、UE、SO 与实时信息引导)下的出行行为。Fakhrmoosavi 等^[122]引入自适应基本图方法,刻画 CAVs 与 HVs 在空间与时间分布上的动态变化。Zhao 等^[24]分析了 CAVs 路径引导策略对城市交通网络流动性与安全性的潜在影响,其中 CAVs 与 HVs 均服从动态用户均衡 (Dynamic User Equilibrium, DUE) 原则。Mansourianfar 等^[123]提出了融合路径选择与收费控制的联合优化方案,采用 DSO 原则模拟 CAVs 行为, HVs 则依循 DUE 原则,以缓解 CAVs 在混合交通环境中的效用损失问题。然而,上述模型难以全面刻画个体层面的行为差异与非理性响应机制,限制了其在真实智能网联环境下的灵活性与适用性。

基于智能体的仿真 (Agent-Based Simulation, ABS) 通过将个体建模为具有不同属性、行为规则的智能体^[124],实现智能体的自主出行选择,为刻画个体差异提供了有力工具^[125, 126]。该方法可表征个体在独立动态出行选择及其与交通系统和其他出行者之间的复杂交互,从而生成系统层面的集体现象与演化结果,基于此,ABS 能够精确描述出行者、交通基础设施和政策干预之间的复杂关系^[127],有助于制定更高效且更具针对性的交通政策与干预措施。目前,ABS 方法已广泛应用于新交通模式引入^[128, 129]、拥堵收费政策^[130, 131]、交通信号控制^[132]等领域以探索复杂交通系统结构演化模式,有效应对个体行为差异性带来的挑战。然而,已有研究多基于理性假设或预设行为规则,忽略了非理性出行选择机制带来的系统扰动以及在非完备信息条件下 CAVs 的出行选择策略自适应机制,难以反映真



实智能网联环境下的理性及非理性行为交互机制及选择演化。因此, 仍需进一步探究非理性与理性主体共存情况下的系统演化模式, 从而有效评估奖励策略在智能网联系统的实施效能。

进一步地, 鉴于仿真方法在刻画逐日出行选择演化方面的优势, 已有研究将其嵌入优化过程, 形成仿真优化 (Simulation-Based Optimization, SBO) 框架, 可以在有限资源投入下获取系统认知, 为复杂交通系统中政策与管控策略的优化设计提供有力支持^[133]。一般而言, SBO 方法主要分为三类——直接搜索法、梯度法和元模型 (或代理模型) 法^[134]。其中, 元模型方法通过学习输入 - 输出映射关系, 在全局参数空间中构建高效的近似模型, 以替代计算代价高昂的原始仿真模型, 从而在降低计算成本的同时, 有效指导参数优化。在全局最优解搜索中, 元模型方法表现尤为优越^[135-137], 常见建模技术包括回归样条、高斯过程回归、径向基函数 (RBF) 以及神经网络等^[137, 138]。目前, SBO 已广泛应用于拥堵收费、交通信号控制等复杂交通管理问题中^[134, 139-141], 验证了其在处理复杂交通系统优化问题中的实用性与有效性。然而, 现有研究多聚焦于理性行为假设下的问题建模, 尚难充分应对 IBTDM 方案优化中所涉及的结构性约束、非理性行为特征, 以及 CAVs 在信息不完备条件下的策略自适应问题。

综上所述, 基于仿真的异质主体出行选择建模及管控方法优化虽能有效刻画逐日行为交互和演化过程, 但在应对智能网联环境下异质主体特性, 尤其是非理性特性及 IBTDM 方案引入的特殊约束方面仍存在不足, 需进一步发展能够综合考虑理性与非理性行为机制、复杂交互关系与环境不确定性的仿真建模与优化方法体系, 以支持智能网联交通系统下奖励方案的设计优化。

2.5 综合评述

通过对现有文献的系统梳理与评述, 可对现有智能网联环境下基于奖励的交通需求管理研究现状得出以下结论:

(1) 当前面向理性 CAVs 和 HVs 的 IBTDM 方案设计难以有效协调全局约束条件和个体复杂出行选择机制的联合影响。首先, 现有 IBTDM 方案优化研究对项目财务能力的约束条件考量不足, 未能将宣传成本、市场渗透率等 IBTDM 全局参数及其相关关系纳入优化模型, 导致奖励预算分配失当、交通供需不均、项目效果评估偏差等问题。其次, 现有对个体在奖励影响下的出行选择机制研究多聚焦于静态日内出行行为, 忽视了原始出行行为和改变幅度等因素带来的实践与心理成本, 致使奖励方案在公平性和对逐日出行场景的适应性方面存在明



显不足。因此,未来研究应当从完善理性主体在奖励影响下的出行选择机制以及求解个体出行选择和全局约束联合影响下的最优奖励方案两方面开展。

(2) 针对非理性 HVs 在奖励影响下的出行选择机制研究仍存在数据支撑不足、行为演化建模缺失等局限。首先,目前世界范围内 IBTDM 的相关实证公开数据较少,且现有研究多局限于小样本、单一奖励策略下的行为分析,缺乏足够数据——尤其是长时、多维度奖励策略数据——支撑。其次,现有出行选择机制研究多采用静态分析框架,通过固定奖励方案考察出行者的即时选择行为,未能系统探究 IBTDM 项目中参与者出行选择的逐日动态演化特征——包括个体差异性出行选择模式、长时行为演化轨迹、反馈认知与偏好调整等核心维度。最后,现有研究主要关注非理性 HVs 的出行选择特征及影响因素分析,尚未建立能够有效刻画非理性 HVs 动态出行行为的预测模型。因此,未来研究应该基于长时数据,揭示奖励干预下出行行为的演化规律,构建考虑逐日动态特征的非理性 HVs 出行选择预测模型。

(3) 智能网联环境下异质主体建模及管控方案设计领域仍存在发展空间。一方面,现有理论及仿真建模仍沿用传统均衡理论分别刻画 HVs 和 CAVs 的行为特征——CAVs 出行选择根据系统最优原则, HVs 基于用户均衡原则,忽视了非理性 HVs 出行行为的随机性特征,以及非理性 CAVs 在非完备信息条件下的策略适应与学习过程。现有模型难以揭示理性及非理性主体复杂的交互机制及非理性主体的扰动传播,进而制约了面向智能网联环境的策略优化效果。另一方面,智能网联环境下的管控方案主要依赖于 CAVs 的可控性,往往以牺牲其个体出行效用为代价。尽管当前研究尝试通过限制效用受损的 CAVs 规模、探索 SO 和 UE 之间的折中方案以及采用交通需求管理策略来缓解这一矛盾,但仍难以解决由此引发的 CAVs 用户接受度不足的挑战,影响了 CAVs 拥堵缓解效能。因此,未来研究需要充分考量在智能网联环境下 HVs 和 CAVs 的出行选择机制差异和双向协作影响,结合管控方案的适用场景与约束条件,探究面向全类型主体的普惠性管控方案。



第3章 理性CAVs和HVs出发时间选择行为建模与奖励方案优化

本章针对智能网联环境中的理性 CAVs 和 HVs，聚焦其出发时间选择行为，利用瓶颈模型在刻画排队形成与消散动态演化过程方面的优势，构建行为分析框架，并通过理论推导，设计考虑 IBTDM 全局约束-个体行为选择联合影响的最优预算分配方案和时变奖励方案。具体而言，一方面，将 IBTDM 项目获取 HVs 和 CAVs 用户所需的异质宣传成本纳入预算考量，建立总奖励预算在宣传成本（获取 IBTDM 用户）与激励成本（引导用户出发时间调整）之间的优化分配机制；另一方面，量化出发时间调整与成本映射关系，提出考虑行为改变幅度的理性出发时间选择行为模型，设计激励成本、渗透率（由宣传成本决定）约束下基于行为调整幅度的奖励方案。本章提出的奖励方案可在有限预算下实现理性 CAVs 和 HVs 系统帕累托改进，建立的理性行为分析框架为后续探究非理性主体出发时间选择机制及智能网联环境下的 IBTDM 方案提供理论支撑与建模基础。

3.1 概述

3.1.1 问题背景

在智能网联环境中，IBTDM 项目通过信息反馈机制在一定程度上缓解了逐日出行选择过程中的信息不对称性。在此环境下，云控平台采用个体利益优先原则以提高 CAVs 用户满意度与依从性，并通过协同优化算法与 IBTDM 行为诱导实现系统最优。此时，存在 CAVs 具备多模态感知和信息处理能力，能够基于确定性算法整合多源信息并做出理性效用最大化选择；同时，IBTDM 的信息反馈机制也增强了原本受信息限制的 HVs 的理性选择能力。因此，在实施 IBTDM 的智能网联系统中，部分 CAVs 和 HVs 可视为理性主体，其奖励策略下的出行行为选择遵循效用最大化原则。

数学建模与优化方法能够从复杂现实系统中提取具有明确物理意义的关键变量及其作用机制，从而揭示行为本质规律。对于遵循效用最大化原则的理性 CAVs 与 HVs，其行为特征具备清晰的逻辑结构和行为准则，可通过建模方法加以刻画和量化分析。

基于此，本章在逐日出发时间选择场景下，聚焦于理性 CAVs 与 HVs，通过建立数学模型系统解析其出发时间选择机理，求解实现系统帕累托改进的最优奖



励方案,并为探究非理性行为特征及智能网联环境下 IBTDM 方案提供理论框架。

瓶颈模型能够有效建模交通排队的形成与消散过程,从而描述高峰期间的交通拥堵动态演化情况,其广泛应用于时间维度的交通拥堵研究^[142]。在时变拥堵定价领域,该模型作为主流建模工具之一,已有大量研究^[46-48, 50, 143-146]基于此模型研究了现行交通环境下面向理性主体的拥堵定价问题。此外, Bernstein^[147]进一步利用该模型,探讨了非营利性拥堵收费(即道路收费和补贴)的可行性,而 Sun 等^[18]则采用此模型对精细化 IBTDM 方案设计进行了探索性研究。尽管上述基于瓶颈模型的研究在交通需求管控策略的场景构建和方法论层面取得了突破性进展,但在应对智能网联环境出发时间选择场景下的奖励方案设计问题时,仍存在若干关键问题亟待解决:

一方面,现有研究在 IBTDM 全局资源配置方面存在不足,尤其忽视了宣传成本、渗透率等全局约束对 IBTDM 效能的潜在错位影响。IBTDM 具有非强制性,仅参与 IBTDM 的出行者可依据奖励调整出发时间,因此 IBTDM 有效性受全局约束(总预算、市场渗透率等)与个体出发时间选择机制的共同影响。IBTDM 项目不仅需要通过经济激励引导用个体调整出行行为,还需扩大市场渗透率(即提升活跃用户规模)以增强效果。为实现这一目标,IBTDM 管理部门需通过多渠道(如广告投放、社交媒体推广等)进行项目宣传,由此产生宣传成本。值得注意的是,面向 CAVs 和 HVs 的宣传方式、难度不同,其宣传成本边际效益存在显著异质性。这要求方案设计必须基于有限总预算,统筹优化激励成本(引导出发时间选择行为改变)与异质宣传成本(获取 IBTDM 用户,即提高渗透率)的动态配置^[148],从而引导 HVs、CAVs 行为趋近系统最优状态。

另一方面,现有个体出发时间选择行为模型未充分体现理性主体的出发时间选择逻辑,尤其是其在逐日动态选择过程中面临的出发时间调整考量^[149],导致出行成本评估偏差,引发奖励强度-出发时间选择预估失准。将出发时间偏移成本纳入出行成本分析框架,更契合理性主体在动态逐日出发时间选择逻辑,并有助于实现奖励机制的有效性和公平性。然而,该方法的实施仍面临核心挑战:如何权衡出发时间调整引发的偏移成本与奖励收益,以及如何建立奖励额度、原始出发时间选择、出发时间偏移量之间的动态关系。

因此,本章将采用瓶颈模型,解析理性主体的出发时间选择机制,并综合考虑全局资源配置和个体出发时间选择对奖励效能的影响,构建面向理性 CAVs 和 HVs 的奖励方案。第 3.1.2 节基于瓶颈模型探究理性出行者的出发时间选择机制;第 3.2 节求解基于总预算在激励成本和宣传成本之间的最优分配方案;第 3.3 节完善理性主体出发时间选择机制并解析理论时变最优奖励方案。3.2 和 3.3 节内容共同构成了总预算下的完整奖励策略设计框架。具体研究架构如图 3.1 所示。




图 3.1 有限预算下面向理性 CAVs 和 HVs 奖励策略设计技术路线

3.1.2 经典瓶颈模型

瓶颈模型能够描述排队形成的基本机制，广泛应用于涉及时间维度的拥堵研究，但其对排队消散过程的简化假设可能无法完全反映现实复杂性。本研究主要利用其对形成阶段的建模表征优势，动态描述高峰期间的拥堵情况。

瓶颈模型^[4]规定，每天早上 N 名出行者驾车从起点（家）出发、到达终点（工作地）上班，从家到工作地有且仅有一条路径，该路径上存在唯一的单位时间通行能力为 c 的瓶颈。如果在瓶颈处车辆到达率大于通行能力 c ，则会造成拥堵。

在出发时间选择机制方面，瓶颈模型对出行者的出行成本进行了量化，规定个人出行成本包括行驶时间成本和计划延误成本——计划延误成本反映实际到达时间早于或晚于期望时间所带来的多维损失，包括经济成本（如停车费用、工资损失）、心理成本以及时间机会成本（如等待时间、工作效率损失）等。具体而言， t 时刻从起点出发的出行者的个人出行成本 $\phi(t)$ 为：

$$\phi(t) = \alpha T(t) + \beta \max\{t^* - [t + T(t)], 0\} + \gamma \max\{[t + T(t)] - t^*, 0\} \quad (3.1)$$

其中， $T(t)$ 为 t 时刻出发的出行者的行驶时间（假设自由流行驶时间为0，则行驶时间为瓶颈拥堵排队时间）， t^* 为期望到达时间，通常为上班时间； α 为单位行驶时间成本； β 为早到单位时间成本； γ 为晚到单位时间成本。上述 α, β, γ 的取值参考 Small 提出的关系^[150]，即 $\gamma > \alpha > \beta$ 。

在瓶颈模型中，基于理性行为假设，每个出行者都会权衡其出发时间，从而最小化个人出行成本（3.1）。当没有出行者能通过单方面改变出发时间来降低其

出行成本时，系统达到均衡状态。即均衡状态下，出行者的出行成本 g 相等。

本章基于瓶颈模型，探究理性 CAVs 和 HVs 出行者的出发时间选择机制，并优化奖励方案。研究涉及的主要变量及相应含义如表 3.1 所示。

表 3.1 模型变量以及相应含义

符号	含义
N	总出行需求
c	路段单位时间通行能力
$t_0(t)$	t 时刻从起点出发的出行者的原始出发时间
$T_0(t_0)$	原始出行模式中， t_0 时刻从起点出发的出行者的行驶时间
$T(t)$	t 时刻从起点出发的出行者的行驶时间
$Z(t)$	t 时刻从起点出发的出行者到达目的地的时间
$D(t)$	t 时刻从起点出发的车辆瞬时出发率，简称出发率
$C(t)$	t 时刻从起点出发的出行者的出发时间偏移量
α	单位行驶时间成本
β	早到单位时间成本
γ	晚到单位时间成本
θ	单位出发时间偏移成本
δ	用于简化公式的参数， $\delta \stackrel{def}{=} \beta\gamma / (\beta + \gamma)$
Γ	系统总行驶时间
Γ_1	HVs 系统总行驶时间
Γ_2	CAVs 系统总行驶时间
p	渗透率
p^*	最优渗透率
p_1	HVs 渗透率
p_2	CAVs 渗透率
$\phi(t)$	t 时刻从起点出发的出行者的出行成本
$\kappa(t)$	t 时刻从起点出发的出行者的计划延误成本
$G(t)$	t 时刻从起点出发的出行者的广义出行成本
g	均衡状态下的出行成本
g^*	系统最优状态下的均衡出行成本
$J(t)$	t 时刻从起点出发的出行者获得的奖励
B	总奖励预算
P	宣传成本
P_1	HVs 宣传成本
P_2	CAVs 宣传成本
M	激励成本
M^*	达到 SO 状态所需的最小激励成本预算
M^{p^*}	渗透率为 p 的情况下最优激励成本预算
t^*	期望到达时间
t^l	奖励停止($\theta < \alpha$)或开始($\theta > \alpha$)实施的时刻
t^r	奖励开始($\theta < \alpha$)或结束($\theta > \alpha$)实施的时刻
t_1	第一位出行者从起点的出发时间
t_N	最后一位出行者从起点的出发时间

3.2 奖励预算配置方案优化

IBTDM 与拥堵收费的本质区别在于经济流向方向的不同：前者由管理者向出行者支付奖励，后者则由出行者向管理者缴纳费用，因此 IBTDM 方案设计需在预算约束下开展。此外，与依托道路收费设施、具备强制执行力的收费政策不同，IBTDM 项目通过移动应用程序或自动驾驶终端实施，采用自愿参与模式，其市场渗透率受奖励机制、宣传力度等因素制约，往往低于 100%。鉴于 IBTDM 项目仅能通过奖励机制影响项目用户的出发时间选择，市场渗透率成为决定策略有效性的关键因素。

基于此，在有限预算下，除了通过激励成本引导 IBTDM 用户改变出发时间外，奖励项目还需通过扩大市场渗透率（即吸引更多活跃用户）来最大化其效果。为实现这一目标，IBTDM 管理部门需要通过多种渠道（如广告、社交媒体活动赞助等）推广其项目，从而产生必要的宣传成本。

因而，为充分发挥有限奖励预算的效果、确保项目的长期可持续性，IBTDM 管理部门必须优化资源配置策略，在激励成本与宣传支出之间寻求最优平衡，以实现整体效益最大化^[148]。假设渗透率 p 为所有理性出行者中通过宣传成本得到的知晓并参与 IBTDM 项目的比例，据此可将理性出行者【下文称为出行者】分为参与者和非参与者，即 IBTDM 项目有 Np 个用户参与。

3.2.1 同质单位宣传成本下的预算分配

研究采用瓶颈模型，将宣传成本纳入奖励预算分配中，以总行驶时间最小化为目标函数，构建组合优化模型，从而求解奖励预算分配方案。

首先，需明确在瓶颈模型中，激励成本对于出发时间选择机制的影响。假设施加奖励方案 $J(t)$ ，那么 t 时刻从起点出发的出行者的广义出行成本 $G(t)$ 将等于出行者的出行成本减去奖励，可表示为：

$$G(t) = \phi(t) - J(t) \quad (3.2)$$

奖励方案中任意时刻的金额需满足非负约束，即 $J(t) \geq 0$ 。因此，出行者最小化其出行成本 $G(t)$ 的出发时间选择，较无奖励时发生变化，进而影响系统均衡状态。根据激励成本的定义，可以得到激励成本 M 与奖励方案的关系如下：

$$M = \int_{t_1}^t D(u)J(u)du \quad (3.3)$$

其中 $D(t)$ 为 t 时刻的出发率， t_1 为第一位出行者从起点的出发时间。

在此基础上，研究构建激励成本和宣传成本分配优化模型如下：

$$\min TSTT = f(M, p) \quad (3.4)$$

$$s.t. P + M = B \quad (3.5)$$

$$kNp = P \quad (3.6)$$

该最优预算分配问题的目标是最小化系统总行驶时间 $TSTT$ ，其定义为所有出行者的行驶时间总和。鉴于激励成本将直接调控出行者出行选择，而渗透率将影响可调控的出行者规模，奖励实施后系统总行驶时间主要取决于激励成本预算和渗透率，因此目标函数为 (3.4)。约束条件 (3.5) 表明总预算 B 是激励成本 M 和宣传预算 P 的总和。假设渗透率 p 与宣传成本之间存在线性关系，得到约束条件 (3.6)。 k 为单位推广宣传成本，即额外获得一位参与者需要付出的成本。

为了求解上述模型，研究首先需要确定目标函数的具体形式，即 $TSTT$ 和激励成本 M 、渗透率 p 的关系。奖励预算根据足以和不足以消除所有参与者的排队延误，分为充足和不充足两类情况。直观地说，对于渗透率 p ，存在一个临界激励成本 M^{p*} ，如果激励成本为 M^{p*} ，则参与者的总排队延迟可以降为零。接下来分别计算两种情况下的 $TSTT$ 。

1) 情况一：预算充足

当预算充足时，即 $M > M^{p*}$ ，此时激励成本能够覆盖所有参与者，最优奖励方案由渗透率 p 所限制，基于系统总行驶时间最小化逻辑^[18]，得到的具体形式为：

$$J(t) = \begin{cases} -\beta t + \beta t^l, & t \in [t_1, t^l] \\ 0, & t \in [t^l, t^r] \\ \gamma t - \gamma t^l, & t \in [t^l, t_N] \end{cases} \quad (3.7)$$

其中， t^l 和 t^r 分别为排队开始和结束时间， t_N 为第 N 名出行者的出发时间。令 $t_1 = 0$ ，则 $t^l = \gamma Np / [c(\beta + \gamma)]$ ， $t^r = N/c - \beta Np / [c(\beta + \gamma)]$ ， $t_N = N/c$ 。

此时，出发率可基于瓶颈模型，相应计算为：

$$D(t) = \begin{cases} c & t \in [0, t^l] \cup [t^r, N/c] \\ \alpha c / (\alpha - \beta) & t \in (t^l, t^r) \\ \alpha c / (\alpha + \gamma) & t \in [t^l, t^r] \end{cases} \quad (3.8)$$

根据激励成本定义 (3.3) 可以计算得到，在渗透率为 p 的情况下实施最优时变奖励方案所需的最小激励成本 M^{p*} 为：

$$M^{p*} = \delta N^2 p^2 / (2c) \quad (3.9)$$

其中为简化等式规定 $\delta \stackrel{def}{=} \beta\gamma / (\beta + \gamma)$ 。

根据定义， $TSTT$ 可以表示为：

$$TSTT = \int_0^{N/c} D(u)T(u)du \quad (3.10)$$

当预算充足且市场渗透为 p 时，相对应的系统总行驶时间可以计算得到：

$$TSTT = \delta (N - Np)^2 / (2\alpha c) \quad (3.11)$$

2) 情况二：预算不充足

当预算不足的情况下,即 $0 \leq M < M^*$, 此时激励成本不能覆盖所有参与者, 而是和不考虑渗透率时, 有限预算的奖励方案一致, 即奖励方案的具体形式为:

$$J(t) = \begin{cases} -\beta t + \beta t^l, & t \in [t_1, t^l] \\ 0, & t \in [t^l, t^r] \\ \gamma t - \gamma t^r, & t \in [t^r, t_N] \end{cases} \quad (3.12)$$

其中, t^l 和 t^r 为排队开始和结束时间。令 $t_1 = 0$, 则 $t^l = \sqrt{2\gamma M / [c\beta(\beta + \gamma)]}$, $t^r = N / c - \sqrt{2\beta M / [c\gamma(\beta + \gamma)]}$ 。

根据奖励实施时间段, 可以计算得到在此预算下, 奖励所能覆盖的渗透率为:

$$p^* = \sqrt{2cM / (\delta N^2)} \quad (3.13)$$

则根据 $TSTT$ 的定义 (3.10), 当预算不充足时, 相对应的系统总行驶时间可以表示为:

$$TSTT = M - N\sqrt{2\delta M / c} + \delta N^2 / (2c) \quad (3.14)$$

根据 (3.11) 和 (3.14) 可以获得关于 M 和 p 的 $TSTT$ 的目标函数, 表示为:

$$\min TSTT = \begin{cases} \delta(N - \sqrt{2cM / \delta})^2 / [2ac], & M < \frac{\delta N^2 p^2}{2c} \\ \delta(N - Np)^2 / [2ac], & M \geq \frac{\delta N^2 p^2}{2c} \end{cases} \quad (3.15)$$

求解模型可得初步结果:

$$p = (\sqrt{k^2 + 2AB} - k) / A \quad (3.16)$$

其中参数 $A = \beta\gamma N^2 / [c(\beta + \gamma)]$, 与渗透率为 100% 时的最优预算相同。此时, $M = \beta\gamma N^2 p^2 / [2c(\beta + \gamma)]$, $P = kp$ 。研究假设 $\alpha = 1, \beta = 0.5, \gamma = 2, c = 20, N = 1000$, 求解了考虑宣传成本时的最优奖励预算分配方案和系统总行驶时间, 结果如图 3.2 所示:




图 3.2 考虑宣传成本时的最优奖励预算分配方案与系统总行驶时间, k 为单位宣传成本



由研究可知,若不考虑宣传成本,则奖励方案的效果(系统总行驶时间减少量)会被高估,进而引发项目运营风险。通过将宣传成本纳入优化框架,可显著提升奖励方案设计的精确性。进一步分析发现,宣传成本投入与系统效益存在此消彼长的关系:随着宣传成本支出的增加,系统总行驶时间的改善幅度呈现递减趋势。

3.2.2 CAVs 和 HVs 异质单位宣传成本下的预算分配

IBTDM 管理部门通过开展营销和宣传活动来吸引用户参与项目。在智能网联环境中,针对 CAVs 和 HVs,其宣传方式的选择和实施难度存在显著差异——HVs 主要通过智能手机等移动终端参与项目,而 CAVs 作为新型智能终端,依托车路协同系统实现与出行行为的深度整合,形成更高效的 IBTDM 推广机制,因而其单位宣传成本通常低于 HVs。此外,CAVs 和 HVs 对宣传活动和奖励项目的响应积极性各不相同,导致宣传效果也存在明显区别。

因此,IBTDM 项目管理部门需要在异质单位宣传成本的约束下,优化奖励预算的分配策略,以最大化宣传成本的效果,从而提升奖励项目的整体实施效果。本节将进一步探讨在不同宣传成本条件下,针对用户群体的最优预算分配方案。

研究采用单位行驶时间成本量化 CAVs 和 HVs 主体的出行意愿及其对奖励项目的响应积极性。假设存在两组出行者(第 1 组为 HVs,第 2 组为 CAVs),其单位行驶时间成本分别为 $\alpha_1 > \alpha_2$,则可将该问题表述为一个非线性规划问题,并建立如下模型:

$$\min TSTT = f(M, p_1, p_2) \quad (3.17)$$

$$s.t. P_1 + P_2 + M = B \quad (3.18)$$

$$k_1 N_1 p_1 = P_1 \quad (3.19)$$

$$k_2 N_2 p_2 = P_2 \quad (3.20)$$

其中 p_1, p_2 为 HVs 和 CAVs 的渗透率, P_1, P_2 为 HVs 和 CAVs 的宣传成本, k_1, k_2 为 HVs 和 CAVs 的单位宣传成本,即额外获取一位 HVs 参与者和 CAVs 参与者所需要的成本。

在本研究中,参与者由宣传成本获取。在最优分配方案中,激励成本的设置应当精确匹配消除参与者排队所需的临界值。这一均衡条件的必要性在于:当激励成本超过或低于该临界值时,将分别导致两种无效率情形:其一,激励资源的冗余配置未能有效缓解排队拥堵,从而降低激励效能;其二,宣传成本的投入因激励不足而无法实现预期效果。

基于此, 后续分析将着重关注能够完全消除参与者排队的最优激励成本临界点及此时的 $TSTT$ 。具体而言, 接下来将计算给定 p_1, p_2 时, 临界奖励预算 $M^{h\&p^*}$ 和相应的 $TSTT$ 。

1) 临界激励成本 $M^{h\&p^*}$

当两组出行者具有不同的单位行驶时间成本且市场渗透率为 100% 时, 两组出行者不会同时出发。此时, 为了最小化系统总行驶时间 ($TSTT$), 单位行驶时间成本较高的出行者的出行成本应尽可能减少, 这意味着奖励措施应优先用于消除第 1 组出行者 (HV) 的排队现象^[18]。

在此基础上, 在市场渗透率低于 100% 的情况下, 奖励措施也应优先激励 HVs。因此, 在求解最优奖励预算 $M^{h\&p^*}$ 之前, 首先需要确定消除 HVs 参与者排队现象的关键奖励阈值 $M^{p_1^*}$ 。当奖励预算 $M \leq M^{p_1^*}$ 时, 所有奖励预算资源应集中用于消除 HVs 所有参与者的排队现象。根据公式 (3.9), 可以得出以下结论:

$$M^{p_1^*} = \delta N_1^2 p_1^2 / (2c) \quad (3.21)$$

接下来, 需要进一步确定当奖励预算 $M > M^{p_1^*}$ 时的最优奖励方案, 并求解能够消除两组参与者排队延迟的临界奖励预算阈值 $M^{h\&p^*}$ 。

当 $M > M^{p_1^*}$ 时, 存在一个无效奖励预算 φ^{p_1} , 该预算表示在每个参与者身上分配的额外奖励, 在此范围内, 奖励预算的增加不会对系统总行驶时间 $TSTT$ 产生进一步的减少效果。具体而言, φ^{p_1} 的计算公式如下:

$$\varphi^{p_1} = (\alpha_1 - \alpha_2) \delta (N_1 - N_1 p_1) / (\alpha_1 c) \quad (3.22)$$

当 $M > M^{p_1^*}$ 时, 在 N_1, p_1, N_2, p_2 固定的情况下, 总无效奖励预算为 $(N_1 p_1 + N_2 p_2) \varphi^{p_1}$ 。基于公式 (3.9), 并考虑 φ^{p_1} 的影响, 最优状态下预算阈值可表示为:

$$M^{h\&p^*} = \delta N_1^2 p_1^2 / (2c) + (N_1 p_1 + N_2 p_2) \varphi^{p_1} \quad (3.23)$$

鉴于约束 (3.18), 总预算由 $M^{h\&p^*}, p_1, p_2$ 组成, 此时, 预算可进一步简化为:

$$B = C p_1^2 + D p_2^2 + E p_1 p_2 + F p_1 + G p_2 \quad (3.24)$$

其中 C, D, E, F, G 是与 $\beta, \gamma, c, \alpha_1, \alpha_2, N_1, N_2, k_1, k_2$ 有关的常数。

2) 最优 $TSTT$

当奖励预算 $M > M^{h\&p^*}$ 时, 应计算相应的最优 $TSTT$ 。对于两组出行者, 假定 Γ_1 为 HVs 的总行驶时间, Γ_2 为 CAVs 的总行驶时间, 则系统总行驶时间可表示为 $TSTT = \Gamma_1 + \Gamma_2$ 。

当 $M > M^{h\&p^*}$ 时, HVs 和 CAVs 参与者的排队延迟时间均为零。在此情况下, HVs 的行为与同质出行者相似, 而 CAVs 则受到 HVs 排队的影响。基于此, 根据公式 (3.15), 当 $M > M^{h\&p^*}$ 时, 可以得到以下关系:

$$\Gamma_1 = \delta (N_1 - N_1 p_1)^2 / (2\alpha_1 c) \quad (3.25)$$

$$\Gamma_2 = \delta(N_2 - N_2 p_2)^2 / (2\alpha_2 c) + \delta(N_1 - N_1 p_1)(N_2 - N_2 p_2) / (\alpha_1 c) \quad (3.26)$$

因此，系统总行驶时间可通过以下公式计算：

$$\begin{aligned} \Gamma = & \delta(N_1 - N_1 p_1)^2 / (2\alpha_1 c) + \delta(N_2 - N_2 p_2)^2 / (2\alpha_2 c) \\ & + \delta(N_1 - N_1 p_1)(N_2 - N_2 p_2) / (\alpha_1 c) \end{aligned} \quad (3.27)$$

公式 (3.27) 可进一步简化为：

$$\Gamma = bp_1^2 + dp_2^2 + ep_1 p_2 + fp_1 + gp_2 + h \quad (3.28)$$

其中 b, d, e, f, g, h 是与 $\beta, \gamma, c, \alpha_1, \alpha_2, N_1, N_2, k_1, k_2$ 有关的常数。

图 3.3 显示了不同渗透率条件下的最优奖励方案以及队列长度。当奖励预算充足时，两组出行者的排队延误时间都会减少，这是因为奖励措施成功引导参与者转向非高峰时段出行。这表明，在奖励措施的作用下，两组出行者的出行体验均得到了改善。然而，HV 的排队延误时间减少幅度更为显著，表明其受益更为明显。在预算有限的情况下，奖励资源应优先用于消除 HV 的排队时间，这进一步说明 HV 在奖励方案中获得了更大的收益。




图 3.3 考虑渗透率时的奖励方案与系统排队时间示意图

根据上述计算结果，可以将模型转化为：

$$\begin{aligned} \min \Gamma = & bp_1^2 + dp_2^2 + ep_1 p_2 + fp_1 + gp_2 + h \\ \text{s.t. } B = & Cp_1^2 + Dp_2^2 + Ep_1 p_2 + Fp_1 + Gp_2 \end{aligned} \quad (3.29)$$

其中 C, D, E, F, G 是与 $\beta, \gamma, c, \alpha_1, \alpha_2, N_1, N_2, k_1, k_2$ 有关的常数。

假设 $\beta = 0.5, \gamma = 2, c = 20, \alpha_1 = 1, \alpha_2 = 0.8, N_1 = 500, N_2 = 500$ ，图 3.4 展示了不同 k_1, k_2 时，两组出行者情况下的最优渗透率和预算分配。由图 3.4 (a) 和 (b) 可得，当 $k_1 = k_2 = 40$ 时，IBTDM 管理部门应该首先提高具有较低单位出行成本



25548202

的人群——即CAVs的渗透率到83%；如果 k_2 增加到42，而 k_1 保持不变，IBTDM管理部门应该将 p_2 增加到61%左右，然后开始吸引HVs人群，如图3.4(c)和(d)所示；若 k_1 相对低于 k_2 ，则IBTDM管理部门应首先吸引HVs，如图3.4(e)和(f)所示。




图 3.4 考虑宣传成本时的最优奖励方案与渗透率，(a) 和 (b): $k_1=40, k_2=40$; (c), (d): $k_1=40, k_2=42$; (e), (f): $k_1=20, k_2=40$

根据图 3.4，宣传成本可能改变 IBTDM 管理部门提高异质用户群体渗透率的顺序，且最终顺序与 k_1 、 k_2 的值有关。因此，为了进一步分析 k_1, k_2 对最优预算分配的影响，假设 $\beta = 0.5, \gamma = 2, c = 20, \alpha_1 = 1, \alpha_2 = 0.8, N_1 = 2,000, N_2 = 1,000$ ，固定 $k_1 = 10$ 而改变 k_2 的大小，得到最优渗透率 p_1, p_2 和 k_1, k_2 的关系如图 3.5 所示。




图 3.5 考虑市场宣传成本时的最优渗透率

由图 3.5 可得以下四个主要结论：

首先，当预算较小时，最优解始终位于 x 轴或 y 轴上。这表明在预算有限的情况下，最优策略是集中资源针对单一用户群体进行宣传推广，而非同时扩展两个群体的渗透率（ p_1 和 p_2 ）。

其次，在不考虑宣传成本的情况下，随着预算的增加，最优策略通常是优先扩展 HVs 的渗透率 p_1 ，因为这能够更显著地减少系统总行驶时间（ $TSTT$ ）。然而，若考虑宣传成本，情况可能发生变化，因为吸引 HVs 的宣传成本可能较高，从而降低其投入的回报率。如图 3.5 所示，在极端情况下（ $k_1 = 10$ 且 $k_2 = 0$ ），当预算较小时，最优策略是优先扩展 p_2 直至 $p_2 = 1$ ，随后保持 $p_2 = 1$ ，增加 p_1 直至 $p_1 = 76\%$ （即转折点，图中 A1 点）。转折点之后，最优解形成一条曲线，具体分析将在后续讨论中展开。随着 k_2 的增大，转折点逐渐下降。例如，当 $k_2 = 6$ 时，转折点降至 $p_1 = 0, p_2 = 1$ ，而当 $k_2 = 13$ 时，转折点进一步降至 $p_1 = 0, p_2 = 0$ 。这表明，在预算有限的情况下， $k_1 = 10, k_2 = 13$ 是决定 IBTDM 管理部门是否吸引 CAVs 和 HVs 用户的关键阈值。

第三，在 k_2 固定的情况下， (p_1, p_2) 的最优解并未严格随预算 B 的增加而单调向右上角移动。以 $k_2 = 2$ 为例，当 $B = 60,000$ 元时， (p_1, p_2) 的最优解为 A2 点



(50%,100%), 而当 $B=68,600$ 元时, 最优解转移至 A3 点 (62%,95%)。这一现象的原因在于, 尽管 k_2 相对较小 ($=2$), 但当达到 A2 点 ($p_2=1$) 时, 进一步降低 $TSTT$ 需要对 CAVs 用户施加较大的边际投入。此时, 尽管 k_1 较大, 但 p_1 仍相对较低 ($=50\%$), 因此将预算用于激励 HVs 用户在非高峰时段出行的效果优于继续激励 CAVs 用户。类似地, 以 $k_2=9$ 为例, 当 $B=12,500$ 元时, 最优解为 A4 点 (0,55%), 而当 $B=15,000$ 元时, 最优解转移至 A5 点 (10%,45%)。此外, 当 k_2 接近 k_1 时, 转折点 (如 A4 点) 出现在预算 B 较小时。这表明, IBTDM 管理部门需准确估算预算以确定最优预算分配方案。若预算被低估, 可能导致无法达到与真实预算对应的最优渗透率方案。

最后, 如图 3.5 所示, 在相同预算 B 下, 不同的 (k_1, k_2) 组合对应不同的最优预算分配方案。以 $B=40,000$ 元为例, 当 $k_1=10, k_2=5$ 时, 最优解为 A6 点 (30%,86%); 而当 $k_1=10, k_2=8$ 时, 最优解为 A7 点 (54%,36%)。这表明, 若对 (k_1, k_2) 的估计存在偏差, 最优渗透率方案将偏离实际最优情况。由于 A6 和 A7 之间不存在支配关系, 且降低渗透率同样需要成本, 因此无法在两者之间自由转换。因此, IBTDM 管理部门应精确估算宣传成本, 以确保预算分配的最优化。

综上所述, 奖励策略应该首先吸引宣传成本较低的用户。此外, 最优渗透率不会相对于总预算严格提高, 因此 IBTDM 项目需要准确估算总预算以及每人的宣传成本, 以确定最优奖励预算分配策略。

3.3 个体动态出发时间选择机制与奖励方案优化

在得到总奖励预算下宣传成本和激励成本的最优分配方案后, 需要进一步确定如何基于激励成本、渗透率等全局约束来设计考虑个体动态出发时间选择机制的最优奖励方案, 以引导理性出行者改变其出发时间, 从而最大程度发挥激励成本缓解系统拥堵的作用。

在逐日出发时间选择场景中, IBTDM 的实施促使理性出行者对其原始出发时间进行调整, 而任何偏离均衡出发时间的选择均会产生相应的偏移成本。该出发时间偏移成本由原始出发时间和调整后的出发时间共同决定。因此, 理性出行者在进行出发时间选择时, 需在行为调整带来的奖励收益与偏移成本之间权衡。

为构建更符合理性出行者【下文称为出行者, 不再单独强调理性】逻辑的出发时间选择机制并以此优化奖励方案, 本节基于瓶颈模型, 考虑个体原始出发时间的异质性特征, 将出发时间偏移量纳入出行成本的分析框架中。在综合考虑激励成本约束和市场渗透率等条件下, 求解激励成本下的最优奖励分配方案, 提出一种更贴近理性 CAVs 和 HVs, 即理性出行者动态逐日出发时间选择思维的新型



奖励机制，从而最大程度发挥奖励在减少高峰期拥堵的作用。

3.3.1 基于出发时间偏移量的个体出发时间选择机制

为了阐明出行者的出发时间偏移量对其出发时间选择以及奖励方案的影响，基于瓶颈模型的出行成本量化公式 (3.1)，研究进一步将出行者出发时间偏移成本纳入考虑范畴，更新了出行者出行成本定义，即：

$$\phi(t) = \alpha T(t) + \beta \max\{t^* - [t + T(t)], 0\} + \gamma \max\{[t + T(t)] - t^*, 0\} + \theta C(t) - J(t) \quad (3.30)$$

其中， θ 为出行者单位出发时间偏移成本， $C(t)$ 为在 t 时刻从起点出发的出行者较原始状态的出发时间偏移量。在原始状态时，出发时间偏移量 $C(t)$ 为 0。

瓶颈模型中的系统最优状态为没有排队发生的状态，出行者在整个高峰期内出发率应等于瓶颈处的单位时间通行能力，即 $D(t) = c$ ，此时 $T(t) = 0$ 。假设系统最优状态时出行者的出行成本为 g^* ，则此时奖励方案可表示为：

$$J(t) = \kappa(t) + \theta C(t) - g^* \quad (3.31)$$

其中， $\kappa(t)$ 为在 t 时刻从起点出发的出行者所面临的计划延误成本，其大小取决于用户的到达时间，根据定义可以得到 $\kappa(t)$ ：

$$\kappa(t) = \begin{cases} \beta \left\{ t^* - \int_{t_1}^t D(u) du / c - t_1 \right\} & t \in [t_1, t'] \\ \gamma \left\{ t_1 + \int_{t_1}^t D(u) du / c - t^* \right\} & t \in [t', t_N] \end{cases} \quad (3.32)$$

系统最优状态下的奖励方案如图 3.6 所示，出行者获得奖励的多少与其出发时间和出发时间偏移量有关。然而，若 IBTDM 管理部门盲目采取该奖励方案，则可能无法控制所需总预算，极易导致预算超支甚至公司破产。因此，为了把控所需预算额度、便于奖励方案落地实施，需要明确出行者的固定出发时间偏移模式，即出行者的“出发时间”和“出发时间偏移量”的关系，从而可以准确计算出出行者的奖励金额以及相应的总奖励预算。在固定出发时间偏移模式下，出行者不再在高峰时段内自由选择、组合其出发时间和出发时间偏移量，而必须基于其初始出发时间，调整现出发时间到要求时刻，方可获得奖励。在如图 3.6 曲面所示的一般性的奖励方案中，存在某出发时间偏移模式，使系统达到 SO 状态所需要的预算最小，具有该模式的奖励方案即为最优奖励方案，假设如图 3.6 中黑色实线所示，此时所需要的最小预算为 M^* 。最优奖励方案和公式 (3.31) 所表示的一般性的奖励方案之间的关系如图 3.6 中黑色实线和曲面所示。




图 3.6 系统最优状态下的奖励方案示意图

根据预算的定义，奖励方案 $J(t)$ 实施所需的激励成本 M 可以表示为：

$$M = \int_{t_1}^{t_N} D(u)J(u)du \quad (3.33)$$

将公式 (3.31) 代入公式 (3.33)，可以计算得到系统最优状态下所需的激励成本：

$$M = \int_{t_1}^{t_N} c\kappa(u)du + \int_{t_1}^{t_N} c\theta C(u)du - Ng^* \quad (3.34)$$

在系统最优状态中，由于 $D(t) = c$ ，系统总延误成本固定。因此，根据公式 (3.34)，为了计算达到 SO 状态下所需要最小激励成本 M^* ，需要寻找使得系统总出发时间偏移量最小的方案。

系统最优状态下，出行者的出发模式将从图 3.12 中的直线和方形组合的实线转变为实线。此时，存在两种出发时间偏移模式，模式一为全部出行者向后调整出发时间；模式二为部分出行者向前调整出发时间，其余出行者向后调整。

在模式一中，所有出行者向后调整其出发时间。较为典型的偏移模式为出行者在无奖励策略下和在奖励策略下的到达目的地的时间相同。假设 t 时刻从起点出发的出行者的到达时间为 $Z(t)$ ，即有：

$$Z(t) = t + T(t) = t_0(t) + T_0[t_0(t)] \quad (3.35)$$

其中， $t_0(t)$ ， $T_0[t_0(t)]$ 分别为 t 时刻从起点出发的出行者的原始出发时间，和原始出行状态中所经历的排队时间。在此模式中，出行者的出发时间偏移量为原始状态下的排队时间，出行者的出行顺序在无奖励和有奖励时相同，典型模型的出行示意图如图 3.7 所示。图 3.7 中 $A_{10}, A_{20}, A_{30}, A_{40}, A_{50}$ 为没有奖励时出行者的原始出发时间， $A_{1J}, A_{2J}, A_{3J}, A_{4J}, A_{5J}$ 为有奖励时出行者调整后的出发时间。




图 3.7 出发时间偏移“典型”模式

除了上述“典型”模式外，出发时间偏移的“向后调整”模式还包括奖励实施前后出行者改变到达时间或出行顺序的情况。在“向后调整”模式中，可能存在两名、三名、四名乃至 N 名出行者的出发顺序互换。在此，为了分析出行者的总出发时间偏移量与典型模式的相对大小，研究将其简化为两名出行者出发顺序互换的情况，例如图 3.8 所示。图中 A_{10}, A_{20} 为没有奖励时出行者的原始出发时间， A_{1J}, A_{2J} 为有奖励时出行者调整后的出发时间。三名、四名乃至 N 名行者互换出发顺序的情况更加复杂，但互换前后总出发时间偏移量的相对大小比较与两名出行者互换的情况相似。




图 3.8 出发时间偏移“向后调整”模式

在模式一中，若存在一名出行者的出发时间从 A_{20} 向后调整到 A_{2J} ，则至少存在另一名出行者调整其出发时间从 A_{10} 至 A_{1J} 以维持均衡状态。假设其余出行者的出行顺序不变，由图 3.8 可知，与“典型”模式相比， $C_1 + C_2 = C_{10} + C_{20}$ ，即“向后调整”模式下，是否保证出行者的到达时间不变不会影响总出发时间偏移量的大小。

在模式二中，部分出行者向后调整，其余出行者向前调整出发时间。相应地，



25548202

出行者可划分为三类：向前调整出发时间的 I 类出行者、受 I 类出行者影响的向后调整出发时间的 II 类出行者，以及不受影响的向后调整出发时间的 III 类出行者。与模式一类似，模式二中可能存在两名、三名、四名乃至 N 名的 I 类和 II 类出行者。为了简化计算过程，研究在此讨论一名 I 类和一名 II 类出行者的情况，如图 3.9 所示。 A_{10}, A_{20}, A_{30} 为没有奖励时出行者的原始出发时间， A_{1J}, A_{2J}, A_{3J} 为有奖励时出行者的调整后的出发时间。




图 3.9 出发时间偏移“部分人向后调整，其他人向前调整”模式

在图中，I 类出行者将出发时间从 A_{10} 调整至 A_{1J} ，II 类出行者将出发时间从 A_{20} 调整至 A_{2J} 。显然， $C_1 + C_2 > C_{10} + C_{20}$ ，因此，任意出行者向前调整出发时间将导致总出发时间偏移量增加。

综上所述，模式一的总出发时间偏移量相同，且小于模式二；因此达成出发时间调整模式一所需的预算更少。而模式一中包含的“典型”模式，实施奖励前后出行者的到达时间不变，且个人的出发时间偏移量即为原始状态下的排队时间，此模式可以最小程度减少出发时间偏移给出行者带来的影响，且易于出行者理解奖励方案，实施难度较小，故而具有较小的用户层面的阻力。因此，研究希望用户的出发时间偏移模式为“典型”模式，即图 3.7 所示模式，并基于此模式计算奖励方案。

根据瓶颈模型中对于行驶时间的定义（当自由流时间为零时， t 时刻的行驶时间可表示为该时刻瓶颈处排队长度与通行能力的比值），可以计算得到 $T_0(t_0)$ ：

$$T_0(t_0) = \begin{cases} \beta t_0 / (\alpha - \beta) & t_0 \in [t_1, t'] \\ \gamma(N/c - t_0) / (\alpha + \gamma) & t_0 \in (t', t_N] \end{cases} \quad (3.36)$$

在系统最优状态下的“典型”模式中，需满足如下条件：

$$C(t) = T_0[t_0(t)] \quad (3.37)$$

则 $t_0(t)$ 与 t 的关系为：

$$t_0(t) = \begin{cases} (\alpha - \beta)t / \alpha & t \in [t_1, t^*] \\ (\alpha + \gamma)t / \alpha - \gamma N / (\alpha c) & t \in (t^*, t_N] \end{cases} \quad (3.38)$$

将 (3.38) 代入 (3.36) 中, 计算得到系统最优状态下的出行者出发时间偏移量如下:

$$C(t) = \begin{cases} \beta t / \alpha & t \in [t_1, t^*] \\ -\gamma t / \alpha + \gamma N / (\alpha c) & t \in (t^*, t_N] \end{cases} \quad (3.39)$$

综合计划延误成本和该系统最优状态下的出行者出发时间偏移模式, 可得到基于出发时间偏移量的广义出行成本, 从而基于广义出行成本最小化原则, 明确基于出发时间偏移量的个体出行选择机制。在该选择机制下, 其出行选择受到奖励方案的影响, 因此, 研究进一步探究基于出发时间偏移量的奖励方案。

3.3.2 基于出发时间偏移量的奖励方案

3.3.3.1 无预算约束的奖励方案

基于求解得到的系统最优状态下的出行者出发时间偏移模式 (3.39), 可得到达到 SO 状态下所需的最优时变奖励方案:

$$J(t) = \begin{cases} -(\alpha - \theta)\beta t / \alpha + \beta t^* - g^* & t \in [t_1, t^*] \\ (\alpha - \theta)\gamma(t - t^*) / \alpha + \theta\beta t^* / \alpha - g^* & t \in [t^*, t_N] \end{cases} \quad (3.40)$$

$J(t)$ 中的常数项数值需要保证奖励的非负性, 则当 $\theta < \alpha$ 时, 需要满足:

$$g^* \leq \theta\beta t^* / \alpha \quad (3.41)$$

假设 $g_0 = \theta\beta t^* / \alpha$, 可得: $g^* \leq g_0$ 。当 $\theta > \alpha$ 时, 需满足:

$$g^* \leq \beta t^* \quad (3.42)$$

最优奖励方案的具体金额与单位行驶时间成本、早到/晚到单位时间成本等成本参数有关, 当成本参数的单位为元/分钟时, 最优奖励方案示意图如图 3.10 所示。其中, 为了展示奖励方案的一般形式, 图 3.10 中不涉及成本参数的具体数值, 仅为示意图。注意 $\theta = \alpha$ 时由公式 (3.40) 可得, 奖励金额恒为常数, 将在之后进行讨论。




图 3.10 最优奖励方案示意图

根据图 3.10, 最优时变奖励方案的形式与单位行驶时间成本 α 和单位出发时间偏移成本 θ 的相对大小有关。当 $\theta < \alpha$ 时, 奖励方案呈“V”型, 该奖励方案在高峰期拥堵开始和即将结束的阶段设置较高的奖励金额, 在最拥堵的阶段设置较低的奖励金额, 从而将在高峰拥堵时段中间出发的出行者推向两端, 达到“错峰填谷”的效果。而当 $\alpha < \theta$ 时, 最优奖励方案呈倒“V”型, 奖励金额在期望到达时间处达到最高, 呈线性向高峰时段两端递减。该奖励方案在出发时间偏移量较少的高峰期两端设置较小的奖励金额, 而在出发时间偏移量较大的高峰期间时段设置较多的奖励金额, 从而促进出行者调整自己的出发时间至预期状态。

当达到 SO 状态时拥堵可完全消除, 即有 $D(t)$ 恒为 c 。故基于激励成本定义, 可计算得到交通管理部门为实施能够完全消除排队的最优奖励方案所需的最小预算为:

$$M^* = |\alpha - \theta| \delta N^2 / (2c\alpha) \quad (3.43)$$

此时, 当 $\alpha > \theta$ 时, 用户的均衡出行成本为:

$$g^* = g_0 < \beta t^* \quad (3.44)$$

当 $\alpha < \theta$ 时, 用户的均衡出行成本为:

$$g^* = \beta t^* \quad (3.45)$$

当 $\alpha = \theta$ 时, 由 (3.40) 可得, $J(t)$ 始终为常数, 其大小与总预算有关, 假设总预算为 M , 则可得到 $J(t) = M / N$ 。相应地, 均衡成本为 $g^* = \beta t^* - M / N$ 。即当 $\alpha = \theta$ 时, 只要 $M > 0$, 出行者均衡状态的出行成本 g^* 即小于出行者不改变出发时间的成本 βt^* , 此时出行者倾向于改变其出发时间。因此, 考虑出发时间偏移量的奖励方案不存在预算约束。

综合上述各类情况可知, 实施奖励方案后, 出行者的均衡成本均不大于不改变出发时间的成本 βt^* , 即该奖励方案可以实现系统的帕累托改进。

3.3.3.2 预算约束下的奖励方案设计

小型出行服务公司难以提供较高总奖励预算以及相应的激励成本, 无法实施图 3.10 中所示的奖励方案。针对中小型服务公司面临的预算挑战, 研究将求解激励成本小于 M^* 的情况下的最优奖励方案, 以保证奖励方案的适应性、合理性和 IBTDM 项目的持续运营。

对于出行者整体而言, 系统总出行成本与激励成本的差值等于所有出行者的实际出行成本, 即有:

$$\int_{t_1}^{t_N} D(u) \phi(u) du - \int_{t_1}^{t_N} D(u) J(u) du = Ng \quad (3.46)$$

由等式 (3.46) 可知, 系统总出行成本取最小值等价于出行者的均衡广义出行成本取最小值, 即 g 取最小值。

在预算不充足情况下, 与预算充足情况相似, 研究仍然考虑将出行者的出发



时间调整为“典型”模式，出行者仍然保持在原始出行模式的到达时间到达目的地，此时：

$$Z(t) = t + T(t) = t_0(t) + T_0[t_0(t)] \quad (3.47)$$

根据出发时间偏移量的定义，可得 $t_0(t) + C(t) = t$ 。则相应地， $C(t) = T_0[t_0(t)] - T(t)$ 。

而与预算充足情况不同，预算不充足时，激励成本无法完全阻止排队发生，因此 $Z(t) = t$ 不再成立。则参考预算充足情况下的 $T_0[t_0(t)]$ 与 t 的关系 (3.39)，可以得到预算不充足情况下， $T_0[t_0(t)]$ 与 $Z(t)$ 的关系：

$$T_0[t_0(t)] = \begin{cases} \beta Z(t) / \alpha & t \in [t_1, t'] \\ -\gamma Z(t) / \alpha + \gamma N / (\alpha c) & t \in (t', t_N] \end{cases} \quad (3.48)$$

在预算不充足时，奖励方案 $J(t) = \phi(t) - g$ 可拆分为：

$$J(t) = \max\{\kappa(t) + \theta T_0[t_0(t)] - g, 0\} + \phi(t) - \max[\kappa(t) + \theta T_0[t_0(t)], g] \quad (3.49)$$

将拆分等式 (3.49) 代入到 (3.33) 中，即可得到激励成本 M 与出发率 $D(t)$ 之间的关系，即：

$$\begin{aligned} & \int_{t_1}^{t_N} D(u) \max\{\kappa(u) + \theta T_0[t_0(t)] - g, 0\} du \\ & + \int_{t_1}^{t_N} D(u) \{\phi(u) - \max[\kappa(u) + \theta T_0[t_0(t)] - g]\} du = M \end{aligned} \quad (3.50)$$

等式 (3.50) 可以拆分为两部分：

$$\Pi_1 = \int_{t_1}^{t_N} D(u) \max\{\kappa(u) + \theta T_0[t_0(t)] - g, 0\} du \quad (3.51)$$

$$\Pi_2 = \int_{t_1}^{t_N} D(u) \{\phi(u) - \max[\kappa(u) + \theta T_0[t_0(t)] - g]\} du \quad (3.52)$$

Π_1 ， Π_2 分别非负。其中 Π_1 随 g 增加而单调下降，故在给定激励成本 M 的情况下，当 Π_2 取最小值时 g 取最小值。因此，根据公式 (3.52)，满足如下条件， g 可取得最小值。

$$\phi(t) = \max[\kappa(t) + \theta T_0[t_0(t)] - g, 0] \quad (3.53)$$

故在给定激励成本 M 时，使得 g 取最小值，即系统总出行成本最小的最优奖励方案应满足：

$$J(t) = \max[\kappa(t) + \theta T_0[t_0(t)] - g, 0] \quad (3.54)$$

根据 $\kappa(t)$ 的定义 (3.32) 和 $T_0[t_0(t)]$ 与 $Z(t)$ 的关系 (3.48)，可知：

$$\kappa(t) + \theta T_0[t_0(t)] = \begin{cases} -(\alpha - \theta)\beta Z(t) / \alpha + \beta t^* & t \in [t_1, t'] \\ (\alpha - \theta)\gamma Z(t) / \alpha - \gamma t^* + \theta\gamma N / (\alpha c) & t \in (t', t_N] \end{cases} \quad (3.55)$$

基于瓶颈模型中的先进先出原则， $Z(t)$ 随 t 单调递增。则 $\kappa(t) + \theta T_0[t_0(t)]$ 随 t 的单调性与 α 和 θ 的相对大小有关，相应的 $J(t)$ 的形式也不相同。由 2.1 节可知，当 $\alpha = \theta$ 时，考虑出发时间偏移量的奖励方案不存在预算约束，因此本节不再进一步说明。接下来分别讨论 $\theta < \alpha$ 和 $\theta > \alpha$ 两种情况。



1) $\theta < \alpha$

由公式 (3.55) 可知, $\kappa(t) + \theta T_0[t_0(t)]$ 在定义域 $[t_1, t']$ 随 t 单调递减, 在定义域 $(t', t_N]$ 随 t 单调递增, 则存在某 $t^l \in [t_1, t']$ 和 $t^r \in (t', t_N]$, 使得:

$$\kappa(t^l) + \theta T_0[t_0(t^l)] = \kappa(t^r) + \theta T_0[t_0(t^r)] = g \quad (3.56)$$

根据 $\kappa(t) + \theta T_0[t_0(t)]$ 的单调性、奖励与 $\kappa(t) + \theta T_0[t_0(t)]$ 的关系 (3.54), 当 $t \in [t^l, t^r]$ 时, 奖励为 $J(t) = 0$ 。

当 $t \in [t_1, t^l) \cup (t^r, t_N]$ 时, 奖励为:

$$J(t) = \kappa(t) + \theta T_0[t_0(t)] - g > 0 \quad (3.57)$$

而根据出行成本的定义 (3.30) 以及出行成本与奖励的关系 (3.2), 可得奖励公式:

$$J(t) = \alpha T(t) + \kappa(t) + \theta T_0[t_0(t)] - \theta T(t) - g \quad (3.58)$$

结合 (3.57) 和 (3.58), 当 $t \in [t_1, t^l) \cup (t^r, t_N]$ 时, 需满足 $T(t) = 0$, $Z(t) = t$ 。

综上所述, 并考虑 $\kappa(t) + \theta T_0[t_0(t)]$ 与 $Z(t)$ 的关系 (3.55), 在给定激励成本 M 时, 可以求得最小化系统总行驶时间的最优奖励方案的具体表达式为:

$$J(t) = \begin{cases} -(\alpha - \theta)\beta(t - t^l) / \alpha & t \in [t_1, t^l) \\ 0 & t \in [t^l, t^r] \\ (\alpha - \theta)\gamma(t - t^r) / \alpha & t \in (t^r, t_N] \end{cases} \quad (3.59)$$

其中, t^l 和 t^r 分别为奖励结束和再次开始实施的时刻。在该奖励方案下, 系统最终达到一个新的均衡状态, 根据均衡状态下广义出行成本 $G(t) = \kappa(t) + \theta C(t) + \alpha T(t) - J(t)$ 在任意时刻相等, 广义出行成本对于 t 的一阶导数 $\dot{G}(t)$ 需满足恒为 0, 则可以计算得到在实施该奖励方案后, 相应的出发率为:

$$D(t) = \begin{cases} c & t \in [t_1, t^l) \cup [t^r, t_N] \\ \alpha c / (\alpha - \beta) & t \in [t^l, t^r] \\ \alpha c / (\alpha + \gamma) & t \in (t^r, t^r) \end{cases} \quad (3.60)$$

本文中假设 $t_1 = 0$, 根据等式 (3.33) 和 (3.60) 可以计算得到 t^l 与 t^r 的具体时刻, 即 $t^l = \sqrt{2\alpha\delta M / [c\beta^2(\alpha - \theta)]}$, $t^r = N / c - \sqrt{2\alpha\delta M / [c\gamma^2(\alpha - \theta)]}$ 。

当激励成本为 M 时, 量化系统排队情况的系统总行驶时间 Γ 可以表示为:

$$\Gamma = M / (\alpha - \theta) - N\sqrt{2\delta M / [c\alpha(\alpha - \theta)]} + \delta N^2 / (2\alpha c) \quad (3.61)$$

2) $\theta > \alpha$

$\kappa(t) + \theta T_0[t_0(t)]$ 在定义域 $[t_1, t']$ 上随 t 单调递增, 在定义域 $(t', t_N]$ 上随 t 单调递减, 则存在某 $t^l \in [t_1, t']$ 和 $t^r \in (t', t_N]$, 满足如下条件:

$$\kappa(t^s) + \theta T_0[t_0(t^s)] = \kappa(t^r) + \theta T_0[t_0(t^r)] = g \quad (3.62)$$

由公式 (3.54) 可得, 当 $t \in (t^l, t^r)$ 时, 奖励为:

$$J(t) = \kappa(t) + \theta T_0[t_0(t)] - g > 0 \quad (3.63)$$



此时, 结合 (3.63) 和奖励公式 (3.58), 当 $t \in (t^l, t^r)$ 时, 需满足 $T(t) = 0$, $Z(t) = t$ 。

当 $t \in [t_1, t^l] \cup [t^r, t_N]$ 时, 奖励为 $J(t) = 0$ 。

综上所述, 在给定激励成本 M 时, 最小化系统总行驶时间的奖励方案的具体表达式为:

$$J(t) = \begin{cases} (\theta - \alpha)\beta(t - t^l) / \alpha & t \in (t^l, t^r] \\ 0 & t \in [t_1, t^l] \cup [t^r, t_N] \\ -(\theta - \alpha)\gamma(t - t^r) / \alpha & t \in (t^l, t^r) \end{cases} \quad (3.64)$$

t^l 和 t^r 分别为奖励开始和结束实施的时刻。在该优化奖励方案下, 系统最终达到一个新的均衡状态, 根据均衡状态下广义出行成本 $G(t) = \kappa(t) + \theta C(t) + \alpha T(t) - J(t)$ 在任意时刻相等, 可以计算得到出发率为:

$$D(t) = \begin{cases} \alpha c / (\alpha - \beta) & t \in [t_1, t^l] \\ c & t \in (t^l, t^r) \\ \alpha c / (\alpha + \gamma) & t \in [t^r, t_N] \end{cases} \quad (3.65)$$

假设 $t_1 = 0$, 根据等式 (3.33) 和 (3.65) 可以计算得到 t^l 与 t^r 的具体时刻, 即


$$t^l = \gamma(\alpha - \beta) \{N / c - \sqrt{2\alpha M / [c\delta(\theta - \alpha)]}\} / [\alpha(\beta + \gamma)],$$

$$t^r = N / c + \{1 - \alpha\beta / [\delta(\alpha - \beta)]\}t^l, \quad t^l = \delta N / (c\beta) - \beta t^l / (\alpha - \beta)。$$


当激励成本为 M 时, 相应的系统总行驶时间 Γ 可以表示为:

$$\Gamma = \delta N^2 / (2c\alpha) - M / (\theta - \alpha) \quad (3.66)$$

上述推导分别得到了 $\theta < \alpha$ 和 $\theta > \alpha$ 情况下的考虑出发时间偏移量的奖励方案, 当成本参数的单位为元/分钟时, 主要形式如图 3.11 所示。注意图 7 仅为奖励方案一般形式的示意图, 不包含参数成本和奖励金额的具体数值。实线和直方实线分别代表了 $\theta < \alpha$ 预算充足和不充足情况下的奖励方案, 虚线和直方虚线分别代表了 $\theta > \alpha$ 预算充足和不充足情况下的奖励方案。当 $\theta < \alpha$ 时, 奖励曲线为倒 V 型, $\theta > \alpha$ 时, 奖励曲线为 V 型。



(a) 金额与出发时间、出发时间偏移量关系



(b) 金额与出发时间关系

图 3.11 $\theta < \alpha$ 和 $\theta > \alpha$ 情况下考虑预算约束的奖励方案示意图

根据图 3.11, 在预算不充足的情况下, 当 $\theta < \alpha$ 时, 最优奖励方案呈“U 型”, 奖励分布在高峰拥堵时段的两端; 而当 $\theta > \alpha$ 时, 最优奖励方案呈分布在高峰时段中间的“倒 V 型”。

相应地, 在考虑预算约束情况下, 上述奖励方案实施后排队形成的消散过程示意图如图 3.12 所示:




图 3.12 瓶颈模型用户均衡状态示意图

3.3.3.3 预算和渗透约束下的奖励方案

渗透率是设计奖励方案时需要重点考虑的关键约束条件之一。IBTDM 管理部门需通过控制渗透率来优化成本支出, 从而实现预算的合理配置。与上文保持一致, 假设渗透率 p 为所有出行者中知晓并参与 IBTDM 项目的比例, 即 IBTDM 项目最多有 Np 个用户参与。基于 3.3.2 节中激励成本约束下的奖励方案设计框架, 研究分别求解 $\theta < \alpha$ 和 $\theta > \alpha$ 情况下考虑渗透率和预算双重约束的奖励方案, 以提高奖励方案的适用性。

1) $\theta < \alpha$

有限预算时, 奖励区间优先设置在高峰时段两端。在考虑渗透率约束的情况下, 这等价于最多能够鼓励 Np 个参与者调整自己的出发时间。

因此, 当激励成本足以鼓励 Np 个参与者调整自己的出发时间时, 渗透率为限制奖励方案实施的主要约束。此时奖励方案如 (3.67) 所示:

$$J(t) = \begin{cases} -(\alpha - \theta)\beta(t - t^l) / \alpha & t \in [t_1, t^l) \\ 0 & t \in [t^l, t^r] \\ (\alpha - \theta)\gamma(t - t^r) / \alpha & t \in (t^r, t_N] \end{cases} \quad (3.67)$$

非参与者将在高峰时段中间形成一个新的均衡状态。 t^l 和 t^r 不再与激励成本相关, 而是与渗透率相关, $t^l = \delta Np / (c\beta)$, $t^r = N / c - \delta Np / (c\gamma)$ 。

根据等式 (3.33), 在渗透率为 p 的情况下实施最优奖励方案所需的最小激励成本 M^{p*} 为:

$$M^{p*} = (\alpha - \theta)\delta N^2 p^2 / (2c\alpha) \quad (3.68)$$

M^{p*} 随着渗透率的增加而单调递增, 这意味着渗透率越高出行服务商就应设置更高的激励成本来缓解拥堵。

当预算不足以将 Np 个参与者推向高峰时段两端时, 即 $0 < M < M^{p*}$, 限制奖励方案的主要约束依旧为激励成本, 最优奖励方案与 3.3.2 节中相同, 如公式(3.59)所示。

此外, 可以求得在激励成本 M 的情况下的最优渗透率 p^* :

$$p^* = \sqrt{2\alpha c M / [(\alpha - \theta)\delta N^2]} \quad (3.69)$$

即当激励成本为 M 时, IBTDM 管理部门应该将项目的渗透率应控制在 p^* 以避免预算浪费。最优渗透率随预算的增加单调递增, 这意味着随着预算的增加, 出行服务公司可以逐步扩大渗透率。当市场渗透为 p 时, 相对应的系统总行驶时间可以表示为:

$$\Gamma = \delta(N - Np)^2 / (2\alpha c) \quad (3.70)$$

2) $\theta > \alpha$

当 $\theta > \alpha$ 时, 在预算有限的情况下奖励区间应优先设置在高峰时段中间, 以鼓励在高峰期中段出发的出行者更多地调整自己的出发时间。在考虑渗透率约束的情况下, 这等价于最多能够通过分配奖励鼓励 Np 个参与者调整自己的出发时间。

当预算足以鼓励 Np 个参与者调整自己的出发时间时, 渗透率为限制奖励方案实施的主要约束。奖励方案如 (3.71) 所示:

$$J(t) = \begin{cases} (\alpha - \theta)\beta(t - t^l) / \alpha & t \in (t^l, t^i] \\ 0 & t \in [t^l, t^i] \cup [t^r, t_N] \\ -(\alpha - \theta)\gamma(t - t^r) / \alpha & t \in [t^i, t^r) \end{cases} \quad (3.71)$$

此时 t^l, t^r 以及 t^i 不再受到奖励预算的影响, 而是受限于渗透率, 具体为 $t^l = \delta(\alpha - \beta)(N - Np) / (\alpha\beta c)$, $t^r = N / c + [1 - \alpha\beta / \delta(\alpha - \beta)]t^l$, $t^i = \delta N / (c\beta) - \beta t^l / (\alpha - \beta)$ 。

相应地, 渗透率为 p 时实施最优奖励方案所需的最小激励成本 M^{p*} 为:

$$M^{p*} = (\theta - \alpha)\delta N^2 p^2 / (2\alpha c) \quad (3.72)$$

当 $0 < M < M^{p*}$, 限制奖励方案的主要约束依旧为预算, 最优奖励方案与 2.2 节中相同, 如公式 (3.64) 所示。在激励成本 M 的情况下的最优渗透率 p^* 为:

$$p^* = \sqrt{2\alpha c M / [(\theta - \alpha)\delta N^2]} \quad (3.73)$$

此外, 当市场渗透为 p 时, 相对应的系统总行驶时间可以表示为:

$$\Gamma = \delta(N^2 - N^2 p^2) / (2\alpha c) \quad (3.74)$$

在预算与渗透率双重约束下, 最优奖励方案实施后的排队形成与消散过程与图 3.12 一致。

3) $\alpha = \theta$

当 $\alpha = \theta$ 时, 由 3.3.2 节可知, 考虑出发时间偏移量的奖励方案不存在激励成本约束, 因此渗透率恒为限制奖励方案实施的主要约束。若激励成本为 M , 则可用于鼓励 Np 个参与者调整出发时间, 奖励方案为 $J(t) = M / (Np)$ 。


此时, 奖励金额固定, 参考图 3.12 所示的奖励作用下的均衡状态, 奖励时段设置在高峰期两端可以完全消除该区间的瓶颈排队, 往往可以取得较好的拥堵缓解效果。

3.3.3 奖励方案对比分析


Sun 等^[18]探究了基于出发时间的奖励方案, 该方案采用“削峰填谷”的方法, 诱导出行者改变出发时间, 以减少拥堵。而本研究将用户出发时间偏移量成本纳入奖励方案设计, 求得了考虑出行者出发时间偏移量的奖励方案, 该方案激励出行者将自身出发时间调整为原始出行模式中的到达时间。为了阐明两种奖励方案的区别及其适用性, 研究将进一步对比两者在形式、缓解拥堵效果上的差异。

(1) 考虑出发时间偏移量的奖励方案与基于出发时间的奖励方案形式对比

基于出发时间的奖励方案在预算充足时呈“V 型”, 在预算不充足时呈“U 型”——这与 $\theta < \alpha$ 条件下考虑出发时间偏移量的奖励方案形式相似, 因此, 本研究对基于出发时间的奖励方案与考虑出发时间偏移量的奖励方案(当 $\theta < \alpha$ 时)进行了比较, 结果如图 3.13 (a) 所示。此外, 本研究综合对比了 $\theta > \alpha$ 情况下的考虑出发时间偏移量的奖励方案与基于出发时间的奖励方案, 结果如图 3.13 (b) 所示, 以更加全面的分析两类奖励方案的异同。图 3.13 为各类奖励方案的一般形式示意图, 并未涉及具体的成本参数以及奖励金额数值, 其中, 实线和虚线分别代表了预算充足和不充足情况下的基于出发时间的奖励方案; 和方形组合的实线和虚线分别代表了奖励充足和不充足情况下的考虑出发时间偏移量(当 $\theta < \alpha$ 时)的奖励方案; 和圆形组合的实线和虚线分别代表了预算充足和不充足情况下的考虑出发时间偏移量(当 $\alpha < \theta \leq 2\alpha$ 时)的奖励方案; 和菱形组合的实线和虚线分别代表了预算充足和不充足情况下的考虑出发时间偏移量(当 $\theta > 2\alpha$ 时)的奖励方案。为了更加明确奖励方案的区别, 图 3.13 中预算不充足时奖励曲线具有相同的总预算。



(a) 考虑出发时间偏移量 (当 $\theta < \alpha$ 时)、基于出发时间的奖励方案对比



(b) 考虑出发时间偏移量 (当 $\theta > \alpha$ 时)、基于出发时间的奖励方案对比

图 3.13 考虑出发时间偏移量和基于出发时间的奖励方案对比示意图

由图 3.13(a)可知,预算充足时,考虑出发时间偏移量的奖励方案(当 $\theta < \alpha$ 时)在 t^* 时刻的奖励金额为 0,而在其他时刻,奖励金额均少于不考虑此成本的基于出发时间的奖励方案。因此,考虑出发时间偏移量的奖励方案的最优奖励预算较小。这在一定程度上说明了基于出发时间的奖励方案由于在分配奖励时忽视了用户原始出发时间的影响,导致部分激励成本未能实现激励用户改变出发时间的预期目标,即存在预算浪费现象。此外,当预算不充足时,在相同的预算条件下,考虑出发时间偏移量的最优奖励方案能够在更长的高峰时段内减少排队拥堵。

如图 3.13(b)所示,与 $\theta < \alpha$ 情况不同,当 $\theta > \alpha$ 时考虑出发时间偏移量的最优奖励方案在预算充足和不充足时均呈“倒 V 型”,考虑出发时间偏移量的最优奖励方案中任意时刻的奖励金额并不总是小于基于出发时间的最优奖励方案。此外,假设使系统达到 SO 状态的基于出发时间、当 $\alpha < \theta \leq 2\alpha$ 和 $\theta > 2\alpha$ 时考虑出发时间偏移量的最优奖励方案分别为 $J_{depart}(t)$ 、 $J_{\alpha < \theta \leq 2\alpha}(t)$ 和 $J_{\theta > 2\alpha}(t)$,则其激励成本分别为 $c \int_{t_1}^{t_N} J_{depart}(t)dt$ 、 $c \int_{t_1}^{t_N} J_{\alpha < \theta \leq 2\alpha}(t)dt$ 和 $c \int_{t_1}^{t_N} J_{\theta > 2\alpha}(t)dt$ 。因此,奖励方案所需激励成本的大小主要取决于奖励曲线与横坐标轴(时间)的面积。由图 3.13(b)

可知,当 $\theta > 2\alpha$ 时,和菱形组合的实线与横坐标轴的面积大于实线与横坐标轴的面积,因此考虑出发时间偏移量的奖励方案的最优预算大于基于出发时间的奖励方案的最优预算。

(2) 考虑出发时间偏移量的奖励方案与基于出发时间的奖励方案效果对比

为了分析两类奖励方案对系统总行驶时间的影响,从而明确其缓解拥堵的有效性,并作为交通管理部门选择奖励方案的依据,本研究计算了不同单位出发时间偏移量成本 θ 下,当 $\alpha = 1$ 元/分钟, $\beta = 0.5$ 元/分钟, $\gamma = 2$ 元/分钟, $c = 20$ 辆/分钟以及 $N = 2000$ 时的奖励方案预算与实施后系统总行驶时间的关系,如图 3.14 所示。一般而言, α, β, γ 越大,诱导用户改变出发时间的难度越大,消除系统排队所需要的奖励就越多;然而若符合 $\gamma > \alpha > \beta$ 的相对关系,则 α, β, γ 的具体取值并不影响奖励方案的形式与激励成本消除系统排队的趋势。根据 3.1 节的相关分析,考虑出发时间偏移量的奖励方案形式与 θ 和 α 的相对大小有关,且主要分为 $\theta < \alpha$ 、 $\alpha < \theta \leq 2\alpha$ 、 $\theta > 2\alpha$ 三类情况。本案例中 $\alpha = 1$ 元/分钟,因此研究将 θ 取值范围设定在 0.2-2.1,以全面考察 $\theta < \alpha$ 、 $\alpha < \theta \leq 2\alpha$ 、 $\theta > 2\alpha$ 三种条件下考虑出发时间偏移量的奖励方案的实施效果。




图 3.14 不同单位出发时间偏移成本下系统总行驶时间与预算的关系

由图 3.14 可见,当 $\theta > \alpha$ 时,系统总行驶时间随着激励成本线性递减。即随着激励成本增加,单位激励成本所带来的边际系统总行驶时间减小量不变。这说明预算充足的大型公司在减少系统排队时间上具有优势,往往能够达到更好的效果。当 $\theta < \alpha$ 时,系统总行驶时间随着激励成本递减,在激励成本处于较低水平时,系统总行驶时间下降速度较快;在激励成本靠近 M^* 时,系统总行驶时间下降速度趋于平稳。即随着激励成本增加,单位激励成本的边际系统总行驶时间减



小量递减。这说明当激励成本处于较低水平时，每单位激励成本能够起到更大的管控效果，激励成本预算低的小型出行服务商相对于大型公司具有一定优势，不利于垄断的发生。

相较于基于出发时间的奖励方案（图 3.14 中实线），当 $\theta < \alpha$ 时，相同激励成本情况下，考虑出发时间偏移的奖励方案在相同预算情况下实现的系统总行驶时间总是较小，即该方案在减少系统排队方面具有较好的效果；相应地，方案所需的能够完全消除排队的最优预算较少。当 $\alpha < \theta < 2\alpha$ 时，存在某一激励成本预算节点——例如图 10 中 $\theta = 1.5$ 元/分钟时的点 A，在激励成本预算大于此节点时，考虑出发时间偏移的奖励方案在相同激励成本条件下实现的系统总行驶时间小于基于出发时间的奖励方案，因此在激励成本较大时该方案能更有效地缓解拥堵。当 $\theta > 2\alpha$ 时，相同激励成本情况下，基于出发时间的奖励方案实施后的系统总行驶时间总是小于考虑出发时间偏移量的奖励方案，因此其在减少系统排队方面具有优势。

综上所述，出行者的单位出发时间偏移量成本 θ 和单位行驶时间成本 α 的相对大小对考虑出发时间偏移量的最优奖励方案形式、不同类型的奖励方案的拥堵缓解效果非常重要，因此 IBTDM 管理部门需要正确预估出行者的单位出发时间偏移成本以及单位行驶时间成本，以合理利用激励成本预算，完成预期目标。

3.4 本章小结

本章面向理性 CAVs 和 HVs，基于经典单瓶颈模型框架对单起点-终点的出发时间选择场景进行建模，研究以最小化系统总行驶时间为目标，通过理论推导分别求解：（1）奖励预算约束下宣传成本与激励成本的最优分配方案，（2）在预算、渗透率等全局约束下，基于出发时间偏移量的个体出发时间选择机制与最优时变奖励策略，实现理性主体在奖励影响下的出发时间选择预测。主要结论如下：

（1）本章假设宣传成本与渗透率呈线性正相关，考虑 CAVs、HVs 群体的异质单位宣传成本构建数学规划模型，求解了 CAVs、HVs 宣传成本与激励成本之间的最优预算分配方案。研究发现：在预算有限时，最优策略应集中资源推广单一用户群体，而非同时提高多个群体的渗透率；不同群体的单位宣传成本差异决定了宣传推广顺序——应优先覆盖单位宣传成本较低的 CAVs 群体。

（2）本章将原始出发时间纳入出行成本函数，完善了理性 CAVs 和 HVs 的个体动态出发时间选择机制，突破传统静态奖励逻辑，推导了有限预算、渗透率下的基于行为调整幅度的最优时变奖励形式，从而实现理性主体在奖励影响下的出发时间选择预测。分析表明，出行者的单位出发时间偏移量成本 θ 和单位行驶



时间成本 α 的相对大小对考虑出发时间偏移量的最优奖励方案形式、拥堵缓解效果具有决定性影响。

现有模型基于理性假设而展开,未能考虑智能网联环境中存在的非理性 HVs 和 CAVs,同时也缺乏异质主体交互影响的考量。为此,本研究将在第4章研究非理性 HVs 在奖励影响下的出发时间选择;第5章将引入非理性 CAVs 出发时间选择特征,构建集成三类异质主体的仿真框架,以刻画智能网联交通环境的真实特性。



25548202



第4章 非理性HVs出发时间选择行为分析与建模

上一章从理论层面分析了理性 CAVs 和 HVs 的出发时间选择机制。然而，智能网联环境中存在的非理性 HVs 呈现有限理性与个体差异特征，与理性主体存在显著差异。为刻画非理性 HVs 的出发时间选择机制，本章采用问卷调查和长时逐日交互实验方法，采集用户奖励策略偏好及逐日动态出发时间选择数据，并运用结构方程模型与面板回归、聚类分析等方法识别影响因素；基于此，采用 Transformer 架构构建奖励策略下的出发时间选择行为预测模型，并通过逐日出发时间预测准确率验证模型有效性。本章构建的非理性 HVs 出发时间选择行为预测模型，作为智能网联环境下异质主体行为建模的关键组成部分，可预测不同 IBTDM 方案下非理性 HVs 的出发时间选择行为。

4.1 概述

在智能网联环境中，部分 HVs 受限于认知能力和信息完备性，在奖励影响下的出行选择往往偏离完全理性效用最大化原则，更多地依赖于启发式规则、满意化原则或惯性策略，以降低认知负荷^[151]，研究将此类 HVs 定义为非理性 HVs。此出行选择行为受到内外部因素的影响，包括环境条件、行为习惯、社会规范以及情绪状态等^[152-155]，呈现出显著的个体差异、不确定性特征。此时，CAVs 需要实时响应非理性 HVs 模糊行为并据此调整其策略，进一步增加了系统不确定性。

因此，在智能网联环境的逐日通勤出发时间选择场景中，刻画非理性 HVs 的出发时间选择模式及其逐日演化规律，是设计有效 IBTDM 方案的关键前提。

鉴于非理性 HVs 行为模式的个体差异性，理论模型或规则型仿真难以有效刻画其特征；相比之下，数据驱动方法无需依赖先验假设，可从观测数据中直接学习潜在模式，更适于揭示行为本质及其逐日动态演化规律。

现有研究基于数据分析，对奖励方案下非理性 HVs 的出发时间、出行方式等选择行为特征进行了系统性分析，并取得了一定进展。例如，Shen 等^[22]发现货币奖励对鼓励单人驾驶者拼车的效果因社会人口和判断因素的不同而不同；而 Lin 等^[83]发现，高收入群体对个人碳交易策略表现出更高的接受度。然而，现有研究在解释和预测奖励策略下非理性 HVs 出发时间选择行为时仍存在以下挑战：
1) 个体差异性量化：由于缺乏 IBTDM 平台支持，以及对多样化奖励策略（高峰时段票价折扣、换乘优惠等）的系统性调查，现有研究难以刻画非理性 HVs 在面对奖励策略时的双重个体差异性——既包括个体选择差异，又涉及不同奖励策

略引致的系统性变化，导致难以建立可靠的策略-选择映射关系。**2) 长时逐日动态演化机制探究：**基于固定奖励方案的实验设计和静态分析框架无法有效捕捉出发时间选择行为随时间和环境变化的动态特征，因而无法准确评估长时出发时间选择规律及奖励策略效果的演变趋势。**3) 非理性 HVs 出发时间选择机制建模：**现有研究多局限于宏观定量分析，尚未构建能够深度刻画非理性 HVs 个体差异性及行为动态演化特征的出发时间选择行为预测模型，从而限制了奖励策略在智能网联环境中的评估与优化。

为弥补现有研究在数据支撑与行为建模方面的不足，本章聚焦出发时间选择行为，开展数据采集、分析与建模工作。问卷调查方法能够高效获取大样本数据，但其结果易受题目设置、场景真实性限制，难以反映真实的逐日选择行为；而实验室实验能在可控环境下模拟出行选择过程，具备较高数据可信度，但受到场地依赖、招募区域集中、样本规模有限及实施成本较高等限制。为兼顾行为真实性与样本广度，本研究结合大规模问卷调查（选择具备 IBTDM 活动参与经验的高德地图平台用户，以缓解实验场景不真实带来的选择偏差），与小样本动态交互实验（实验宣传范围内具备参与意愿的个体，以提高长时参与度），采集能够较真实反映非理性 HVs 的多样化奖励策略偏好数据及逐日动态出发时间选择行为数据，在此基础上分析其出发时间选择特征并构建出发时间选择行为预测模型。

本章研究架构如图 4.1 所示。具体而言，第 4.2 节依托高德平台实施问卷调查，探究非理性 HVs 对针对不同管控目标（出发时间及出行模式）、奖励形式的多样化奖励策略的偏好差异。第 4.3 节设计并开展长时交互实验室实验（含 10 天无奖励对照期和 21 天奖励干预期）以探究非理性 HVs 的出发时间选择演化规律。第 4.4 节拟合了非理性 HVs 出发时间选择行为预测模型。




图 4.1 非理性用户出发时间选择行为分析技术路线



4.2 基于问卷调查的多样化奖励策略偏好分析

实验室实验存在场景构建复杂、成本高昂、样本规模不足等局限，而问卷调查方法作为出行行为研究的重要工具，能够高效获取大样本数据，有效支撑非理性 HVs 对多样化 IBTDM 策略的偏好分析。

因此，研究采用问卷调查方法，探究非理性 HVs 的多样化奖励策略偏好及其影响因素。鉴于 IBTDM 策略的实施效果高度依赖于其公众接受度^[75]，研究将非理性 HVs 对奖励策略的接受度作为衡量其在奖励影响下行为依从性的关键指标。为系统获取非理性 HVs 对多样化奖励策略的接受度数据，研究依托高德地图平台（中国代表性的、具备 IBTDM 实施经验的出行服务商，其 2022 年月活跃用户达 4.9 亿^[156]），在中国苏州（因其具备高德地图 IBTDM 项目开展经历）开展大规模问卷调查，共回收 1054 份有效样本，受访者均具备 IBTDM 参与经验。

接下来将详细介绍问卷调查的设计与实施过程，并对收集数据进行深入分析。

4.2.1 非理性 HVs 多样化奖励策略偏好数据集

本研究通过问卷调查方法，获取非理性 HVs 奖励策略偏好数据集。问卷设计包含两个模块：（1）受访者社会人口特征，包括年龄、性别、主要出行方式以及起点-目的地（OD 对）等；（2）对奖励策略的接受度评估。为了充分评估出行者对于主流 IBTDM 策略的接受度，提高实验数据的应用价值和真实性，根据美国联邦公路管理局对 15 个典型或试点 IBTDM 项目的调研结果^[25]（其中 5 个关注出发时间，8 个关注出行方式选择）以及北京市碳普惠活动的实践经验，本研究筛选了 7 种主流 IBTDM 策略。具体包括：1）出发时间改变策略（早高峰票价折扣、绿色积分奖励）；2）出行方式转换策略（工作/休闲出行场景下的绿色积分奖励、停车换乘折扣、工作/休闲出行场景下的基于出行频次的公交票价折扣）。

问卷采用线上渠道，严格限制 IP 地址及设备重复提交，并设置答题逻辑校验与填写完整性约束，以控制无效样本。在数据清洗阶段，剔除存在明显逻辑冲突、缺失信息或填写随意的问卷，最终共收集到 1,054 份有效问卷。此外，研究对有效问卷的 OD、性别、年龄等结构分布进行了统计分析，结果显示其与苏州市通勤人群的总体特征具有较高一致性，因而具备良好的外部代表性。

表 4.1 展示了问卷调查第一部分关于受访者社会人口特征、出行方式倾向性的调查结果。统计分析表明，调查样本具有较强的多样性，具体而言：女性占 55%，男性占 45%；年龄集中在 18 至 55 岁之间；收入分布较为均衡，其中收入在 5,000 - 10,000 元人民币区间的受访者占比最高，为 34%。

针对出行方式倾向性，为全面捕捉受访者在不同出行场景下的出行方式偏好，



第4章 非理性 HVs 出发时间选择行为分析与建模

问卷设置了多选题，分别调查其在工作与休闲场景下的主要出行方式。基于问卷结果，对六类交通方式（公共交通、私家车、自行车、电动车、步行、出租车）进行了倾向性评估——若某一交通方式同时被选为工作与休闲出行的主要方式，则视为受访者对该方式的偏好最强。

表 4.1 问卷调查信息汇总

信息类别	具体分类	数量	百分比
性别	1=男	471	44.69%
	2=女	583	55.31%
年龄	1=18 岁以下	49	4.65%
	2=18-25 岁	416	39.47%
	3=26-35 岁	348	33.02%
	4=36-45 岁	137	13.00%
	5=46-55 岁	72	6.83%
	6=56-65 岁	22	2.09%
	7=65 岁以上	10	0.95%
教育水平	1= 初中及以下	60	5.69%
	2= 职业中学和高中	106	10.06%
	3= 大专	686	65.09%
	4= 学士学位及以上	202	19.17%
在苏州的家庭成员数	1=1	224	21.25%
	2=2	100	9.49%
	3=3	339	32.16%
	4=多于 3 个	391	37.10%
月工资收入	1=少于¥3,000	294	27.89%
	2=¥3,001 - ¥5,000	172	16.32%
	3=¥5,000-¥10,000	360	34.16%
	4=¥10,000-¥30,000	196	18.60%
	5= ¥30,000 以上	32	3.04%
私家车数量	1=无	295	27.99%
	2=1 辆	538	51.04%
	3=多于 1 辆	221	20.97%
每周工作天数	1=0 天	42	3.98%
	2=1-2 天	18	1.71%
	3=3-5 天	676	64.14%
	4=6-7 天	318	30.17%
通勤拥挤程度	1=完全不拥堵	104	9.87%
	2=相对不拥堵	139	13.19%
	3=一般	405	38.43%
	4=相对拥堵	321	30.46%
	5=完全拥堵	85	8.06%



第 4 章 非理性 HVs 出发时间选择行为分析与建模

(续表)

信息类别	具体分类	数量	百分比
改变出发时间自由度	1=完全无法改变	148	14.04%
	2=相对无法改变	352	33.40%
	3=一般	272	25.81%
	4=相对可以改变	196	18.60%
	5=完全可以改变	86	8.16%
出行距离	1=少于 1km	159	15.09%
	2=1-3km	228	21.63%
	3=3-5km	226	21.44%
	4=5-10km	200	18.98%
	5=多于 10km	241	22.87%
公共交通出行倾向性	1=上班上学和休闲娱乐时都不选择	290	27.51%
	2=休闲娱乐时选择；上班上学时不选择	387	36.72%
	3=上班上学时选择；休闲娱乐时不选择	80	7.59%
	4=上班上学和休闲娱乐时都选择	297	28.18%
私家车出行倾向性	1=上班上学和休闲娱乐时都不选择	478	45.35%
	2=休闲娱乐时选择；上班上学时不选择	149	14.14%
	3=上班上学时选择；休闲娱乐时不选择	101	9.58%
	4=上班上学和休闲娱乐时都选择	326	30.93%
自行车出行倾向性	1=上班上学和休闲娱乐时都不选择	852	80.83%
	2=休闲娱乐时选择；上班上学时不选择	79	7.50%
	3=上班上学时选择；休闲娱乐时不选择	76	7.21%
	4=上班上学和休闲娱乐时都选择	47	4.46%
电动车出行倾向性	1=上班上学和休闲娱乐时都不选择	751	71.25%
	2=休闲娱乐时选择；上班上学时不选择	56	5.31%
	3=上班上学时选择；休闲娱乐时不选择	154	14.61%
	4=上班上学和休闲娱乐时都选择	93	8.82%
步行出行倾向性	1=上班上学和休闲娱乐时都不选择	743	70.49%
	2=休闲娱乐时选择；上班上学时不选择	93	8.82%
	3=上班上学时选择；休闲娱乐时不选择	143	13.57%
	4=上班上学和休闲娱乐时都选择	75	7.12%
出租车出行倾向性	1=上班上学和休闲娱乐时都不选择	646	61.29%
	2=休闲娱乐时选择；上班上学时不选择	295	27.99%
	3=上班上学时选择；休闲娱乐时不选择	33	3.13%
	4=上班上学和休闲娱乐时都选择	80	7.59%

为探究 OD 组合对 IBTDM 策略接受度的影响，研究基于苏州多中心化的独特地理特征，对 OD 组合进行了细致分类，重点关注了涉及苏州中心城区（图 4.2 中红色区域）、周边各区（图 4.2 中绿色区域）和其他城市（图 4.2 中蓝色区域）的 OD 组合。其中，苏州中心城区——姑苏区作为古城区，实行“古城保护”政

策；而由吴江区、吴中区、工业园区、虎丘区和相城区组成的周边各区均设有各自的区域中心。表 4.2 详细列出了受访者的 OD 组合信息及其对应的参与者分布情况。




图 4.2 苏州行政区图

表 4.2 OD 对分类和受访者 OD 对分布

OD	OD 区域	数量	百分比
中心区_中心区	O&D-姑苏区	162	15.37%
中心区-周边各地区	O-姑苏区, D-周边各地区	55	5.22%
周边各地区_中心区	O-周边各区, D-姑苏区	59	5.60%
其他城市_其他城市	O&D-其他城市	89	8.44%
Extra_OC	O or D-其他城市	70	6.64%
吴中_吴中	O&D-吴中区	105	9.96%
工业园_工业园	O&D-工业园区	209	19.83%
虎丘_虎丘	O&D-虎丘区	91	8.63%
吴江_吴江	O&D-吴江区	19	1.80%
相城_相城	O&D-相城区	73	6.93%
周边各地区_周边各地区	O&D-周边各地区	122	11.57%



表 4.3 展示了调查问卷第二部分的内容和调查结果，具体呈现了受访者对以改变出发时间和出行方式为目的的奖励策略的接受程度。

表 4.3 不同奖励策略的接受度

策略分类	奖励策略	接受度	数量	百分比
I-1	如果出行次数越多，公共交通票价越优惠，您愿意增加休闲娱乐的公共交通出行次数吗？	1=完全不愿意	7	0.66%
		2=相对不愿意	25	2.37%
		3=一般	168	15.94%
		4=相对愿意	344	32.64%
		5=完全愿意	510	48.39%
I-2	您愿意为了收集绿色积分，改变您休闲娱乐的出行方式吗？	1=完全不愿意	12	1.14%
		2=相对不愿意	30	2.85%
		3=一般	192	18.22%
		4=相对愿意	383	36.34%
		5=完全愿意	437	41.46%
II-1	如果出行次数越多，公共交通票价越优惠，您愿意增加上班上学的公共交通出行次数吗？	1=完全不愿意	19	1.80%
		2=相对不愿意	59	5.60%
		3=一般	228	21.63%
		4=相对愿意	293	27.80%
		5=完全愿意	455	43.17%
II-2	如果地铁站实施停车换乘优惠，您愿意减少私家车出行次数吗？	1=完全不愿意	14	1.33%
		2=相对不愿意	48	4.55%
		3=一般	228	21.63%
		4=相对愿意	359	34.06%
		5=完全愿意	405	38.43%
II-3	您愿意为了收集绿色积分，改变您上班上学的出行方式吗？	1=完全不愿意	26	2.47%
		2=相对不愿意	61	5.79%
		3=一般	269	25.52%
		4=相对愿意	335	31.78%
		5=完全愿意	363	34.44%
III-1	如果公共交通在早高峰前后提供票价折扣，您是否愿意提前出发？	1=完全不愿意	43	4.08%
		2=相对不愿意	109	10.34%
		3=一般	340	32.26%
		4=相对愿意	261	24.76%
		5=完全愿意	301	28.56%
III-2	您愿意为了收集绿色积分，改变您上班上学的出发时间吗？	1=完全不愿意	34	3.23%
		2=相对不愿意	102	9.68%
		3=一般	299	28.37%
		4=相对愿意	284	26.94%
		5=完全愿意	335	31.78%



4.2.2 非理性 HVs 奖励策略接受度的影响因素分析

如表 4.3 显示,大多数非理性 HVs 对奖励策略持积极态度,完全不愿意或相对不愿意接受者占比较少。对于同类奖励策略,受访者的接受度分布较为一致,而不同类型策略之间的接受度分布差异显著。进一步地,研究采用 H 检验(一种用于比较多个独立样本分布的非参数检验方法)对三类奖励策略的接受度分布进行统计分析,结果表明,受访者对上述三类奖励策略的接受度存在显著分布差异。

基于上述分析,研究将进一步探讨非理性 HVs 对不同类型奖励策略的接受程度差异及其影响因素。

传统模型(如描述性分析、影响因素分析、线性回归和逻辑回归模型)已广泛应用于公众对 TDM 策略态度的研究中。然而,这类方法通常仅关注单一因变量(如特定奖励策略或某一类别奖励策略的接受度),例如用于分析非理性 HVs 对特定策略(如旨在改变上班出行方式的绿色积分策略)或特定类型策略(如旨在改变出发时间的奖励策略)的接受度及其影响因素。然而,这类模型难以表征变量之间的潜在关系,无法全面分析非理性 HVs 对不同类别策略的态度差异。

另一方面,更复杂的选择模型(如混合选择模型 HCM、综合选择和潜变量模型 ICLV 以及嵌套 logit 模型 NL)能够模拟复杂的出行选择过程。然而,这类模型更适用于排他性选择场景,与本研究的具体问题——分析接受度的影响因素及其差异——并不完全契合。此外,这类复杂模型对数据要求较高:例如,ICLV 模型需要不同选择方案的属性数据,而 HCM 则需要指标数据,最好同时包含陈述偏好和揭示偏好数据。本研究的数据集无法满足上述模型的严格要求。

相比之下,结构方程模型能够基于问卷数据,通过建立多个相互关联的方程,探究不同类型奖励策略接受度的影响因素,并进一步分析其差异。表 4.4 列出了上述三类模型的对比分析。

表 4.4 传统回归模型、SEM 和典型选择模型的特点

特点	传统回归	SEM	选择模型		
			HCM	ICLV 模型	NL 模型
本研究场景适应性	中	强	弱		
数据采集难度	弱	弱	中	强	弱
本数据集适应性	强	强	弱		强
因果建模能力	弱	强	中		

综上所述,结构方程模型更适合本研究的需求。因此,研究采用 SEM 模型来分析受访者的属性对其奖励策略接受度的影响。在该模型中,设定了三个内生变量,分别为受访者对改变出发时间、上班出行方式以及休闲出行方式的奖励策

略的接受度,并将其作为社会经济学属性、出行习惯和 OD 组合的函数进行分析。结构方程模型结构图如图 4.3 所示。




图 4.3 结构方程模型结构

通过结构方程模型,得到受访者的社会经济学、出行习惯、OD 属性对于受访者对不同类别的奖励策略的接受度的影响,结果如表 4.5 所示。

表 4.5 直接效应、间接效应和总效应

变量	改变出发时间 奖励策略的接受度			改变上班上学出行方式 奖励策略的接受度			改变休闲娱乐出行方式 奖励策略的接受度		
	D	I	T	D	I	T	D	I	T
月收入	-0.093	-0.011	-0.103	0	-0.083	-0.083	0	-0.061	-0.061
OD	-0.147	0.005	-0.141	0	-0.128	-0.128	0	-0.102	-0.102
出行距离	0	0.03	0.03	0.049	0.011	0.06	0	0.062	0.062
私家车数量	0	-0.046	-0.046	-0.08	-0.065	-0.144	0.073	-0.117	-0.044
性别	0	0.007	0.007	0.075	0.013	0.087	0.077	0.071	0.148
步行倾向性	0	-0.014	-0.014	0.059	-0.025	0.033	0	0.027	0.027
家庭成员数量	0	-0.018	-0.018	0	-0.026	-0.026	0	-0.021	-0.021
私家车倾向性	0	-0.05	-0.05	0	-0.08	-0.08	0	-0.065	-0.065
年龄	0	-0.003	-0.003	0	-0.009	-0.009	0	-0.008	-0.008
自行车倾向	0	0.021	0.021	0	0.037	0.037	0	0.03	0.03
电动车倾向	0	-0.032	-0.032	-0.031	-0.055	-0.086	0	-0.07	-0.07
公共交通倾向	0.134	0	0.134	0.111	0.124	0.235	0	0.19	0.19
教育水平	0.077	0	0.077	0.036	0.071	0.108	0	0.087	0.087

从表 4.5 中可以看出,影响受访者对各类奖励策略接受度的因素是多维度的:
1) 公共交通倾向性、月收入和出行天数是影响受访者对调整出发时间奖励策略接受度的前三大主要因素; 2) 公共交通倾向性、私家车数量和 OD 组合是影响



改变上班出行方式策略接受度的三大主要因素，此外，教育程度也对其具有显著影响；3）公共交通倾向性、性别和 OD 组合是影响改变休闲出行方式策略接受度的前三大因素。基于上述研究结果，IBTDM 管理部门应优先考虑受访者对公共交通的偏好、教育程度、性别、OD 组合以及私家车数量等特征属性，以制定更具针对性的奖励策略方案，并针对特定出行群体开展营销宣传活动。

接下来将进一步分析不同特征对受访者奖励策略接受度的影响。

1) OD 对奖励策略接受度的影响

根据调查数据，受访者的 OD 组合显著影响其对 IBTDM 策略的接受度，尤其是对旨在改变出发时间的奖励策略的接受度。为深入探究 OD 组合对接受度的影响，研究比较了不同 OD 组合的受访者对三类 IBTDM 策略的平均接受度，结果如图 4.4 所示。图中 OD 与表 4.2 一致。红色、橙色、蓝色、绿色、紫色分别代表表 4.2 中的五个 OD 组合分类。“Mid”、“SurD”和“OC”分别代表苏州的中心城区、周边地区和其他城市。红色、蓝色和绿色的水平虚线分别代表受访者对改变休闲出行方式、工作出行方式和出发时间的 IBTDM 策略的平均接受度。




图 4.4 具有不同 OD 的受访者对三类 IBTDM 策略的接受度

如图 4.4 所示，出发地和目的地均位于姑苏区（OD 组合中的“Mid_Mid”）的受访者对三类 IBTDM 策略的接受度显著高于其他 OD 组合的受访者。这一现象可能出于以下原因：

①公共交通发展：姑苏区优先加强了公共交通基础设施建设，政府将其定位为绿色出行示范区，重点发展以公共交通和慢行交通为主的交通体系，并强化铁

路、公交与慢行交通之间的衔接。通过一系列举措，老城区绿色出行比例已超过75%^[157]。此外，姑苏区位于苏州中心位置，公共交通网络四通八达，显著缩短了乘客的出行距离和时间。

②交通规划政策的实施：姑苏区严格执行了严格的交通管制措施，例如早高峰限行政策^[158]，有效地减少了整体车流量。同时，该区域还实施了强有力的交通需求管理政策，并辅以科学的停车管理措施^[159]。

③基础设施建设：政府监督建设了姑苏区内的特色道路和小巷，并战略性地部署了公共自行车设施，显著改善了古城的整体出行环境。

④环保意识：由于姑苏区的古城特色和丰富的历史街区保护背景，该区域非理性 HVs 可能表现出更高的环保意识，更倾向于支持绿色出行方式。

基于以上分析，在苏州推广 IBTDM 策略时，可以优先将重点放在姑苏区。此外，在其他城市推广 IBTDM 策略时，建议将目标锁定在已成功实施绿色出行或交通需求管理策略的城市或地区，或选择交通网络完善且便利的中心地带，以提高策略成功的可能性。

2) 公共交通倾向性对奖励策略接受度的影响

为分析非理性 HVs 对公共交通的倾向性对其接受度的影响，研究分析了具有不同公共交通倾向性水平的非理性 HVs 对三类 IBTDM 策略的平均接受度，结果如图 4.5 所示。




图 4.5 具有不同公共交通倾向性的受访者对三类 IBTDM 策略的接受度

图 4.5 显示，在非理性 HVs 中，最大的群体是在休闲娱乐时使用公共交通而在上班/上学时不使用公共交通的受访者 (n=387)，其次是在休闲和工作时均



使用公共交通的受访者 ($n=297$), 以及在这两种场景下均不使用公共交通的受访者 ($n=290$)。公共交通倾向性显著影响了受访者对三类奖励策略的接受度, 倾向性较高的受访者更愿意调整自身的出行行为, 包括改变出发时间和出行方式。这一现象可能源于习惯使用公共交通的受访者对原有出行模式和出发时间的依赖性较低, 因而对改变出行行为持更为积极的态度。

在宣传推广旨在改变出行方式的奖励策略时, 重点不应局限于已表现出强烈公共交通倾向性的受访者 (即在上班/上学和休闲娱乐时均使用公共交通的群体)。为进一步推动受访者改变出行方式为拼车、公共交通等进而减轻交通拥堵, IBTDM 管理部门应优先鼓励当前仅在休闲时使用公共交通而在工作时不使用的群体。这一选择基于以下两点原因: ①该群体在样本中占比较大; ②该群体对公共交通等绿色出行方式已具备一定的熟悉度。针对该群体的有效奖励措施包括: 宣传绿色出行方式在节约时间和成本方面的优势、推广实时公交时刻表服务, 以及提供“最后一公里”问题的解决方案。

3) 性别对奖励策略接受度的影响

为探讨非理性 HVs 性别对奖励策略接受度的影响, 研究结合结构方程模型的结果, 进行了 T 检验, 并比较了男性和女性受访者对三类 IBTDM 策略的平均接受度。

根据表 4.5 所示的 SEM 结果, 性别对改变出行方式的奖励策略接受度具有显著影响 (对 I 类策略和 II 类策略的总效应分别为 0.148 和 0.087), 其中女性表现出更高的接受度。然而, 性别对旨在改变出发时间的奖励策略 (III 类策略) 的接受度影响较小 (总效应为 0.007)。

T 检验结果显示, 女性和男性受访者对 I 类和 II 类策略的接受度存在显著差异 (显著性分别为 $p=0.000$ 和 $p=0.013$), 而对 III 类策略的接受度则无显著差异 ($p=0.379$)。

进一步比较男性和女性受访者对三类 IBTDM 策略的平均接受度 (如图 4.6 所示) 发现, 女性受访者对 I 类和 II 类策略的平均接受度显著高于男性。尽管女性对 III 类策略的平均接受度 (图中方点) 略高于男性, 但差异并不显著。

综上所述, 性别对 I 类和 II 类策略接受度的影响值得深入研究, 但对于 III 类策略, 性别并非需要重点关注的因素。因此, 若 IBTDM 管理部门计划实施以改变出行方式为目的的奖励策略, 可将更多宣传成本分配给女性群体; 而在实施旨在改变出发时间的奖励策略时, 性别则无需作为主要考量因素。




图 4.6 女性和男性对 IBTDM 策略的平均接受度

4) 其他因素对奖励策略接受度的影响

如表 4.5 所示，除了上述讨论过的因素外，还有其他因素会影响公众对 IBTDM 策略的接受度。接下来将探究收入、私家车数量和教育程度对接受度的影响。

收入与受访者对 IBTDM 策略的接受度呈负相关，这表明收入越高的非理性 HVs 越不愿意因 IBTDM 策略而改变自己的出行行为。这一现象可能是由于奖励策略对高收入非理性 HVs 的诱惑力相对较小，这与现有研究结果^[160, 161]一致。因此，低收入人群成为 IBTDM 管理部门宣传 IBTDM 的主要目标。

受访者拥有的私家车数量对 IBTDM 策略的接受度具有负面影响，尤其是对于旨在改变上班出行方式的策略。这可能源于拥有多辆私家车的受访者习惯于每天开车上下班，因此不太愿意过渡到公共交通出行。相比之下，没有私家车的受访者更倾向于选择公共交通，也更容易接受奖励下的行为改变。因此，IBTDM 管理部门在推广奖励策略时，应战略性地将重点放在没有私家车的非理性 HVs 身上。

教育程度与旨在改变出行行为的策略接受度呈正相关。这种趋势可能是由于教育程度越高的受访者对 IBTDM 机制的理解越深，从而能够做出更明智的出发时间选择。因此，受教育程度较高的非理性 HVs 成为 IBTDM 策略的潜在参与者。在这种情况下，可以针对大学和科技园区等地点开展宣传活动，以吸引受教育程度较高的非理性 HVs。此外，还可以通过视频、动画、游戏等多样化的传播



渠道来促进非理性 HVs 对 IBTDM 机制的全面了解，减少影响公众接受度的障碍。

综上所述，收入较低、私家车较少、受教育程度较高的非理性 HVs 群体是 IBTDM 策略的潜在参与者。值得注意的是，本节基于高德地图平台实施的问卷调查样本均来自平台活跃用户，且合作方高德地图不考虑宣传推广因素，因而问卷设计未纳入宣传成本变量。因此在 IBTDM 新项目推广阶段，应进一步考量宣传成本影响，以优化目标用户群体筛选。

4.3 基于长时交互实验的出发时间选择逐日演化分析

实验室实验方法能够有效模拟和解析奖励策略下受试者出发时间选择的逐日演化过程。与实地实验相比，实验室实验具有成本效益高、条件可控性强、可重复性好的优势，是研究非理性 HVs 在奖励策略下的逐日出发时间选择的重要方法^[162, 163]。因此，本章利用瓶颈模型设计并开展交互式长时实验室实验，旨在探究非理性 HVs 在奖励方案作用下的出发时间选择逐日动态演化特征。

4.3.1 长时交互实验室实验设计

根据第 4.2 节问卷分析结果显示，不同的管控目标会影响个体对多样化奖励策略的偏好。基于此，研究在分析非理性 HVs 的逐日出发时间选择时，引入出行方式转换策略作为对比，探讨非理性 HVs 在逐日情境下的出发时间与出行方式选择特征及其影响因素差异。因此，实验设计同时考虑了出发时间调整与出行方式转换两类 IBTDM 策略，以探讨出发时间奖励机制的可拓展性及其适用边界。

在早高峰出行场景中，拼车作为一种有效的交通需求管理策略，其核心机制是通过匹配出发地和目的地相似的乘客与司机，使其共同乘坐一辆车出行，从而减少每次出行的单车使用量^[164, 165]并缓解系统拥堵。随着 CAVs 技术的发展，拼车模式在匹配效率和用户体验等方面获得了技术支撑，展现出广阔的应用前景。已有研究表明，奖励措施可以有效缓解拼车带来的不便和隐私担忧，并平衡司机与乘客之间的成本差异，是鼓励出行者参与拼车的有效手段^[62]。基于此，本研究将鼓励拼车的奖励策略作为典型的出行方式转换策略纳入实验，与出发时间调整策略形成对比。

下文将从人员招募、实验框架、出行环境、实验流程等方面详细阐述本研究的实验室实验设计方案。

4.3.1.1 人员招募

在实验受试者的招募过程中,本研究采用分层抽样策略,以高校在读本科生和研究生为主要目标群体。该群体对科研实验的接受度和参与意愿普遍较高。具体招募方式包括校园海报宣传和校内微信群推广等渠道。为进一步提升样本的多样性和代表性,本研究还通过微信官方账号面向社会工作社区进行公开招募,并鼓励志愿者进行二次传播。值得注意的是,本研究未设置地域限制,以确保样本的空间分布广度。




图 4.7 招募海报

在完成初步招募后,研究团队对所有志愿者进行了系统的实验规则讲解和操作培训。为确保数据质量,研究设计了一套简明的测试题,用于评估志愿者对实验流程的理解程度及其参与态度。未达标的志愿者被排除后,通过补充招募和二次筛选,最终确定了实验样本。经过严格筛选的受试者表现出良好的实验依从性和认知水平,既保障了实验顺利开展,也提高了数据可信度。

最后,研究共招募了 206 名受试者。在实验过程中,由于实验周期较长,部分受试者中途退出,最终有 194 名受试者坚持完成了全部实验流程。这一参与率特征与 IBTDM 项目在实际实施中普遍面临的用户流失问题具有高度相似性。

需指出,本实验受限于资源条件,样本主要来源于在校学生,群体相对同质,但在行为实验研究中,采用学生样本作为代表性群体已是一种被广泛接受的做法,尤其适用于识别个体行为机制与反应模式。例如 Aziz 等^[97]与 Saedi 等^[166]均采用学生样本分析个体出行行为反应。虽然此类样本设置可能限制研究结果的现实外推性,但其有助于在可控实验环境中排除干扰变量,从而更清晰地识别政策干预下的行为变化特征。同时,本研究样本规模在同类出行行为实验研究中具有较强的可比性,高于部分已有研究。例如, Vosough 等^[167]分别基于 66 名与 36 名受试者开展出发时间偏好调查, Pan 等^[168]使用 160 名参与者构建行为模型,均成功揭示了个体异质性对行为选择的影响。这表明,本研究样本规模与结构具有合理的代表性与分析有效性。



此外,为首要满足非理性 HVs 奖励影响下的出发时间选择特征的研究需求,实验设计未纳入 IBTDM 项目的宣传成本和渗透率等系统约束,及假设招募的所有受试者均为奖励项目的实际参与者,而不考虑渗透率和宣传成本等因素的影响。

4.3.1.2 实验框架

本实验框架的设计包括以下关键特征:

1) 采用长时追踪与可控实验相结合的设计框架,以确保数据的时序性和可靠性:受试者以天为轮次进行出发时间及拼车模式选择,每天仅可提交一次、不可回溯修改,减少随意性与回忆偏差,保证选择过程的自然性和充分性,从而提升数据可信度,有效评估奖励对促进受试者改变出发时间和出行方式的长时效果;

2) 引入互动性和信息反馈机制,以模拟真实场景中的出行选择过程:每一轮的出行结果由所有受试者的选择决定,并在下一轮选择开始之间反馈给受试者,这种交互与反馈机制有利于受试者从每一轮的反馈信息中学习并调整其出行行为,提升受试者参与的主动性与参与持续性;

3) 多维度出行选择框架:以往关于 IBTDM 的研究主要集中于出发时间选择或出行方式偏好等单一维度,在本实验中,受试者的多维度出行行为(包括出发时间和出行方式)被整合到统一框架中,更贴近真实奖励实施场景;

实验的具体流程如图 4.8 所示。




图 4.8 实验室实验流程

研究采用微信小程序平台开展实验。微信小程序平台凭借其友好的用户界面设计、强大的系统稳定性以及高效的交互体验,已成为当前开展大规模在线实验的理想工具。其技术特性不仅确保了实验操作的便捷性,还能够支持大量受

试者的同时在线参与，为本实验的顺利实施提供了可靠的技术保障。

为确保受试者能充分整合出行信息，做出最符合其心理预期的选择，实验过程中会给予受试者相应的信息反馈。实验界面和信息反馈界面如图 4.9 所示，主要反馈三类信息：①上一轮每个出发时间间隔的出行人数和拥堵状况，如图 4.9 (b) 中的柱状图所示，其中，柱状图颜色为红色表示拥堵，绿色表示不拥堵，柱状图颜色越深表示拥堵越严重；②当前累计的出行成本、奖励以及净出行成本，如图 4.9 (c) 中折线图以及折线图下方总结信息所示；③上一轮的结果，包括拼车是否成功、等待时间、出发和到达时间、排队情况、出行成本和获得的奖励金额，如图 4.9 (c) 中蓝色框内所示。每轮实验的出行结果由受试者的选择决定。在完成每一轮实验后，受试者都会收到全面的反馈信息，有助于他们对下一轮的出行方式和出发时间做出明智选择。



图 4.9 小程序实验界面。

为了保证实验的严谨性和公平性，制定规则如下：

①为严格控制在总预算约束内开展实验，并保证受试者参与长时实验的积极性，研究依据受试者净出行成本(即总出行成本与总奖励之差)的最终排名顺序，统一进行“酬劳奖励”兑换。须明确，此“酬劳奖励”为实验结束后发放给受试者的实质报酬，区别于实验中激励出行行为改变的虚拟奖励。“酬劳奖励”额度遵循梯度递增原则，即排名越靠前，所获金额越高。发放规则如表 4.6 所示。

表 4.6 “酬劳奖励”金额发放规则

排名	酬劳奖励/元	排名	酬劳奖励/元
前 1.8%	200	50%~75.8%	140
1.8%~8.1%	190	75.8%~91.9%	122
8.1%~24.2%	178	91.9%~98.2%	110
24.2%~50%	160	后 1.8%	100



②为激励受试者持续参与实验,确保实验数据的完整性和连续性,本研究设置了如下规则:首先,为应对受试者在实验过程中可能出现的轮次缺席情况,实验预先制定了统一的处理规则——缺席者的该轮出行成本将被设定为 205 元,即所有受试者的最高成本水平,且该规则已在实验开始前明确告知全体受试者。其次,针对数据缺失问题,当受试者未能在实验当天上传数据时,采用固定算法,基于全体受试者的出行选择分布,通过概率统计方法构建“随机人”模型,以替代缺席者提供必要的选择数据。最后,采用缺席惩罚规则——若受试者连续缺席两天,其最终奖励将减少 5%;若连续缺席三天,其最终奖励将减少 25%。

4.3.1.3 出行环境

瓶颈模型能够有效模拟出行者的行为动态,并复现排队形成与消散的过程,为研究提供了可靠的理论框架。本实验基于瓶颈模型,模拟了典型的通勤情境,用于计算受试者的出行选择结果,并评估奖励策略的实施效果。

实验场景具体设计如下:每天有 206 名受试者需要从同一居住地前往同一工作地点,途中需经过一条通行能力为 82 辆/小时的瓶颈路段,该路段的自由行驶时间为 20 分钟。受试者的出发时间窗口设定为 7:00 AM 至 9:30 AM,工作开始时间为 9:00 AM,早到或迟到均会产生相应的时间成本。实验设置的出发时间窗口较实际早高峰时段(如 7:00-9:00 AM)有所扩展,旨在通过提供更宽的时间选择范围来优化交通流分布,并有效引导出行者向非高峰时段转移。在出行方式选择上,受试者可在独自出行、作为拼车乘客或拼车司机三种模式中自主选择。

需要说明的是,由于在受试者招募过程中,同时具备驾照和私家车的受试者数量有限,本研究未对出行方式的选择设置限制条件。这一设计基于现实考量:在实际通勤场景中,无驾照或无私家车的上班族同样可能选择拼车出行。这种主体灵活性的实验设计方法广泛应用于行为研究中。例如, Aziz 等^[97]以及 Saedi 等^[166]采用的样本仅由同质学生组成。

本实验中,出行成本涵盖四个维度:行驶时间成本、早到成本、晚到成本及拼车匹配等待成本。其中,早到和晚到成本反映了受试者因早于和晚于期望到达时间到达工作地点而面临的经济成本(如停车费用、工资损失)、心理成本以及时间成本(如等待时间、工作效率损失)等。拼车乘客的单位行驶时间成本为 0.375 元/分钟($\alpha = 0.375$),由于需要承担额外的燃油费、车辆折旧费用,拼车司机以及独自出行司机的单位行驶时间成本为 0.75 元/分钟($\alpha = 0.75$)。迟到会面临工资损失,因而迟到成本往往显著高于早到成本,实验中单位早到成本为 0.375 元/分钟($\beta = 0.375$),单位迟到成本为 1.5 元/分钟($\gamma = 1.5$)。

实验遵循“先到先服务”原则,当受试者选择作为拼车乘客或者司机出行时,



系统会根据他们的出发时间顺序与相应的拼车司机/拼车乘客进行匹配，拼车等待时间上限为 10 分钟，单位等待成本为 0.4 元/分钟。具体而言，系统首先构建拼车受试者的“待匹配队列”，并按出发时间进行优先级排序。随后，系统为当前最高优先级的受试者在 10 分钟时间窗口内按顺序搜索潜在拼车伙伴：若匹配成功，则双方组成拼车对并移出队列；若匹配失败，则该受试者将独立出行。这一匹配流程迭代执行，直至队列清空，确保所有受试者均完成匹配尝试。


在成本计算方面，首先计算受试者的排队时间，随后整合匹配机制得出的匹配结果和等待时间，最终确定每位受试者的到达时间。在此基础上，依据公式(3.1)量化受试者的出行成本，值得注意的是，实验设计纳入了等待匹配时间的影响，最终受试者的总出行成本为公式(3.1)计算值与其等待成本之和。

4.3.1.4 实验流程


传统短时多轮实验需要受试者在一段时间内频繁做出出行选择，受试者往往会在接近结束时失去注意力，并且可能会做出不合理行为，无法保证数据质量^[98]。而本实验中，受试者每日做出出发时间和拼车模式选择，共进行 31 轮，实验持续一个月。因此，受试者无需匆忙做出决定，从而收集到更真实的行为数据^[100]。

实验包含三个阶段，旨在系统评估奖励机制对拼车及出发时间选择的综合影响。实验的第一阶段为期 10 天，作为对照组，此阶段不实施任何奖励策略，主要目的是收集基准出行数据。第二阶段持续 14 天，此阶段对成功拼车的司机和乘客实施特定的奖励策略（设计参考理性假设下的优化方案，具体奖励方案见图 4.10 (a) (b)，以分析奖励机制对拼车及出发时间行为的激励效应。第三阶段为期 7 天，此阶段引入了对拼车失败者的 4 元补偿机制（具体方案见图 4.10 (c) (d)），并整体下调了各个出发时间的奖励金额，这一设计旨在通过降低受试者的风险感知和经济成本，进一步引导受试者选择拼车，同时考察奖励金额调整对出发时间选择的影响。


在奖励方案设计上，实验充分考虑拼车等待的不确定性特征。当受试者选择拼车后，将经历 0-10 分钟的等待匹配时间，这一时间长度受到同阶段内其他受试者选择的影响。由于不同轮次中选择相同出发时间的受试者可能会面临不同的匹配等待时间、匹配结果和等待成本，为确保所有受试者的广义出行成本保持均衡，奖励方案特别纳入了等待匹配时间这一变量。具体而言，奖励金额将根据等待时间的不同在图 4.10 所示的红色和蓝色范围内进行动态调整，以此确保实验设计的科学性和结果的可靠性。




(a) 第二阶段拼车司机奖励方案



(b) 第二阶段拼车乘客奖励方案



(c) 第三阶段拼车司机奖励方案



(d) 第三阶段拼车乘客奖励方案

图 4.10 第二阶段和第三阶段对拼车司机和拼车乘客的奖励方案

4.3.2 奖励方案长时逐日效果分析

(1) 出发时间选择模式统计分析

实验于 2023 年 1 月 22 日正式启动, 持续 31 天。由于实验周期较长, 部分受试者中途退出, 经统计, 最终完成全部实验流程的受试者共计 194 名。通过微信小程序平台实时采集实验数据, 记录每位受试者每轮实验的拼车选择、出发时间及系统效能等关键指标, 共收集到 206 组有效实验数据, 累计数据点超过 12,000 个。原始数据经过标准化处理后, 可转换为结构化实验数据, 具体如表 4.7 所示。

表 4.7 采集实验数据样本

ID	轮次	出发时间	最终出发时间	延误	到达时间	出行模式	最终出行模式	出行成本	奖励
1	1	500	500	9.8	529.8	2	2	26.2	0
1	2	490	490	7.3	517.3	2	2	29	0
...	...	...	...	...	...	...	...	...	...
1	31	470	470	3.1	493.1	2	2	34.9	26.2
2	1	510	520	48.4	588.4	0	1	128	0
2	2	490	490	3.7	513.7	1	1	27.6	0
...	...	...	...	...	...	...	...	...	...
206	31	480	489	1.7	510.7	0	0	22.7	11.6

基于 31 轮实验收集的统计数据，本研究进行了系统性整理与分析，结果如图 4.11 所示。数据分析表明，受试者对迟到行为表现出极低的容忍度，具体表现为在所有实验轮次中，仅有极少数受试者选择在 8:40 AM 之后出发。通过对比分析发现，与未实施奖励机制的第一阶段相比，在引入奖励机制的第二、三阶段中，受试者的出发时间显著提前，实现了交通需求在时间维度上的有效再分配。这一行为模式的转变直接导致了人均出行成本的显著降低：绝大多数受试者的出行成本降至 45 元以下，其中第二阶段的平均出行成本为 33.06 元，较第一阶段的 54.34 元降低了 21.28 元；第三阶段的平均出行成本进一步降至 30.37 元，较第一阶段降低了 23.97 元。

从奖励投入产出比来看，第二阶段的人均奖励为 16.61 元，第三阶段为 18.04 元，投入产出比均大于 1（第二阶段：投入 16.61 元，收益 21.28 元；第三阶段：投入 18.04 元，收益 23.97 元）。这一结果表明，奖励机制不仅能够有效降低出行成本，而且具有显著的经济效益。值得注意的是，随着实验的推进，各阶段受试者的行为模式逐渐趋于稳定，这证实了在长时情境下，奖励机制对出行行为改善的正向激励效应具有持续性和稳定性。这些研究发现为 IBTDM 项目的开展提供了有力的实证支持。




图 4.11 三阶段中出发时间、出行成本、平均奖励箱型图

实验结束后，发放了一份调查问卷，以收集受试者的基本信息、策略及实验感受。研究通过问卷调查共收集了 168 份有效样本，问卷的统计分析结果如表 4.8 所示。受试者大部分为学生，从人口统计学特征来看，样本呈现出以下分布特征：性别构成方面，男性受试者比例略高于女性；教育程度方面，受试者以本科生为主体；年龄分布方面，样本主要集中在 18-25 岁区间；经济特征方面，大多数受试者的月收入水平分布在 1,000 元至 10,000 元之间。



第4章 非理性 HVs 出发时间选择行为分析与建模

表 4.8 受试社会经济学属性

属性	分类	数量
性别	0=男性	89
	1=女性	79
年龄	1=18 岁以下	2
	2=18-25 岁	101
	3=26-40 岁	25
	4=40-50 岁	31
	5=50 岁以上	9
教育	1=初中及以下	2
	2=中专及职高	33
	3=高中	14
	4=在读本科生	98
	5=本科及以上	21
家庭成员数	1=1	1
	2=2	8
	3=3	70
	4=3 人以上	89
月收入	1=低于 1,000 元	75
	2=1,001 元-2,500 元	26
	3=2,501 元-4,000 元	19
	4=4,001 元-5,500 元	20
	5=5,501 元-7,000 元	13
	6=7,001 元-10,000 元	8
	7=高于 10,000 元	7
私家车数量	1=有	131
	0=无	37
驾驶证	1=有	96
	0=无	72
驾龄	0=0 年	72
	1=1 年以下	33
	2=1-3 年	18
	3=3-5 年	11
	4=5 年以上	34
通勤天数	1=0	22
	2=1-2 天	6
	3=3-5 天	102
	4=6-7 天	38

此外,受试者对实验机制的认知水平显著影响奖励策略在改变出行行为方面的有效性。为系统评估受试者在实验不同阶段的理解程度,研究分别在实验过程



中和实验结束后进行了测验。测验结果显示，绝大多数受试者对实验机制的理解程度达到了3级或以上水平（采用5级量表），这一发现确保了实验数据能够准确反映受试者的实际出行选择。

为进一步探究受试者在拼车及出发时间选择机制，本研究在问卷中特别设计了相关量表条目，用于收集受试者的出行选择策略信息，具体结果如表4.9所示。受试者出行选择过程主要呈现两种模式：其一，大部分受试者倾向于基于实时路况反馈信息，选择出行成本最低的时段；其二，部分受试者表现出明显的奖励导向型特征，其选择行为主要受奖励机制驱动。

表 4.9 受试者拼车出行策略

策略	数量	百分比/%
和别人配对	37	21.51
根据前一天的路况图	132	76.74
根据奖励的多少	76	44.19
根据自己估计的成本最低方式	131	76.16
其他	4	2.33

（2）奖励对出行行为的长时效应分析

为探究奖励措施对出行行为的长时影响及其对交通系统的潜在效应，研究对每一轮的实验结果进行了评估。评估指标体系包括个人平均延误时间、个人平均出行成本以及拼车率等关键指标。其中，“平均个人延误时间”和“平均个人出行成本”分别指代某一实验轮次中所有受试者的平均延误时间和出行成本，个体出行成本根据公式（3.1）中的广义出行成本定义计算得出。此外，研究还深入分析了不同奖励方案下受试者拼车选择的逐日变化特征。

图4.12展示了受试者在31轮实验过程中的平均个人延误时间和平均个人成本的变化趋势。数据分析显示，在奖励机制的作用下，两项指标均呈现显著下降趋势。具体而言，与第一阶段相比，第二阶段的平均个人延误时间减少了59.4%，平均个人成本降低了39.3%；在第三阶段引入拼车失败补偿机制后，两项指标进一步改善，平均个人延误时间较第一阶段减少70.4%，平均个人成本降低43.9%。

图4.13呈现了31轮实验中拼车率（选择拼车的受试者比例）和拼车成功率（成功完成拼车匹配的受试者比例）的演变过程。实证结果表明，奖励措施对提升拼车参与度具有显著作用。与第一阶段相比，第二阶段的拼车率平均提升33.9%，成功率提高64.7%。而第三阶段引入的补偿机制进一步强化了这一效果：拼车率较第一阶段提升47.2%，成功率提高82.3%。这一发现证实，对拼车失败者实施补偿措施能够产生显著的投资回报，有效提升奖励项目的整体效能。



综上所述,本研究证实奖励机制与补偿机制的结合是促进出行行为改善的有效策略,不仅能够显著降低个人出行延误和成本,同时也有助于优化整体交通系统效能。




图 4.12 206 名受试者人均出行成本和人均延误变化趋势




图 4.13 206 名受试者拼车参与率与成功率变化趋势

4.3.3 非理性 HVs 个体差异表现及影响因素分析

在 IBTDM 实施后,识别非理性 HVs 在项目参与度、行为依从性及出行选择策略等方面的差异性表现,对于分析其出行选择特征、优化宣传策略的有效性和提升预算配置效能具有重要的实践意义。

4.3.3.1 参与度差异

既有研究表明,IBTDM 项目的用户参与度呈现显著的分化特征^[161]:部分用户表现出持续稳定的参与模式,而另一部分用户则呈现间歇性参与或快速流失的特征。鉴于宣传成本是 IBTDM 项目运营的重要支出项,识别并锁定具有高参与



倾向的用户群体，并据此制定针对性营销策略，对于降低用户流失率、确保项目可持续性和优化营销资源配置至关重要。

为量化评估用户参与度，在为期 31 天的拼车实验中，研究通过追踪受试者在实验周期内的参与轮次，构建参与度的衡量指标。图 4.14 显示了 206 名受试者的参与轮次分布。数据显示，136 名受试者（占总样本的 66.02%）完成了全部 31 轮实验，展现出高度持续性的参与行为；58 名受试者（占比 28.15%）完成了 28-30 轮实验，仅存在个别轮次的缺席，显示出较高的参与度；而 12 名受试者（占比 5.83%）的参与轮次低于 25 轮即退出实验，表现出明显的流失倾向。基于参与度的差异，本研究将样本划分为三类群体：高参与度群体（31 轮）、中高参与度群体（28-30 轮）和低参与度群体（ ≤ 25 轮）。值得注意的是低参与度群体中 83.33% 的个体未完成实验后的问卷调查，可能对研究结论的普适性产生影响。因此，本研究将重点关注高参与度和中高参与度群体的行为特征，其更能代表项目的目标核心用户群体。为进一步降低数据缺失偏差，未来研究可考虑在实验中期增设问卷调查环节，以获取更全面的受试者行为数据。




图 4.14 受试者参与实验轮次分布

基于调查问卷数据，本研究采用逻辑回归模型对高参与度群体与中高参与度群体的特征差异进行了深入分析。在回收的 168 份有效问卷中，共有 164 份问卷符合分析标准，其中高参与度样本 121 例（占比 73.78%），中等参与度样本 43 例（占比 26.22%）。根据“事件数-变量数”准则（Events per Variable, EPV），为确保模型稳健性，每个自变量对应的事件数应保持在 5-20 之间^[169-171]。本研究样本量（包含 5 个自变量）满足这一统计要求。模型拟合优度检验结果显示，Wald 卡方检验统计量（ χ^2 ）对应的 p 值（ $Prob > \chi^2$ ）趋近于零，表明模型具有统计意义。各变量的具体回归系数及其显著性水平详见表 4.10。



表 4.10 高参与度及中等参与度受试者特点分析结果

		Coef.	Std. Err.	p
性别		0.618	0.767	0.135
月收入	1000 元以下			
	1000-7000 元	0.273	0.613	0.558
	7000 元以上	1.671	4.810	0.065*
私家车数量		0.670	0.925	0.157
驾照		-0.819	0.194	0.062*
第二阶段理解程度		0.294	0.270	0.145
第三阶段理解程度		0.642	0.409	0.003**
常数		3.283	0.043	0.004**

注：显著性水平 ** $p<0.05$; * $p<0.1$

分析表明，实验参与度与以下三个关键变量呈现显著相关性：①月收入水平；②驾照持有状态；③对实验机制的理解程度。具体而言，无驾照但具备较高实验机制理解能力且月收入超过 7000 元的受试者表现出显著更高的实验参与度（ $p<0.01$ ）。具体原因可能为：

首先，实验允许受试者自由选择包括拼车乘客与司机在内的出行模式，为无驾照受试者提供了体验私家车出行优势（如舒适性与便利性）的机会。这种出行模式备选方案的扩展增强了 IBTDM 项目的吸引力，从而提高了该群体的参与积极性与持续性。

其次，对实验机制有深入理解的受试者能够通过优化出行行为选择策略实现奖励收益的最大化。同时，完成实验后获得的奖励进一步强化了其持续参与动机，形成了正向的行为强化循环。

最后，高收入群体（月收入>7000 元）表现出更强的实验参与度，可能源于其对实验过程中累积成本、奖励波动等信息的敏感性较低，从而降低了中途退出的风险。这一发现与前景理论中关于损失规避程度差异的假设相一致，即高收入个体的损失厌恶系数相对较低，其对潜在损失的容忍度较高。

4.3.3.2 行为依从度差异

IBTDM 项目的核心目标是通过奖励机制引导用户调整拼车选择或出发时间，从而有效缓解交通拥堵。基于这一目标，研究构建了行为依从度的双维度评估框架：其一是出发时间调整幅度，用于衡量受试者在奖励作用下原始出发时间调整程度；其二是拼车参与率提升程度，用于评估受试者对拼车的采纳水平。

在出发时间调整维度上，提前与延后出发两种调整方向对缓解早高峰拥堵具有等效作用，因此研究重点关注出发时间调整的绝对幅度，而非具体方向。在拼车率维度上，鉴于拼车行为对降低道路负荷率的显著贡献，拼车率提升程度成为



研究的另一个关键目标。基于上述维度，研究将在奖励措施下表现出显著出发时间调整或拼车率提升的受试者界定为高依从度群体。

基于此，本研究将进一步探究高依从度群体的行为特征及其影响因素。具体而言，研究通过计算无奖励阶段与奖励阶段平均出发时间差（以分钟为单位）的绝对值，控制了个体选择波动的影响，从而准确量化出发时间调整程度；同时，考虑到第三阶段引入的补偿机制，研究分别计算了三个阶段拼车率的变化，以系统捕捉奖励方案调整对行为依从度的影响。

由于实验的长时性，受试者可能出现轮次缺失或中途退出的情况，导致数据出现异常值，进而影响回归分析准确性。因此，本研究采用稳健回归，通过迭代加权最小二乘法对数据点进行权重分配，并在每次迭代中修正回归系数直至权重变化收敛，从而有效降低异常值对估计结果的干扰。使用 G*Power 软件计算得出采用多元线性回归模型所需最小样本量为 74,168 人的样本量满足统计精度要求。模型拟合结果如表 4.11-表 4.13 所示，其中 F 检验的 p 值（ $Prob > F$ ）显著低于 0.05，表明模型具有统计学意义，能够有效解释变量之间的关系。

表 4.11 无奖励和有奖励阶段，受试者出发时间变化影响因素分析

		Coef.	Std. Err.	t	p
性别		1.522	1.238	1.23	0.221
第三阶段理解程度		0.881	0.686	1.28	0.201
月收入	1000 元以下				
	1000-7000 元	-3.474	1.592	-2.18	0.031**
	7000 元以上	-0.919	2.409	-0.38	0.703
周通勤天数 ≥ 3		-3.970	1.669	-2.38	0.019**
驾龄	0 年				
	0-3 年	-0.806	1.603	-0.5	0.616
	3 年以上	2.203	1.516	1.45	0.148
教育水平 $\geq$ 本科生		2.179	1.320	1.65	0.101
常数		8.461	5.016	1.69	0.094*

注：显著性水平 ** $p < 0.05$; * $p < 0.1$



第4章 非理性 HVs 出发时间选择行为分析与建模

表 4.12 第一阶段和第二阶段之间受试者拼车率变化的影响因素

		Coef.	Std. Err.	t	p
性别		0.041	0.043	0.94	0.347
家庭成员数		0.037	0.034	1.10	0.271
月收入	1000 元以下				
	1000-7000 元	0.067	0.084	0.80	0.427
	7000 元以上	0.310	0.106	2.92	0.004**
周通勤天数 ≥ 3		-0.102	0.058	-1.76	0.080*
教育水平 $\geq$ 本科生		-0.039	0.047	-0.84	0.404
年龄	25 岁以下				
	25-40 岁	-0.067	0.086	-0.78	0.438
	40 岁以上	-0.154	0.089	-1.72	0.087*
常数		0.277	0.180	1.54	0.125

注：显著性水平 ** $p < 0.05$; * $p < 0.1$

表 4.13 第二阶段和第三阶段之间受试者拼车率变化的影响因素

		Coef.	Std. Err.	t	p
月收入	1000 元以下				
	1000-7000 元	0.049	0.030	1.64	0.102
	7000 元以上	0.014	0.038	0.38	0.705
驾龄	0 年				
	0-3 年	0.011	0.020	0.54	0.588
	3 年以上	-0.020	0.020	-1	0.319
年龄	25 岁以下				
	25-40 岁	-0.062	0.034	-1.85	0.067*
	40 岁以上	-0.097	0.036	-2.67	0.008**
第二阶段理解程度		-0.012	0.008	-1.5	0.135
第三阶段理解程度		-0.023	0.009	-2.54	0.012**
_cons		0.228	0.045	5.04	0.000**

注：显著性水平 ** $p < 0.05$; * $p < 0.1$

结果（表 4.11-表 4.13）表明，月收入、通勤频率、年龄及对奖励机制的理解程度是影响受试者行为依从性的关键因素。具体而言，低频通勤者（每周 < 3 天）表现出更强的出发时间调整倾向，而中等收入群体（1000-7000 元）相较于低收入群体（ < 1000 元）的出发时间调整意愿较低。在第二阶段，高频通勤者（每周 > 3 天）和年长群体（ > 40 岁）的拼车参与率显著下降，而高收入群体（ > 7000 元）比低收入群体表现出更强的出行模式转换倾向。此外，对实验机制有深入理解的中高龄受试者（ > 25 岁）在第三阶段的拼车参与率较第二阶段显著提升。

研究发现，不同收入群体在出行行为调整策略上呈现系统性差异：低收入群体倾向于通过出发时间调整来规避高峰拥堵，而高收入群体则更偏好出行模式转



换。这一现象可通过风险偏好理论解释：在第二阶段，拼车选择面临奖励收益与延误风险的不确定性，而低收入群体通常表现出更强的风险规避倾向^[172, 173]，因此选择通过时间调整来降低出行成本。这一发现对 IBTDM 项目的目标群体定位具有重要启示：管理部门应根据政策目标（时间调整或模式转换）锁定目标人群，制定针对性推广策略。

此外，低频出行群体表现出更高的行为依从性，这源于其较低的出行惯性与转换成本。在第三阶段，年轻和对实验机制理解有限的群体具有更高的拼车参与率，这可能与年轻群体对新事物的接受度较高，以及对创新补偿机制的较强适应性有关。这些发现为制定基于用户特征的个性化奖励策略提供了重要依据，有助于优化奖励机制设计并提升项目的整体实施效果。

4.3.3.3 出行策略差异

（1）个人拼车策略

心理认知因素在非理性 HVs 拼车选择中具有重要作用，不同个体在出行选择过程中表现出个性化的目标导向差异。为深入探究奖励机制对出行行为的作用机制，本研究在实验结束后实施了出行选择策略问卷调查，结果如表 4.14 所示。受试者主要采用基于历史信息的成本最小化策略：即通过分析前一日道路通行状况，估算预期出行成本并选择最优方案。

表 4.14 受试者拼车出行策略

策略	数量	百分比
和别人配对	37	21.51%
根据前一天的路况图	132	76.74%
根据奖励的多少	76	44.19%
根据自己估计的成本最低方式	131	76.16%
其他	4	2.33%

基于上述研究结果，受试者当前轮次的出行选择主要受上一轮次的反馈信息、经验积累及个人偏好的综合影响。这一行为模式符合适应性预期理论（Adaptive Expectations Theory），即出行者倾向于将前一轮次的状态作为当前出行选择的参考基准，假设前一轮的状态会延续到当前轮次。换言之，出行者在当前轮次做出出行选择时的期望结果，与其上一轮相同选择的实际结果之间存在显著关联。

具体而言，问卷调查数据表明，受试者在做出出行选择时主要参考上一轮的关键指标：平均奖励收益、出行成本、延误程度、各时段与期望到达时间的偏差，以及特定时段的出行人数。这些指标共同构成了受试者的出行选择参考框架。

为识别受试者的策略模式，本研究采用 K-Means 聚类算法对 31 轮实验数据



进行分类。通过最小化样本点与聚类中心之间的平方误差和，将数据集划分为 K 个聚类。基于策略可解释性与分类效果的综合评估，确定最优聚类数 $K=4$ 。

进一步地，深入分析四个聚类中心点特征，可识别四类出行策略：第一类以最小化到达时间偏差为目标；第二类倾向于通过提前出发（约 1 小时）来最大化奖励收益；第三类偏好选择出行人数密集时段出发；第四类则愿意通过推迟出发（约 0.5 小时）来获取更高奖励。综上所述，四种典型的出行选择策略特点如下：

① I 类策略：“时间刚性”型（占比 22.9%）

该类策略以准时到达为首要目标，表现出强烈的出行惯性。即使面对显著的经济奖励和拥堵缓解机会，仍倾向于维持既定的出发时间。由于其行为依从度较低，倾向于采取此类策略的群体并非 IBTDM 项目的核心目标人群。

② II 类策略：“奖励敏感”型（占比 22.9%）

该类策略愿意通过显著提前出发时间来最大化奖励收益，对奖励措施具有高度敏感性，同时确保工作准时性。由于其奖励敏感性较强，倾向于采取此类策略的群体是出发时间调整类 IBTDM 项目的理想目标人群。

③ III 类策略：“出行惯性”型（占比 49.3%）

该类策略以维持其固有出行行为为目标，较难在奖励措施下调整出发时间。值得注意的是，该类策略往往导致选择出行需求密集时段出发，因而拼车成功的概率较高，倾向于采取此类策略的群体是拼车类 IBTDM 项目的潜在优质用户。

④ IV 类策略：“延误容忍”型（占比 5%）

该类策略以奖励最大化和成本最小化为主要目标，表现出对延误的异常高容忍度。然而，由于该类群体占比过低，针对其制定专项奖励方案和宣传方案的经济价值有限，因此不宜作为 IBTDM 项目的主要服务对象。

综上所述，II 类和 III 类策略群体是 IBTDM 项目的重点目标人群。相比之下，IV 类策略群体由于规模不足，不宜作为主要目标。

（2）不同策略受试者特征分析

基于对受试者策略模式的深入分析，研究发现受试者的出行选择并非遵循单一固定模式，而是在多维反馈信息的驱动下呈现出显著的逐日演化特征。

为探究受试者的策略偏好，本研究采用定量分析方法，计算了每位受试者在 31 轮实验周期（或实际参与轮次）中采用 I-III 类策略的频率分布，并构建分数回归模型以揭示其与社会经济特征的内在关联。考虑到分数对数模型包含 5-7 个解释变量，168 人的样本量完全满足“事件数-变量数”（EPV）在 5-20 之间的统计要求，确保了多变量分析的可靠性。主要回归结果见表 4.15、表 4.16 和表 4.17。通过模型拟合优度检验，Wald 卡方统计量对应的 p 值（ $Prob > \chi^2$ ）显著低于 0.05，证实模型具有统计学意义。



第4章 非理性 HVs 出发时间选择行为分析与建模

表 4.15 受试者选择 I 类策略的比例的影响因素

		Coef.	Std. Err.	z	p
月收入	1000 元以下				
	1000-7000 元	-0.678	0.297	-2.28	0.022**
	7000 元以上	-0.319	0.524	-0.61	0.543
私家车数		-0.292	0.279	-1.05	0.295
周通勤天数 ≥ 3		0.729	0.266	2.74	0.006**
教育水平 $\geq$ 本科生		0.246	0.252	0.97	0.330
第二阶段理解程度		-0.445	0.125	-3.57	0.000**
第三阶段理解程度		-0.198	0.133	-1.49	0.135

注：显著性水平 ** $p < 0.05$; * $p < 0.1$

表 4.16 受试者选择 II 类策略的比例的影响因素

		Coef.	Std. Err.	z	p
年龄	25 岁以下				
	25-40 岁	0.705	0.606	1.16	0.245
	40 岁以上	0.838	0.639	1.31	0.190
月收入	1000 元以下				
	1000-7000 元	-0.660	0.629	-1.05	0.295
	7000 元以上	0.064	0.675	0.09	0.925
周通勤天数	0-2 天				
	3-5 天	-0.401	0.356	-1.13	0.260
	6-7 天	-1.220	0.454	-2.68	0.007**
教育水平 $\geq$ 本科生		-0.497	0.248	-2.00	0.045**
第三阶段理解程度		0.036	0.093	0.39	0.696

注：显著性水平 ** $p < 0.05$; * $p < 0.1$

表 4.17 受试者选择 III 类策略的比例的影响因素

		Coef.	Std. Err.	z	p
年龄	25 岁以下				
	25-40 岁	-0.650	0.556	-1.17	0.242
	40 岁以上	-1.336	0.542	-2.46	0.014**
家庭成员数		-0.160	0.146	-1.09	0.274
月收入	1000 元以下				
	1000-7000 元	1.421	0.521	2.73	0.006**
	7000 元以上	0.120	0.617	0.2	0.845
周通勤天数 ≥ 3		-0.309	0.272	-1.14	0.256
第二阶段理解程度		0.258	0.107	2.42	0.016**

注：显著性水平 ** $p < 0.05$; * $p < 0.1$

表 4.15 的回归结果显示，月收入、通勤频率及对实验机制的理解程度显著影响 I 类策略的采用比例。高频通勤者（每周 >3 天）和对实验机制理解有限的个体更倾向于采用 I 类策略。这一现象可以从两方面进行解释：首先，高频通勤者



具有更强的出行惯性，其调整出发时间和出行模式的成本较高；其次，对实验机制认知不足的群体难以准确评估行为调整带来的潜在收益，从而降低了改变出行行为的动机。

表 4.16 的分析表明，通勤频率和教育程度是影响 II 类策略采用比例的关键因素，而实验机制理解程度的影响未达到统计显著性。具体而言，高频通勤者（每周>3 天）和高学历群体（本科及以上）采用 II 类策略的概率较低，即较少选择提前出发以获取奖励。

表 4.17 的结果显示，年龄、月收入和对实验机制的理解程度对 III 类策略的采用比例具有显著影响。其中，对实验机制有深入理解的群体更倾向于采用 III 类策略，这源于其能够准确评估拼车成功概率与奖励收益的关联。此外，中等收入（1000-7000 元）的年轻群体更倾向于选择 II 类策略，这一发现与拼车率差异性分析的结果相互印证。

因此，为提高奖励预算收益，建议管理部门重点针对倾向于采用 II 类和 III 类策略的群体制定宣传方案，以提高奖励项目参与人群的行为依从度，并通过示范效应带动其他群体的参与积极性。

4.3.4 出行行为长时逐日演化分析

Tian 等^[98]的研究表明，在可交易路票实验中，非理性 HVs 表现出显著的学习效应，即能够通过经验积累和信息反馈机制不断优化其出行选择策略。由此推测，在 IBTDM 项目中，非理性 HVs 可能基于多轮实验结果逐步调整其出行选择。然而，该学习效应在以奖励机制促进拼车和出发时间改变的情境中是否存在及其强度，仍缺乏验证。

为深入探究信息反馈机制下非理性 HVs 的学习效应与出发时间及拼车模式选择演化规律，研究构建了面板数据模型，探究了影响受试者逐日出行行为（包括拼车选择与出发时间调整）的关键因素，为优化 IBTDM 信息反馈机制提供依据。

1) 拼车选择行为影响因素分析

研究将每轮实验中的出行模式选择设定为二元因变量（0 表示单独出行，1 表示选择作为拼车乘客或司机参与拼车），并选取实验信息反馈系统中的多维度关键指标作为自变量，包括累积奖励金额、累积出行成本、拼车成功率、拼车等待时间以及延误时间等指标。为准确捕捉出行行为的逐日演化特征，研究依次构建了混合回归模型、固定效应模型和随机效应模型进行对比分析。

F 检验结果表明，固定效应模型相较于混合回归模型具有更优的拟合效果，



证实了个体差异性的存在。为进一步验证个体效应的显著性，研究实施了豪斯曼检验（Hausman test），检验结果（表 4.18）显示 p 值为 0.000，强烈拒绝随机效应模型的原假设，从而确认了固定效应模型的适用性。基于上述统计检验结果，本研究最终采用固定效应框架下的广义最小二乘法（GLS）回归模型进行参数估计，具体回归结果详见表 4.19。

表 4.18 豪斯曼检验的估计结果

	(b)	(B)	(b-B)	$\sqrt{\text{diag}(V_b-V_B)}$
	FE	RE	Difference	S.E.
上一轮拼车是否成功	0.066	0.153	-0.086	0.004
上一轮拼车等待时间	0.000	0.000	0.000	0.000
上一轮的延误	0.001	-0.001	0.002	0.000
累计奖励	-0.001	0.000	-0.001	0.000
累计成本	0.001	0.000	0.001	0.000
常数	0.451	0.794	-0.343	0.032
$\chi^2(6) = (b-B)[(V_b-V_B)^{-1}](b-B) = 504.01$ Prob > $\chi^2 = 0.0000$ (V_b-V_B is not positive definite)				

表 4.19：固定效应 GLS 回归结果

	Coef.	Std. Err.	z	p
上一轮拼车是否成功	0.066	0.021	3.21	0.002**
上一轮拼车等待时间	0.000	0.000	-0.84	0.401
上一轮的延误	0.001	0.001	1.03	0.305
累计奖励	-0.001	0.000	-5.59	0.000**
累计成本	0.001	0.000	6.3	0.000**
_常数	0.451	0.072	6.28	0.000**

注：显著性水平 ** $p < 0.05$; * $p < 0.1$

在每一轮中，受试者的拼车选择主要受到上一轮拼车匹配结果、累积奖励和累积成本三个关键变量的显著影响（ $p < 0.01$ ），而与拼车等待时间的相关性未达到统计显著性水平（ $p > 0.05$ ）。

具体而言，当受试者在上一轮成功实现拼车匹配后，其后续选择拼车的概率显著提升（ $\beta = 0.324, p < 0.01$ ）。这种行为持续性可归因于成功拼车带来的双重正向反馈：其一是直接的经济收益，包括出行成本的显著节约和奖励获取；其二是间接的心理收益，如拼车认同性提高和出行体验改善。此外，研究发现累计奖励较低且出行成本较高的受试者表现出更强的拼车意愿（ $\beta = -0.217, p < 0.01$ ），这一现象可通过前景理论（Prospect Theory）中的损失规避机制进行解释：该类受试者倾向于通过拼车行为改善其在群体中的相对收益排名。这一发现强调了奖



励措施和相对收益排名显示对促进出行行为改善的重要性。

基于上述实证发现，本研究为 IBTDM 部门提出了以下优化建议：首先，建立拼车伙伴预匹配数据库，通过智能算法提高匹配效率和匹配成功率；其次，设计信息反馈界面，实时展示可匹配的司机-乘客数量及预期等待时间，有效降低信息不对称性；最后，优化奖励反馈机制，通过可视化方式突出显示拼车带来的成本节约效应与相对收益排名，强化对受试者的行为激励。

2) 出发时间选择行为影响因素分析

豪斯曼检验(Hausman test)结果显示不存在显著的个体随机效应($p > 0.05$)，因此研究采用固定效应框架下的广义最小二乘法(GLS)回归模型进行参数估计。模型估计结果如表 4.20 所示。

表 4.20 固定效应 GLS 回归结果

	Coef.	Std. Err.	z	p
上一轮拼车是否成功	-2.412	0.756	-3.19	0.001*
上一轮拼车等待时间	0.005	0.006	0.79	0.430
上一轮的延误	0.366	0.085	4.33	0.000*
累计奖励	-0.027	0.008	-3.26	0.001*
累计成本	0.018	0.004	3.97	0.000*
常数	472.821	3.242	145.85	0.000*

在每轮实验中，受试者的出发时间选择受到多重因素的显著影响，包括上一轮拼车匹配结果、延误情况、累计奖励和累计成本等关键变量。具体而言，当受试者在上一轮遭遇拼车失败时，其倾向于基于本轮各时间段的出行人数分布信息调整出发时间($\beta = 2.412, p < 0.01$)。此外，在上一轮经历严重延误的个体表现出显著的时间推迟倾向($\beta = 0.366, p < 0.01$)，以规避潜在的延误风险；而累计奖励较低($\beta = -0.027, p < 0.01$)且出行成本较高($\beta = 0.018, p < 0.01$)的受试者则倾向于选择提前出发。这种行为差异源于出发时间选择对延误成本与出行成本的相反作用机制：时间推迟虽可降低延误概率，但会导致出行成本呈现边际递增趋势，从而形成受试者复杂的出行选择权衡过程。

上述研究结果表明，IBTDM 部门可以实施基于用户画像的个性化出发时间推荐策略来提升 IBTDM 项目的实施效果。具体而言，建议构建一个多维分类指标体系，该体系整合累计成本/奖励、拼车成功率及延误历史等关键行为指标，从而将 IBTDM 项目用户划分为具有不同行为特征的群体。在此基础上，基于实时路网通行能力数据，为具有不同行为特征的用户群体提供个性化出发时间建议。这种个性化推荐机制通过调节出发时间分布实现交通流时空均衡，能够有效缓解系统拥堵，并辅助非理性 HVs 做出更优选择，提升个体出行效用。



综上所述, IBTDM 管理部门可以通过以下措施优化项目: 首先, 构建智能化的拼车搭档预匹配机制, 通过提升匹配成功率增强用户粘性和积极性; 其次, 强调奖励措施的成本补偿机制, 提升拼车模式的吸引力; 最后, 实施基于用户画像的出发时间推荐系统, 通过协调个体出行选择实现系统最优。上述改进措施有助于提升 IBTDM 效能, 为智能交通管理实践创新提供新路径。

4.4 非理性 HVs 逐日出发时间选择预测模型

为了刻画非理性 HVs 出发时间选择行为的多样性和不确定性特征, 传统理论方法通常基于人口细分假设, 对复杂行为进行简化建模。然而, 这类方法存在显著局限性: 首先, 难以有效纳入个体偏好、约束条件以及行为模式的多样性; 其次, 过度简化导致无法完整刻画个体出发时间选择过程的复杂性; 最后, 计算复杂度随研究规模呈指数增长, 易导致系统性偏差。

相较而言, 数据驱动方法不依赖先验理论假设, 通过直接学习观测数据中的潜在模式, 能更准确地捕捉行为本质特征及其逐日动态演化规律。特别是深度学习框架, 其端到端特征学习机制, 降低了对人工特征工程的依赖, 强大的非线性建模能力可有效处理高维数据中的噪声与异常值, 在出行行为不确定性建模方面具有显著优势。

基于上述方法论优势, 本研究将基于实验采集的动态、个体差异性数据, 系统评估神经网络、LSTM 和 Transformer 三种架构在非理性出发时间选择预测中的性能表现, 以构建非理性 HVs 的出发时间选择行为预测模型。

4.4.1 数据模型构建与编码

(1) 数据预处理

本研究基于第 4.3 节实验室实验所采集的原始数据, 在预处理阶段发现存在两类典型的数据质量问题: 一是实验受试者在特定轮次的缺席或提前终止实验导致的样本缺失, 二是问卷调查中部分特征值的遗漏。

为确保数据质量, 研究采用系统化的数据清洗流程: 首先剔除受试者缺席轮次的记录, 其次删除含缺失值的问卷条目, 最终通过唯一标识符——受试者的微信 id——实现实验观测数据与问卷数据的精确匹配。此外, 为更全面解析非理性 HVs 的出发时间偏好及其在奖励影响下的出发时间选择机制, 本研究整合了实验全周期(第一至第三阶段)数据作为分析样本。

基于 4.2 节和 4.3 节的数据分析结果, 本研究识别并提取了影响非理性 HVs



出发时间选择的关键预测变量作为输入。输入数据主要划分为两类：第一类是非理性 HVs 的个体层面数据，包括用户的社会人口统计学特征、累积经济指标（每轮实验后计算的累计个人出行成本与累计奖励）以及用于表征出行行为惯性的之前轮次的出发时间选择；第二类是全局数据，涵盖早高峰时段内实施的奖励方案分布特征，以及系统在每轮实验开始时反馈的上一轮次的拥堵分布数据。

基于上述数据处理流程，本研究构建的结构化数据集包含 5,052 条有效观测样本，为后续建模分析提供了数据基础。每条观测记录由多维特征向量和决策变量组成：在特征向量方面，整合了非理性 HVs 的社会人口统计学特征（涵盖性别、年龄、收入水平、家庭车辆保有量、家庭规模、驾驶资格、教育程度、每周通勤频率及实验认知程度等 9 个维度）、行为经济学变量（累计奖励金额与出行成本）、奖励方案参数（当期实施的奖励方案）以及系统状态指标（上一实验轮次的拥堵分布模式）；在决策变量方面，记录了非理性 HVs 在当前实验轮次中的出发时间选择。

（2）数据特征编码

对于全局数据，为了能够有效区分全局信息序列中不同时间位置的元素，研究对输入的全局数据（包括早高峰时段内的奖励分布数据以及系统反馈的拥堵分布数据）进行了位置编码。位置编码通过为输入数据序列中的每个时间位置分配唯一的编码向量，从而将时序信息嵌入到输入数据中，确保模型能够识别并利用序列中的时序模式。

对于个体特征数据，由于问卷调查数据获得的是区间信息，因此将得到的社会人口统计学特征采用独热编码（One-hot Encoding）映射为高维稀疏向量；而对于累积奖励、出行成本等连续型行为经济指标，则进行标准化处理以消除量纲影响。

（3）滑动采样

为满足 LSTM 和 Transformer 等序列建模算法的输入要求，本研究设计了一种基于滑动窗口的时序数据采样方法。具体而言，采用固定长度为 3 的滑动窗口对用户实验序列进行遍历采样，采样步长设置为 1 以保证时序特征的连续性。考虑到实验过程中存在用户中途退出或部分轮次缺失的情况，算法首先按照用户 ID 对实验记录进行分组整理，构建每个用户的完整参与序列。在采样过程中，当检测到非连续实验轮次时，系统自动终止当前窗口并重新初始化采样起点，从而确保每个训练样本都包含连续三轮完整的实验数据。具体步骤见图 4.15。该采样机制通过智能容错处理有效解决了数据稀疏性问题，最终生成了 4,547 组的时序训练样本。




图 4.15 基于固定时间窗的滑动采样

通过上述数据处理流程，研究构建了输入-输出数据集，接下来采用三类机器学习模型进行预测性能评估。

4.4.2 不同方法效果对比

研究分别应用神经网络、LSTM 和 Transformer 架构进行模型训练，对三种深度学习模型的出发时间预测的平均绝对误差 (Mean Absolute Error, MAE) 关键评价指标进行系统的定量比较分析，结果如图 4.16 所示。




图 4.16 三种深度学习方法平均绝对值误差 (MAE) 曲线

三种模型的性能对比结果显示:Transformer 模型在训练集和测试集上均展



现出卓越的预测性能，其在训练集和测试集上的 MAE 分别为 8.425 和 8.090，显著优于神经网络模型（13.446/14.885）和 LSTM 模型（35.123/15.670）。具体而言，Transformer 模型在训练集上的预测误差较 NN 与 LSTM 模型分别降低了 37.3%和 48.3%，在测试集上分别降低了 45.7%和 48.4%，整体性能提升均超过 35%。同时如图 4.16 所示，在训练过程中 Transformer 模型表现出优异的收敛特性，其收敛速度较 LSTM 模型提升约 10 倍。因此本研究选择 Transformer 架构作为核心预测模型，以保证预测精度和计算效率。

4.5 本章小结

本章基于 IBTDM 项目实践经验，通过问卷调查与实验室实验方法，采集了非理性 HVs 多样化奖励策略偏好数据及逐日出发时间选择行为数据，并系统识别其影响因素，进而构建了非理性 HVs 出发时间选择行为预测模型。主要结论如下：

（1）在多样化奖励策略偏好方面，依托高德平台开展问卷调查获得非理性 HVs 奖励策略偏好数据集，并采用结构方程模型分析影响因素。研究发现：公共交通倾向性、月收入 and 出行天数是影响调整出发时间奖励策略接受度的前三大主要因素；公共交通倾向性、私家车数量和 OD 组合是影响改变上班出行方式策略接受度的三大主要因素。基于此，可将偏好公共交通、低收入、高学历、无私家车的女性群体作为 IBTDM 重点推广对象。

（2）在出发时间选择行为逐日演化方面，开展为期 31 天的交互式实验室实验，采集了奖励作用下 206 名非理性 HVs 的出发时间选择逐日演化数据，并采用面板回归、聚类分析等方式识别其影响因素。结果表明：非理性 HVs 的出发时间选择受到月收入水平、驾照持有状态、对实验机制的理解程度、通勤频率、年龄和教育程度的显著影响。基于此，研究提出目标群体推广策略与奖励机制：1）在推广初期，优先覆盖高收入、高理解度的年轻群体；2）在政策成熟阶段，逐步扩展至低收入、有车老年群体；3）优化信息反馈机制，以增强非理性 HVs 对奖励策略目标的认知与参与积极性。

（3）基于采集的动态出发时间选择数据及分析结果，构建非理性 HVs 出行行为预测变量体系，并分别采用神经网络、长短期记忆网络和 Transformer 三种深度学习模型对其出发时间选择进行建模。以逐日出发时间预测准确率为指标评估模型性能，结果表明，Transformer 模型在逐日出发时间预测准确度上相较于其他两类模型提升 35%以上，收敛速度提升近 10 倍。



第5章 异质主体出发时间选择行为仿真与奖励方案优化

本章通过整合理性 CAVs 和 HVs（第 3 章内容）与非理性 HVs（第 4 章内容）在奖励影响下的出发时间选择机制研究成果，引入非完全信息条件下非理性 CAVs 出发时间选择特征，构建涵盖三类主体的仿真框架并据此优化奖励方案。首先，采用基于智能体的仿真方法，利用大语言模型的语义理解与协同选择能力模拟非理性 CAVs 的认知推理过程，刻画三类主体的出发时间选择模式及其对环境、逐日博弈的理解能力。然后，开展仿真实验评估理性假设下的奖励方案在不同主体比例下的实施效果及各主体行为演化表现。最后，结合双层模型与贝叶斯优化算法构建智能增强仿真优化框架，提出基于主体类别的奖励方案。

5.1 概述

除第 3 章研究的理性 CAVs 和 HVs、以及第 4 章探讨的非理性 HVs 之外，智能网联环境中还存在一类主体——非理性 CAVs。其依托中央云控系统，基于 CAVs 群体内部通信和多源环境感知信息，结合对 HVs 的行为模式推理，做出类人化选择（而非完全信息下的效用最大化选择），进一步增加了系统行为模式的多样性。与非理性 HVs 相比，非理性 CAVs 具有本质差异：前者在信息受限条件下表现出基于经验法则的选择行为，具有显著的主观性与个体异质性；后者则在在高信息可获取能力下进行“推理型”非理性出发时间选择，其选择过程体现为出行成本与系统建议可行性之间的动态权衡。

由此，在逐日出发时间选择场景中，智能网联环境下的三类主体——理性 CAVs 和 HVs、非理性 HVs 及非理性 CAVs——在奖励影响下的出发时间选择机制呈现出显著异质性，这为面向三类主体的 IBTDM 方案设计带来了新挑战。具体而言，上述三类主体的出发时间选择异质性，导致交通系统状态与个体出行成本等结果较单一主体系统发生显著偏离。其次，在逐日重复博弈过程中，三类主体对系统状态的认知能力和出发时间选择调整机制存在异质性，进一步加剧了系统演化的复杂性，导致个体出发时间选择持续偏离单主体环境的均衡状态。

因此，在优化面向异质主体的 IBTDM 方案时，必须系统性考量不同类型主体（理性 HVs 与 CAVs、非理性 HVs 以及非理性 CAVs）的出发时间选择异质性，以及由此引发的出发时间选择行为耦合演化对 IBTDM 方案实施效果的影响，从而提升 IBTDM 在异质主体环境中的适应性。



现有关于智能网联环境下 IBTDM 方案设计优化的研究主要聚焦于两方面：一是异质主体的均衡状态理论及仿真建模探索^[23, 113, 116, 133, 174, 175]，二是面向单一主体的 IBTDM 策略设计^[17-22]。然而，现有研究尚未有效应对智能网联环境中奖励机制设计所面临的核心挑战，主要体现在以下两方面：1) 异质主体理论及仿真建模普遍基于完全理性假设或特定规则，难以真实反映智能网联环境下非理性主体在环境感知能力、出行选择机制和选择策略调整上的个体差异；2) IBTDM 方案设计多集中于面向理性主体的最优奖励方案求解或非理性 HVs 奖励影响下的个体差异性行为分析，忽略了理性及非理性主体逐日行为耦合演化引发的奖励策略的实施效能波动，限制了奖励方案评估及优化效果。

基于上述挑战，亟需构建能够反映智能网联环境中非理性主体出发时间选择机制及其与其他主体逐日交互关系的建模方法，实现对奖励方案的效能评估与优化。然而，当前 CAVs 尚未大规模部署，且其实际应用受多种外部条件限制，在现实交通系统中直接观测异质主体出发时间选择行为或评估 IBTDM 方案实施效能成本高、且实施难度大。此外，传统理论模型难以全面刻画智能网联环境中交通行为的动态性、非理性特征及多主体复杂交互机制。

在此背景下，发展具备高可控性与可重复性的仿真方法，是研究智能网联系统复杂行为机制与政策响应效能的关键方法。因而，本研究将构建基于智能体的仿真 (Agent-based Simulation, ABS) 平台，充分利用其在刻画个体异质特征及其与环境和其他主体间交互关系的优势，模拟出发时间选择行为逐日演化过程。该平台刻画异质主体的非对称信息接收认知架构，并集成第4章提出的非理性 HVs 出发时间选择行为预测模型，及表征非理性 CAVs 出发时间选择的大语言模型 (大语言模型的语义理解、社会推理和多智能体协同扩展性，可有效模拟不完全信息下非理性 CAVs 的类人化出发时间选择动态过程)，从而弥补现有仿真模型在非理性行为信息接收和出发时间选择行为建模方面的不足，实现 IBTDM 方案在智能网联环境下的长期效能评估。

进一步地，研究将上述仿真平台嵌入优化流程，基于奖励长时效能开展奖励方案的迭代优化求解。然而，现有仿真优化研究 (如直接搜索法、随机梯度法和元模型 (或代理模型) 法^[134])，在应对智能网联环境 IBTDM 优化需求时面临如下挑战：1) 现有方法普遍忽略策略优化的先验知识——如奖励预算约束、奖励形式、奖励对象等，影响策略合理性、可行性与可解释性；2) 传统方法多将仿真视为黑箱，忽视输入输出的结构关系，难以利用历史信息进行趋势建模与高效搜索，制约优化效率与精度；3) 现有研究多依赖静态行为仿真建模或优化求解思路，难以应对出行者，尤其是 CAVs 出发时间选择机制随环境反馈逐步调整的动态特征，缺乏自适应能力。

为克服上述挑战,研究引入具备自适应学习与人类专家—智能算法协同交互能力的智能增强(Intelligence Augmentation, IA)仿真优化方法。IA作为融合人类与人工智能优势的协作模式,旨在提高人类认知能力并辅助复杂决策^[176]。该方法依赖智能网联环境下奖励方案先验知识及效果分析,进行结构化奖励方案建模;并通过数据驱动持续学习奖励策略与效能关系,引导策略自适应优化,以在提升效率与鲁棒性的同时,保留人工干预能力,增强策略的可控性与可实施性。

综上所述,本章将构建基于智能体的出发时间选择行为仿真模型,并提出融合IA方法的异质IBTDM方案仿真优化框架,为IBTDM项目实施提供决策依据。具体而言,第5.2节构建了基于智能体的仿真系统;第5.3节依托该系统开展仿真实验,考察奖励方案实施效能及CAVs与HVs行为差异;第5.4节进一步提出了面向不同类型主体的异质奖励方案优化方法及方案。具体研究框架如图5.1所示。




图 5.1 面向异质主体选择行为仿真与奖励方案优化技术路线

5.2 异质主体出发时间选择行为仿真建模

本研究将构建面向智能网联环境的ABS仿真系统,集成第3章与第4章的理性CAVs和HVs、非理性HVs出发时间选择机制研究结果,并进一步引入非理性CAVs出发时间选择特征。通过多智能体交互建模,完整再现异质主体个体出发时间选择的耦合演化过程,系统考察奖励策略在智能网联环境中的长时实施效果。该异质主体行为仿真建模可进一步拓展至路径选择、出行方式转换等维度的选择行为研究。具体而言,该框架的设计与实现遵循以下原则:



(1) 智能体定义

在智能网联环境中,主体可依据其主体属性和出发时间选择机制划分为三类典型的行为主体:理性 CAVs 和 HVs、非理性 HVs、非理性 CAVs。

为精确刻画智能网联环境中的异质主体特征,并系统再现智能网联环境下的复杂行为交互机制,研究构建的多智能体仿真系统定义了具有不同认知架构、出发时间选择逻辑与实现路径的三类智能体类型,来对应表征智能网联环境的三类主体。

三类智能体的特征差异如下所示:

1) 理性 CAVs 和 HVs 智能体: 理性 CAVs 与理性 HVs 采用相同的出发时间选择机制,二者均具备对交通环境与 IBTDM 策略的完备认知能力,并严格遵循效用最大化原则进行出行出发时间选择,因而仿真系统将其统一建模为“理性 CAVs 和 HVs 智能体”

具体而言,理性 CAVs 和 HVs 智能体建模不考虑个体社会经济属性差异。在逐日出发时间选择时,该类智能体遵循第 3 章内的完全理性范式,在完备信息环境下基于出行成本最小化原则进行出发时间选择,即其不仅能够获取 IBTDM 项目反馈的个体及系统信息,还具备对所有出行者出发时间选择状态的完全认知能力。

2) 非理性 HVs 智能体: 采用该类智能体来模拟刻画具有认知偏差的 HVs 的出发时间选择行为特征。

具体而言,基于第 4 章出行实验的受试者数据,非理性 HVs 智能体定义了年龄、性别等社会经济属性参数。在逐日出发时间选择时,该类智能体依托 Transformer 架构的行为预测模型(如第 4 章所述),有效模拟复杂交通环境下非理性 HVs 的认知偏差和个体行为差异,从而准确捕捉其在奖励机制影响下的非理性出发时间选择行为。后续仿真实验环境参考了第四章的实验场景,因而 Transformer 模型保持输入输出结构不变,以保障预测准确度——输入包括 IBTDM 项目反馈的系统(奖励方案分布、历史出发时间选择模式等)与个体(出行成本、奖励金额、延误等)信息,输出为非理性 HVs 的出发时间选择。

3) 非理性 CAVs 智能体: 针对非完全信息条件下的非理性 CAVs,研究采用大语言模型(Large Language Model, LLM)模拟其出发时间选择行为。原因如下:①模型凭借其强大的语义理解与表征能力,可有效解析并处理复杂交通场景中的非结构化信息(包括环境感知模糊性、他车意图不确定性等关键因素),适应非完全信息逐日重复博弈环境;②具备意图识别和社会推理能力,可根据多源反馈信息推测其他出行者意图,实现类人化学习与出发时间选择策略优化;③具有多



智能体协同扩展性，支持群体协同出发时间选择；④与仿真平台高度兼容。

具体而言，非理性 CAVs 智能体建模不考虑个体属性差异。在逐日出发时间选择时，该类智能体通过 DeepSeek API 搭建的自然语言交互框架，集成大语言模型推理引擎处理系统反馈的多模态信息——包含系统（奖励方案分布、历史出发时间选择模式等）与个体（出行成本、奖励金额、延误等）——并支持非理性 CAVs 智能体间的协同通信机制，最终模拟具有认知计算能力的 CAVs 群体协同选择过程。

自然语言交互过程中，需向 API 输入包含以下要素的上下文信息：1）场景配置参数，包括早高峰时间窗、目标到达时间、道路容量、出行者类型及比例等；2）系统反馈数据，涵盖前三轮次的历史拥堵数据、奖励方案、非理性群体 ID 及其对应的拥堵时间、奖励收益、累计成本和累计奖励等绩效指标。API 需基于上述信息为 CAVs 群体生成协同最优出发时间建议，要求时间分辨率达到 0.1 分钟，且解决方案需在可行性和成本最优之间达成平衡。

表 5.1 中详细对比分析了不同类别智能体的属性。

表 5.1 三类智能体属性

智能体类型	理性 CAVs 和 HVs 智能体	非理性 HVs 智能体	非理性 CAVs 智能体
物理属性	无个体差异	包含年龄、性别等 社会经济属性	无个体差异
理性水平	完全理性	非理性	准理性
可解释性	高 基于明确的最优化模型	中 基于数据驱动的行为模式	低 黑箱过程
信息透明度	完全信息	系统反馈个人、系统信息	系统反馈个人、系统信息 同类智能体通信
行为准则	效用最小化原则	Transformer 预测模式	大语言模型推理
出发时间 选择依据	完全信息下的 成本最小化	历史行为数据 与有限信息反馈	语义理解 与环境感知

通过上述分类，该多智能体仿真框架能够模拟智能网联环境下异质主体的出发时间选择模式差异；通过耦合个体出发时间选择、成本及系统状态计算反馈机制，结合群体认知能力差异的量化表征，完整再现了异质主体出发时间选择的耦合演化过程。特别地，通过调整各类智能体的构成比例，该框架可模拟 CAVs 技术不同渗透率阶段的智能网联场景，进而建立异质群体比例与奖励方案效能之间的量化关联，支撑智能网联环境下的奖励方案设计与优化。

（2）环境与交互机制建模



本章基于经典瓶颈模型理论,针对早高峰逐日出发时间选择场景建立多轮重复仿真系统。系统采用双层结构设计,具体如下:

1) 个体行为层:集成三类异质智能体(理性 CAVs 和 HVs 智能体、非理性 HVs 智能体和非理性 CAVs 智能体),在每轮仿真中各类智能体基于特定的出发时间选择机制生成出发时间选择。

2) 系统反馈层:每轮仿真后系统会集成群体出发时间数据,计算个体指标(包括拥堵分布、计划延误和奖励收益,并基于广义出行成本函数计算个体出行成本)和系统集计指标(时段流量分布与拥堵模式等);将计算结果作为状态信号输入次日仿真,形成“行为选择-状态更新-信息反馈”闭环。在该多轮重复仿真框架中,个体行为层的三类异质智能体的出发时间选择共同构成了系统反馈层的输入变量,在系统反馈层通过个体指标和系统集计指标的计算输出系统反馈信息,并输入个体行为层进一步影响三类智能体的后续出发时间选择。即在该仿真框架中,异质智能体的选择将通过集计结果互相影响,导致个人出发时间选择持续偏离单主体环境的均衡状态——这反映了智能网联环境中的复杂出发时间选择博弈过程。

基于此,本仿真框架能够系统性地模拟智能网联环境的核心特征,为奖励方案的优化设计提供高度拟真的实验平台,并建立奖励方案与实施效果之间的量化映射关系。

(3) 仿真运行流程

仿真系统运行流程如下:

1) 初始化阶段:将三类智能体总数定为 150 人,并将道路通行能力设置为 60 人/小时,模拟 7:00-9:30 AM 时间段内的系统交通情况。分别设置三类智能体比例以及异质属性参数(与第 4 章交互实验室实验保持一致)。定义奖励方案。

相较于实际早高峰时段(如 7:00 - 9:00 AM),该实验的出发时间窗口适度扩展,旨在通过奖励机制促进错峰出行,引导出行需求在延长时间维度上的合理分布,从而缓解高峰时段的交通压力。在上述时间窗口及参数设定下,若系统运行达到最优状态,则整个模拟期间可避免交通拥堵的发生。

2) 迭代运行阶段:在每轮迭代中,通过智能体出发时间选择-系统计算个人和系统指标-信息反馈的循环过程模拟逐日调整,直到完成预先设定的实验轮次。所有实验轮次运行 5 次取平均值,以减少仿真带来的随机性误差。

3) 数据分析阶段:系统采集三个尺度的仿真数据——微观层面的个体逐日出发时间选择、中观层面的群体行为模式演化以及宏观层面的系统特征,从系统效能改进、公平性等维度评估奖励方案的实施效果。特别地,通过对比分析不同

智能体类别的出发时间选择差异，揭示智能网联环境下群体博弈的内在机理。

图 5.2 展示了基于智能体的仿真框架，图 5.3 展示了仿真框架的多层次决策机制。该仿真框架能够系统性地分析智能网联环境下奖励策略的实施效果，从而为交通管理与政策制定提供科学依据与理论支持。




图 5.2 基于智能体的仿真框架




图 5.3 基于智能体的仿真框架决策机制

5.3 基于多智能体仿真的奖励方案效能评估

基于多智能体仿真框架，通过调控三类智能体的比例分布，研究将系统评估理性优化奖励方案在智能网联环境中的长时行为调控效果。

5.3.1 异质主体出发时间选择模式与仿真有效性验证

在固定奖励方案的作用下，不同主体展现出不同的出发时间选择模式。基于此，研究将分别构建三类智能体的单一主体仿真环境，识别其选择模式，从而为验证奖励干预下逐日博弈过程仿真有效性及评估方案实施效果提供基础。

5.3.1.1 仿真建模有效性验证

由于 CAVs 普及率不足，难以获取真实早高峰场景下单一非理性 CAVs 智能体及智能网联环境中三类异质主体的出发时间选择数据。为此，本研究通过构建两类仿真环境（第 3 章中的单一理性主体环境和第 4 章实验室实验中的单一非理性 HVs 环境），将仿真输出的出发时间与基准数据（理性主体采用第 3 章理论均衡状态，非理性 HVs 采用第 4 章实验室实验数据）进行对比，以验证仿真模型的可靠性。图 5.4 展示了两类智能体的仿真与基准出发时间分布对比结果。




图 5.4 仿真模型输出出发时间与基准出发时间分布对比图

研究使用 Jensen-Shannon (JS) 散度 d_{js} 评估仿真输出的出发时间与基准数据分布差异。 d_{js} 取值范围为[0,1]，其值越趋近于 0，表明分布相似度高，具体定义如公式 (5.1)：

$$d_{js} = \frac{D(p \parallel m) + D(q \parallel m)}{2} \quad (5.1)$$

其中， p 和 q 分别指仿真模型输出的出发时间和基准出发时间的概率分布， m 为两个概率分布 p 和 q 的平均分布， D 为 KL 散度： $D_{KL}(p \parallel q) = \sum_{i=1}^M p(x_i) \log(p(x_i)/q(x_i))$ ， M 为样本个数。

计算结果表明，理性智能体和非理性 HVs 智能体的 JS 散度分别为 0.044 和 0.003，均趋近于 0，表明仿真输出与基准数据高度吻合，验证了模型在再现早高峰逐日出发时间博弈过程的可靠性。



5.3.1.2 异质主体出发时间选择模式

接下来,研究将在单一主体环境下分别探究三类主体在奖励方案影响下的出发时间选择特征及方案实施效果,作为后续异质主体环境奖励方案效能评估基准。

进一步地,为系统评估 CAVs 协同机制对出发时间选择的影响,本研究设计了对比实验框架:将非理性 CAVs 智能体划分为两种典型配置:(1)独立选择智能体组,采用独立出发时间选择模式,即每个智能体由单独的 Deepseek API 接口控制;(2)网联协同智能体组,通过单一 Deepseek API 接口实现群体协同出发时间选择,所有智能体的出发时间由集中式优化算法统一调度,从而有效模拟互联环境下信息共享与协同出发时间选择的运作机制。

图 5.5 分别展示了四类主体(非理性 HVs 智能体、理性 CAVs 和 HVs 智能体、独立选择智能体、网联协同智能体)在面对时变奖励方案时的出发时间选择分布和相应出行成本-奖励分布。

值得注意的是,在单一网联协同智能体环境中,凭借内部通信机制,智能体可获得系统的完全信息。在此条件下,网联协同 CAVs 能够实现理性选择,其出发时间分布趋于系统均衡。同时,协同选择能力削弱了个体分散选择时的博弈强度,避免了纯理性个体环境中可能出现的选择振荡和次优收敛现象,且加快了系统收敛速度。因而,图 5.5(g)(h)中展示的网联协同智能体环境具有最优表现。




图 5.5 出发时间选择模式及成本-奖励分布

根据图 5.5 所示,四类智能体在面对奖励策略时的出发时间选择呈现出显著差异性。具体而言:1)非理性 HVs 智能体在奖励机制的影响下具有明显的时间偏好,其出发时间调整主要集中于较小的时间窗口(8:00-8:50 AM),而倾向于规避迟到或过度提前出发等极端选择。此出发时间选择模式可能是因为早起或迟到



所带来的心理成本过高, 仅凭奖励难以得到完全补偿。2) 理性 CAVs 和 HVs 智能体作为奖励机制设计的基准群体, 其出发时间选择均衡分布。这类智能体能够有效利用奖励机制, 通过优化与其他智能体的交互关系, 实现出行成本的最小化。此理性行为不仅有利于个体出行效用的提升, 同时也有助于缓解系统层面的交通拥堵问题。3) 独立选择智能体在出发时间选择时, 倾向于在确保不迟到的前提下选择出发时间, 在非完全信息情况下, 最终结果呈现多名智能体集体出行的现象。这表明独立选择智能体在出发时间选择过程中更注重路网系统信息和交互机制的判断, 而对个体层面的累计奖励、累计成本等个性化指标的关注相对不足。4) 网联协同智能体具有协同出发时间选择能力, 使得系统内所有主体能够实现高效通信与协同合作, 从而在宏观层面实现了出发时间的均衡分布

对比智能网联环境中奖励机制下全体三类智能体(理性 CAVs 和 HVs 智能体、非理性 HVs 智能体、独立选择/网联协同非理性 CAVs 智能体)的行为模式及其结果, 可以发现非理性 HVs 智能体表现出更强的出发时间偏好和较为保守的出发时间调整特征, 而理性 CAVs 和 HVs 智能体、非理性 CAVs 智能体则展现出更高的出发时间调整灵活性。后两类智能体能够基于对出行成本分布的准确评估, 在整个高峰时段内协调出发时间选择。此外, 相较于独立选择非理性 CAVs 智能体, 信息共享与协同机制不仅显著降低了系统整体拥堵水平, 同时实现了个人出行成本的最小化。在此情境下, 智能体能够在完全信息条件下以最小化自身出行成本为目标实现理性选择, 最终在第 3 章得到的最优时变奖励方案作用下实现了用户均衡与系统最优状态的一致性。

5.3.2 智能网联环境下奖励方案实施效果

接下来, 研究将分别从实施效能、出发时间选择模式维度, 系统分析智能网联环境下异质主体的行为博弈与演化, 以确保 IBTDM 行为调控效果。

(1) 实施效能

首先, 研究将探究奖励策略在智能网联环境中随异质智能体构成比例变化的实施效能。需要特别说明的是, 主体的行驶时间可分解为自由流行驶时间和排队延误两部分。在第 3 章的理论建模中, 为简化分析, 通常假设自由流行驶时间为零; 然而在现实交通场景中, 自由流行驶时间始终表现为一个与交通状态无关的正定值, 因此不受 IBTDM 方案的影响。为避免自由流行驶时间对奖励方案实施效果评估的干扰, 本研究在评估奖励方案效果时, 将理论框架中的系统总行驶时间指标转化为系统总延误指标, 消除自由流时间带来的系统性偏差, 从而捕捉 IBTDM 政策对缓解交通拥堵的实际效应。

图 5.6 和图 5.7 对比了不同主体构成对奖励方案的实施效果,即系统总延误的影响。其中,为了对比独立选择和网联协同非理性 CAVs 智能体的表现,分别探究了在两者与其他主体共存的环境下奖励方案的实施效果。图 5.6 为理性 CAVs 和 HVs-非理性 CAVs-独立选择非理性 CAVs 智能体系统,图 5.7 为理性 CAVs 和 HVs-非理性 CAVs-网联协同非理性 CAVs 智能体系统。其中,图 5.7 中的全非理性协同网联 CAVs 环境属于特殊案例,因 CAVs 内部通信实现了完全信息共享,使其能够实现理性选择,且系统选择有效避免了单一理性主体环境中的博弈震荡与次优收敛,因而该环境的系统效能优于纯理性主体环境。




图 5.6 非理性 HVs-理性 CAVs 和 HVs-独立选择非理性 CAVs 智能体系统总延误变化




图 5.7 非理性 HVs-理性 CAVs 和 HVs-网联协同非理性 CAVs 智能体系统总延误变化

由图 5.6 及图 5.7 可知,首先,在单一类型主体的场景下,仅包含网联协同非理性 CAVs 智能体的系统表现出最低的总延误,仅包含理性 CAVs 和 HVs 智能体的系统表现出次低的总延误。其中,仅由网联协同智能体构成的系统具备



CAVs 间的通信机制, 可实现完全信息共享, 从而赋予协同网联 CAVs 理性选择能力。这一发现表明, 理性智能体在协调系统整体效能方面具有独特优势。

其次, 在包含理性 CAVs 和 HVs 智能体的异质主体环境中, 系统的总延误显著低于不包含理性 CAVs 和 HVs 智能体的情况, 这证实了理性 CAVs 和 HVs 智能体在优化奖励方案实施效果和降低系统拥堵方面的重要作用。进一步分析发现, 在缺乏理性 CAVs 和 HVs 智能体的情况下, 非理性 HVs 智能体与非理性 CAVs 智能体共存的系统, 其总延误通常低于单一类型主体 (仅非理性 HVs 或仅非理性 CAVs 智能体) 构成的系统。这一现象表明, 非理性 CAVs 智能体具备较强的信息处理能力, 能够准确辨识并预判非理性 HVs 智能体的行为特征及其影响, 进而生成更具系统优化性的出发时间选择方案。

最后, 引入信息共享与协同机制显著优化了含非理性 CAVs 智能体的异质主体系统效能。数据显示, 三种包含网联协同非理性 CAVs 智能体的异质主体系统均稳定收敛于 3000 分钟的拥堵水平, 验证了该机制通过协调出发时间分布、促进系统均衡的有效性。这一发现证实了协同出发时间选择机制在智能网联环境中的关键调节作用。

上述结果表明, 在多类型智能体共存的环境中, 主体在奖励影响下的出发时间选择行为及系统状态并非简单的线性叠加, 而是呈现出复杂的非线性耦合效应。

(2) 出发时间选择模式

为深入探究不同主体在智能网联环境下的具体出发时间选择表现, 图 5.8 和图 5.9 展示了在非理性 HVs 智能体、理性 CAVs 和 HVs 智能体和独立选择/网联协同非理性 CAVs 智能体数量均等的实验环境下, 系统出发时间选择模式以及高峰期成本-奖励水平的分布情况。




图 5.8 相同数量非理性 HVs、理性 CAVs 和 HVs 和独立选择智能体共存环境出行模式




图 5.9 相同数量非理性 HVs、理性 CAVs 和 HVs 和网联协同智能体共存环境出行模式

由图 5.8 和图 5.9 可知，在三类智能体共存（理性 CAVs 和 HVs、非理性 HVs、独立选择/网联协同非理性 CAVs）情况下，三类智能体较各自的单独出行场景的出发时间选择模式存在不同。具体而言，三类智能体共存场景下的出行成本和延误分布水平数值介于全理性 CAVs 和 HVs 智能体构成的最优出行环境与全非理性 CAVs 智能体构成的出行环境之间。这一实证结果表明，不同类型智能体间的行为耦合机制对个体的出发时间选择产生了系统性影响，从而优化了奖励方案的实施效果。研究进一步证实，多主体共存环境下的出发时间选择行为并非单一主体行为的简单叠加，而是通过复杂的行为耦合演化实现了系统效能的整体提升。

此外，在多主体交互环境下，三类智能体展现出显著的出发时间选择模式差异：1）独立选择/网联协同非理性 CAVs 智能体因对延误成本的高度敏感性及高峰期后段其他智能体随机出发时间选择带来的不确定性，表现出“早期偏好”；2）非理性 HVs 智能体保持其固有的“中期偏好”；3）理性 CAVs 和 HVs 智能体基于完全信息和效用最大化原则，其出发时间选择模式呈现“全高峰分布”特征。

最后，对比图 5.8 和图 5.9 可知，信息共享与协同机制对系统产生了显著影响：在高峰时段（8:20-8:50AM），存在网联协同非理性 CAVs 智能体的异质主体系统呈现出更高的瞬时出行成本峰值和瞬时拥堵成本峰值，但有效消除了对照系统（含有独立选择智能体的异质主体系统）中出现的次高峰现象及其伴随的持续性高拥堵水平；在出发时间分布方面，存在网联协同非理性 CAVs 智能体的异质主体系统中，约 93% 的出行量集中于 8:25 AM 前完成，剩余出行则延迟至 9:10 AM 后，形成较长的出发时间段空白，从而使得拥堵高峰持续时间相对较短，而含有独立选择非理性 CAVs 智能体的异质主体系统则维持相对均匀的连续分布模式。综上所述，在存在网联协同非理性 CAVs 智能体的异质主体系统下，系统的高峰期拥堵较为严重，但由于该时段实际出行量显著降低（仅占总量的 2%），



系统并未产生实质性拥堵恶化, 拥堵持续时间相对较短, 相比之下, 存在独立选择非理性 CAVs 智能体的异质主体系统中相对平缓的瞬时拥堵水平却因持续性的出行流量而转化为更持久的拥堵状态。

结合异质主体环境下的系统延误对比及三类智能体的出发时间分布等分析, 研究发现在异质主体的交通环境中, 理性 CAVs 和 HVs 智能体展现出显著的系统优化特性——在单类型主体及与多类型主体共存时, 其能够灵活调整出发时间选择, 显著缓解系统拥堵水平。因此, 理性 CAVs 和 HVs 智能体是实现智能网联环境下奖励机制最优管理效能的目标群体。

此外, 基于网联协同非理性 CAVs 智能体在信息处理和生成科学出发时间选择方面的显著优势, 本研究在后续构建异质主体交通仿真场景时仅考虑网联协同非理性 CAVs 智能体, 而未纳入独立选择非理性 CAVs 智能体。

5.3.3 较大规模交通需求场景下的奖励方案实施效果

考虑到现实早高峰交通系统具有出行群体规模庞大、行为耦合关系复杂等典型特征, 本研究对时变奖励方案在扩展规模异质主体场景下的适用性及实施效果进行评估, 旨在验证奖励方案对较大规模条件下出行需求调控的有效性, 进而为其在实际早高峰交通系统中的适用性提供科学依据。

基于上述研究目标, 研究将总出行者数量扩展至 5 倍, 同时等比例提升瓶颈模型的通行能力, 确保系统在高峰时段内保持相同的通行效率。在保持三类智能体 (非理性 HVs 智能体、非理性 CAVs 智能体、理性 CAVs 和 HVs 智能体) 数量相同的情况下, 图 5.10 展示了扩展规模后各类型智能体的出行模式和奖励-成本分布。




图 5.10 相同数量非理性 HVs、理性 CAVs 和 HVs 和非理性 CAVs 共存环境出行模式

如图 5.10 所示, 在扩大系统规模的情境下, 系统均衡状态相较于基准小规模情境更接近于系统最优状态, 其延误、出行成本分布曲线更加平缓且峰值降低。因此, 在需求规模较大的情况下, 时变奖励机制能更有效地在时间维度上重新分



配其出行需求，从而实现系统层面的交通流优化。因而在预算约束条件下，应优先将奖励资源集中投放于出行需求密集的主要干道，而非采取均匀分配策略。

5.4 基于主体类型的奖励方案仿真优化

由 5.3 节可知，理性假设下的时变奖励方案建立在理性 CAVs 和 HVs 同质出发时间选择机制基础上，未能充分反映异质出行群体选择特性，易在智能网联环境中引发系统性偏差，限制其行为引导效能。

为突破该局限，本研究提出基于智能增强的仿真优化方法，考虑异质出行群体特征，分别设计针对性奖励策略。该方法融合 5.3 节 IBTDM 仿真评估结果及先验知识，明确奖励形式结构与约束条件，依托多智能体仿真，再现智能网联环境下重复博弈情境中奖励强度与出发时间选择行为的耦合关系，评估奖励长时效能；进一步在预算约束下，通过持续学习系统趋势，实现参数迭代优化，分别构建适配不同群体特征的奖励方案，引导系统向最优状态演化，并提升奖励方案的环境自适应性与可实施性。

5.4.1 基于智能增强的奖励方案仿真优化

本研究构建基于智能增强的仿真优化框架如下：首先明确面向三类异质主体的时变奖励方案参数及约束；并采用双层规划理论建立智能网联环境下的奖励方案优化问题模型；引入贝叶斯优化算法实现模型的高效求解。通过这一完整的建模-求解框架，最终获得了基于主体类型的优化奖励方案。

5.4.1.1 优化问题建模

在双层优化模型中，上层规划以奖励调控为核心，通过优化奖励函数参数来引导主体行为调整，最终实现系统总延误最小化；下层规划则采用基于智能体的仿真方法，刻画个体在上层奖励方案下的出发时间选择行为及其对系统拥堵状态的影响，并将生成的主体出发时间选择集合反馈至上层模型，用于计算延误，形成闭环优化。

具体而言，基于主体类型的奖励方案双层优化框架如下：

上层模型（奖励策略优化层）：

$$\min_{g \in \Theta} f(g) = \sum_{i=1}^N \tau_i(x_i^*(g)) \quad (5.2)$$

$$s.t. \sum_{k=1}^3 \sum_{i \in N_k} r_k(x_i^*; g) \leq M \quad (5.3)$$



$$x^*(\mathcal{G}) = \Gamma(\mathcal{G}) \quad (5.4)$$

$$\tau_i = \max \left\{ \tau_{\sigma(i)-1} - \left(x_{\tau_{\sigma(i)}} - x_{\tau_{\sigma(i)-1}} \right) + 1/C, 0 \right\} \quad (5.5)$$

下层模型（出发时间选择行为响应层）：

$$\Gamma(\mathcal{G}) = \{x_i \mid x_i = \pi_k(s_i; \mathcal{G}), \forall i \in N_k, k \in \{1, 2, 3\}\} \quad (5.6)$$

$$s.t. x_i \in [420, 570] \quad (5.7)$$

其中决策变量 $\mathcal{G} \in \Theta$ 表示奖励方案参数， $f(\mathcal{G})$ 为目标函数——系统内所有出行者的延误之和， N_k 表示第 k 类智能体集合（ $k=1, 2, 3$ 对应非理性 HVs/理性 CAVs 和 HVs/非理性 CAVs 智能体）， $r_k(\cdot)$ 为与智能体类型相关的奖励函数， $x^*(\mathcal{G})$ 为下层模型返回的当奖励方案参数为 $\mathcal{G}$ 时各个出行者的出发时间选择， τ_i 是第 i 个出行者的延误， σ 为出发时间排序索引， C 为道路瓶颈的通行能力， s_i 为智能体观测状态。

在双层规划模型中，上层模型的结构与功能的具体含义如下：公式（5.2）定义了上层模型的目标函数，即最小化系统中所有主体的延误总和；公式（5.3）为激励成本约束，确保对主体的总激励成本预算不超过预设预算阈值；公式（5.4）用于接收下层模型的出发时间选择集合；公式（5.5）基于下层模型提供的出发时间选择，计算个体排队延误，在计算逻辑上，本研究在计算延误时，采用顺序递推的逻辑进行估算。具体而言，系统首先将所有主体按照出发时间先后顺序进行排序。首位主体排队时间为零。对于后续的每一位主体，其排队时间的计算需考虑前一位主体的累积等待时间以及两者出发时间间隔内的道路通行能力。若该时间间隔内的通行能力不足以完全消化新增的出行需求，则超出部分将转化为当前主体的额外排队时间。

下层模型的结构定义如下：公式（5.6）表征多智能体仿真框架，公式（5.7）约束出发时间选择的可行域，限定早高峰时段为 7:00 AM 至 9:30 AM。

5.4.1.2 奖励方案求解

针对奖励方案双层优化框架，本研究提出了基于贝叶斯优化的求解框架，通过构建高斯过程代理模型和主动采样策略，实现复杂决策空间的高效搜索，逐步逼近最优奖励参数组合。

贝叶斯优化是一种基于概率推理的序列优化算法，通过构建目标函数的概率代理模型，采用序贯实验设计的方式逐步探索参数空间，逐步迭代更新提升代理模型。该方法无需目标函数的梯度信息，特别适用于基于智能体仿真的黑箱优化场景。

（1）奖励参数确定

为了避免贝叶斯求解时出现的维度灾难问题，并保证奖励方案的可行性，研



究通过基函数分解将无限维的奖励曲线优化转化为有限维参数优化，同时保持时空灵活性。

本研究采用基于主体类型的基函数表征方法，构建面向多类型主体的时变奖励方案体系。参数化的基函数线性组合方式，保证了奖励方案的时变特性及可调节性。具体而言，对于任意智能体类型 $k \in [\text{非理性 HVs}, \text{理性 CAVs 和 HVs}, \text{非理性 CAVs}]$ ，其奖励曲线 $r_k(t)$ 表示为：

$$r_k(t; \mathcal{G}) = \sum_{z=1}^Z \omega_z^k \phi_z^k(t; c_z^k, b_z^k) \quad (5.8)$$

其中：待优化的奖励参数 $\mathcal{G}_z^k = (\omega_z^k, c_z^k, b_z^k)$ ，

$\phi_z^k(\cdot)$ ：第 k 类出行者的第 z 个基函数（如高斯型、三角型等），

ω_z^k ：第 k 类出行者的第 z 个基函数的权重参数，控制奖励强度，

c_z^k ：第 k 类出行者的第 z 个基函数的中心点参数，决定奖励时段位置，

b_z^k ：第 k 类出行者的第 z 个基函数的带宽参数，调节奖励时间跨度。

本研究采用高斯径向基函数（Gaussian Radial Basis Function, RBF）作为奖励方案的数学表征工具，其函数形式如式（5.9）所示：

$$\phi_z^k(t) = \exp \left(-\frac{(t - c_z^k)^2}{2(b_z^k)^2} \right) \quad (5.9)$$

高斯径向基函数（RBF）表征奖励方案的优势如下：1）高斯 RBF 的局部敏感性特征使其能够精确刻画奖励在特定时段的局部影响效应，同时通过调节单个基函数参数即可实现对目标时段奖励强度的针对性调控，从而在智能网联环境中实现对单类型主体的针对性诱导。2）该方法的参数设计具有明确的物理意义，其中关键参数直接对应于奖励强度、奖励实施时段及持续时间等实际特征。3）高斯 RBF 的连续可微特性不仅满足政策实施过程中渐进调整的实际需求，更与出行者对奖励策略的连续性感知特性相吻合，确保了出行者出发时间的微小调整不会引发奖励值的突变现象。为系统阐明高斯 RBF 的优越性，本研究在表 5.2 中详细对比分析了其与其他基函数类型的性能差异：

表 5.2 典型基函数与高斯径向基函数对比分析

基函数类型	局限性	RBF 的改进
多项式基	全局振荡，难以捕捉局部特征	局部化控制，避免远距离干扰
分段常数函数	不连续，导致行为响应突变	平滑过渡，符合出行选择连续性
傅里叶基	需高频分量拟合突变，参数冗余	低频分量即可表征典型出行模式
小波基	参数解释性差	中心点 c_j 直接对应高峰时段

综上所述，研究选择高斯径向基函数表征奖励方案，其主要参数包括：表征



奖励强度的幅值参数 ω_z^k ，决定奖励时段中心位置的中心点参数 c_z^k 以及控制奖励作用时间范围的宽度参数 b_z^k 。

针对第 5.3 节揭示的三类主体在奖励影响下的出发时间选择模式异质性，研究为三类主体分别设计了由两个高斯径向基函数线性组合表征的奖励方案。这一建模方法将奖励优化问题转化为一个 18 维参数空间的搜索问题，具体参数维度构成如公式 (5.10) 所述：

$$\mathcal{G}_{i,d} = [\omega_1^{k=1}, c_1^{k=1}, b_1^{k=1}, \omega_2^{k=1}, c_2^{k=1}, b_2^{k=1}, \dots, \omega_2^{k=3}, c_2^{k=3}, b_2^{k=3}] \quad (5.10)$$

其中，参数搜索边界分别为 $\omega \in [0, 40]$ ， $c \in [420, 570]$ ， $b \in [10, 60]$ 。

基于上述参数建模和 18 维搜索空间界定，研究下一步将展开决策变量的系统性优化求解。

(2) 求解流程

在确定奖励形式的决策变量后，通过如下步骤来进行优化求解最优奖励参数：

1) 初始化设计：

通过采用 Sobol 序列生成 n_0 个初始参数样本集 $\{\mathcal{G}_i\}_{i=1}^{n_0}$ ，确保空间分布均匀覆盖，避免局部最优。然后通过智能体仿真模型获取系统响应数据，建立初始的输入-输出映射关系数据集 $\mathcal{D}_0 = \{\mathcal{G}_i, f(\mathcal{G}_i)\}_{i=1}^{n_0}$ 。

在此初始化设计过程中，研究选择 Sobol 序列进行贝叶斯优化的初始化采样，使得样本在高维空间中分布均匀，且随着样本数量增加，采样点之间的距离逐渐变小，能够提供比独立均匀分布采样（如随机采样或拉丁超立方采样）更均匀的覆盖率。Sobol 序列是一种准蒙特卡洛（quasi-random）低差异序列，通过确定性方法生成在超立方体中均匀分布的点集，数学上，Sobol 序列基于方向向量和二进制递归构造，利用 Gray 码（反射二进制码）和异或运算快速生成点集。

其生成步骤为：

①初始化方向向量：在 D 维空间中，对每个参数维度 d ($d=1, 2, \dots, D$)，预设一组互质的方向数 $v_{j,d}$ （通常为奇数的二进制分数），满足递推关系：

$$v_{j,d} = a_1 v_{j-1,d} \oplus a_2 v_{j-2,d} \oplus \dots \oplus a_s v_{j-s,d} \quad (5.11)$$

其中 j 为二进制位数 ($j=1, 2, \dots, J$ ，通常 J 取 30-64 位)， $\oplus$ 为二进制异或运算， a_k 为递推系数。

②点生成算法：对于第 n 个（总样本数为 N ）样本点—— $\mathbf{x}_n = (x_{n,1}, x_{n,2}, \dots, x_{n,D}) \in [0, 1]^d$ ：

计算 n 的 Gray 码 $g(n) = n \oplus (n/2)$

将 $g(n)$ 的二进制表示为 $g(n) = \sum_{j=0}^{J-1} b_j 2^j$



计算第 d 维坐标: $x_{i,d} = b_0 \cdot v_{1,d} \oplus b_1 \cdot v_{2,d} \oplus \dots \oplus b_{J-1} \cdot v_{J,d}$

重复直至所有 D 维度坐标生成完毕

③参数空间映射: 将单位超立方体中的点 $\mathbf{x}_n \in [0,1]^d$ 线性映射到实际参数范围:

$$\theta_n = \mathbf{L} + \mathbf{x}_n \cdot (\mathbf{U} - \mathbf{L}) \quad (5.12)$$

其中 $\mathbf{L}, \mathbf{U}$ 分别为参数下限和上限向量。

Sobol 序列的星差异 (Star Discrepancy) 极小, 为 $O((\log N)^D / N)$, 远优于随机采样的 $O(1/\sqrt{N})$ 。该采样方法为贝叶斯优化提供了低偏差、高覆盖的初始数据, 是解决高维 (10 维以上) 黑箱优化问题的理想初始化工具。

2) 构建高斯过程代理模型, 提供预测均值并量化预测不确定性。

首先, 利用初始数据集 $\{\mathcal{G}_i, f(\mathcal{G}_i)\}_{i=1}^{n_0}$ 训练高斯过程回归 (Gaussian Process Regression, GPR), 建立目标函数 (系统总延误) 与奖励参数间的概率关系, 并通过 Matern 核函数刻画参数间的非线性依赖关系, 引入白噪声项处理仿真过程中的随机性。

假设目标函数 $f(\mathcal{G})$ 服从高斯过程, 定义后验分布:

$$f(\mathcal{G}) \sim \mathcal{GP}(\mu(\mathcal{G}), k(\mathcal{G}, \mathcal{G}')) \quad (5.13)$$

其中 $\mu(\mathcal{G})$ 为后验均值函数, $k(\mathcal{G}, \mathcal{G}')$ 为核函数, 表征数据点间的协方差。研究采用 Matern 5/2 核函数, 兼顾平滑性与灵活性, 其形式如下所示:

$$k(\mathcal{G}, \mathcal{G}') = \sigma^2 \left(1 + \frac{\sqrt{5}d}{\ell} + \frac{5d^2}{3\ell^2} \right), d = \mathcal{G} - \mathcal{G}' \quad (5.14)$$

其中 ℓ 为长度尺度。

其次, 进行超参数优化, 高斯过程回归的超参数优化通过最大化边缘似然函数实现, 其目标是找到最优的核函数超参数 ℓ 和 σ , 使得观测数据 $\mathbf{y}$ 的边缘概率最大。高斯过程的边缘似然 (对数形式) 为:

$$\log p(\mathbf{y}|\mathbf{X}) = -\frac{1}{2} \mathbf{y}^T (\mathbf{K}_{\sigma, \ell} + \sigma_n^2 \mathbf{I})^{-1} \mathbf{y} - \frac{1}{2} \log |\mathbf{K}_{\sigma, \ell} + \sigma_n^2 \mathbf{I}| - \frac{n}{2} \log 2\pi \quad (5.15)$$

其中 $\mathbf{X}$ 代表输入特征矩阵, $\mathbf{K}_{\sigma, \ell}$ 是由核函数 $k_{\sigma, \ell}(\mathcal{G}_i, \mathcal{G}_j)$ 构成的 $n \times n$ 协方差矩阵, σ_n^2 是观测噪声方差, n 为样本数量。

3) 采集函数优化, 进行候选点选择:

研究使用期望改进 (Expected Improvement, EI) 准则, 优先选择可能比当前最优 f_{min} 更优的点, 用于在高斯过程回归框架下指导序贯实验设计, 平衡探索与开发, 以高效寻找全局最优解。其核心原理与实施步骤如下:

设当前最优观测值为 f_{min} , 对于候选点 $\mathcal{G}$, 其改进量为:

$$I(\mathcal{G}) = \max(0, f_{min} - f(\mathcal{G})) \quad (5.16)$$

由于 $f(\mathcal{G})$ 是高斯过程预测的随机变量（服从后验分布），期望改进即改进量的数学期望：

$$EI(\mathcal{G}) = \mathbb{E}[I(\mathcal{G})] = \int_{-\infty}^{f_{min}} (f_{min} - f) p(f|\mathcal{G}) df \quad (5.17)$$

其解析解形式如下所示：

$$EI(\mathcal{G}) = \begin{cases} (f_{min} - \mu(\mathcal{G})) \Phi(Z) + \sigma(\mathcal{G}) \phi(Z), & \text{if } \sigma(\mathcal{G}) > 0 \\ 0, & \text{if } \sigma(\mathcal{G}) = 0 \end{cases} \quad (5.18)$$

其中 $Z = f_{min} - \mu(\mathcal{G}) / \sigma(\mathcal{G})$ 为标准化的改进量； Φ, ϕ 为标准正态分布的累积分布函数（CDF）和概率密度函数（PDF）。

在参数空间内优化采集函数 $EI(\mathcal{G})$ ——采用多起点梯度上升求解新评估点：

$$\mathcal{G}_{new} = \arg \max_{\theta} EI(\mathcal{G}) \quad (5.19)$$

在核函数满足连续性条件下，EI 准则可保证渐进稠密采样，对于有限参数空间，满足 $\lim_{n \rightarrow \infty} f(\mathcal{G}_n) \rightarrow f(\mathcal{G}^*)$ ，确保算法收敛性。

4) 仿真评估与模型更新：

执行基于智能体的仿真模型，输出结果并更新数据集 $\mathcal{D}_{t+1} = \mathcal{D}_t \cup \{\mathcal{G}_{new}, y_{new}\}$ 。

用新数据重新训练高斯过程回归模型，更新后验分布。

5) 收敛判断

重复步骤（3）-（4），直到满足以下任一条件：

达到最大迭代次数；

目标值改进幅度小于阈值（ $|(f_t - f_{t-1}) / f_{t-1}| < \epsilon$ ）。

最后返回历史最优解 $\mathcal{G}^* = \arg \max_{\mathcal{G} \in \mathcal{D}} f(\mathcal{G})$ 。

具体求解流程如图 5.11 所示：




图 5.11 基于仿真优化的奖励方案求解流程



通过上述流程, 研究得到最终的三类主体的奖励基函数参数, 并相应计算得到最终的奖励曲线 $r_k(t)$, $k \in [\text{非理性 HVs}, \text{理性 CAVs 和 HVs}, \text{非理性 CAVs}]$ 。

5.4.2 优化奖励方案案例结果分析

研究将以三类主体（理性 CAVs 和 HVs、非理性 HVs 和非理性 CAVs）和两类主体（理性 CAVs 和 HVs、非理性 HVs）共存情况下的智能网联环境为例, 通过上述算法步骤, 求解优化奖励方案, 并进一步对比非理性 CAVs 的引入对于奖励方案的影响。

5.4.2.1 三类出行者（理性 CAVs 和 HVs、非理性 HVs 和非理性 CAVs）共存

理性 CAVs 与 HVs、非理性 HVs 以及非理性 CAVs 三类出行者共存构成了智能网联环境的典型场景。为此, 本研究设定三类智能体数量均等, 以探究该情境下的最优奖励方案, 并从奖励形式、奖励实施结果、拥堵缓解效果三方面对该优化奖励方案进行系统性评估。

（1）奖励形式

优化奖励方案的高斯径向基函数参数如表 5.3 所示, 具体形式如图 5.12 所示:

表 5.3 非理性 HVs、理性 CAVs 和 HVs、非理性 CAVs 共存情况的优化奖励方案参数结果

对象	RBF	奖励幅值 ω	中心点参数 c	宽度参数 b
非理性 HVs 智能体	RBF1	6.99	467.61	42.44
	RBF2	28.29	459.78	47.73
理性 CAVs 和 HVs 智能体	RBF1	28.96	461.60	20.20
	RBF2	10.11	479.91	44.26
非理性 CAVs 智 能体	RBF1	33.14	473.79	13.26
	RBF2	17.85	568.28	54.71




图 5.12 非理性 HVs、理性 CAVs 和 HVs、非理性 CAVs 共存情况的优化奖励方案



根据图 5.12 的优化奖励方案分析结果，可以得到以下结论：

1) 该方案在时间分布策略上与理论时变最优奖励存在显著差异。三类智能体的优化方案选择不在高峰期末端施加高额奖励，这可能源于两方面因素：首先，高峰期末端的出行延误成本较高，若要有效激励出行者选择该时段出发，所需奖励金额将大幅增加，导致经济性降低；其次，由于非理性 CAVs 和 HVs 出行者行为模式的影响，高峰期的前中段出发时间选择已呈现一定随机性，这种随机性在期末端进一步放大，使得该时段的出行分布更具不确定性，从而降低了奖励措施的可预测性和有效性。

2) 三类主体的奖励方案呈现出明显的时空分布差异。①非理性 CAVs 智能体的奖励方案在 7:50 AM 达到峰值（超过 35 元），但随后快速衰减，其高奖励水平（20 元以上）集中在 7:40-8:10 AM 的 30 分钟区间内，同时在 7:30-9:30 AM 的宽泛时段内维持 10 元以上的基础奖励，展现出“高峰值、快衰减、长尾效应”的特点。②理性 CAVs 和 HVs 出行者的奖励分布同样在 7:50 AM 出现峰值（约 38 元），其高奖励时段（20 元以上）持续 50 分钟（7:20-8:10 AM），并在更宽的 7:00-8:30 AM 区间内保持 10 元以上的奖励水平，呈现“高峰值、中持续”的特征。③相比之下，非理性 HVs 智能体的奖励方案表现出独特的“长持续、缓衰减”模式，其峰值出现在 7:45 AM，随后缓慢下降，在 7:00-8:30 AM 的 90 分钟内维持 20 元以上的高奖励水平，并在 7:00-9:00 AM 的完整高峰时段内确保 10 元以上的基础奖励。

(2) 奖励方案实施结果

针对该优化奖励方案的实施结果分析表明，在 24 轮实验周期内，优化奖励方案的平均单轮总预算为 2012.15 元，其中非理性 HVs、非理性 CAVs 智能体、理性 CAVs 和 HVs 的预算分配分别为 341.09 元、680.77 元和 990.29 元。相比之下，理性假设奖励方案的平均单轮总预算高达 3612.34 元，预算分配结构亦存在显著差异：非理性 HVs 智能体、非理性 CAVs 智能体、理性 CAVs 和 HVs 智能体的预算分别为 739.76 元、1158.98 元和 1713.59 元。

通过对比分析，可得出以下结论：

1) 预算优化效果显著：优化奖励方案的总预算远低于理性假设方案，降幅达 44.30%（减少 1600.19 元），表明优化方案在成本控制方面表现优异——优化方案通过调整奖励分配策略，减少了不必要的支出，同时仍能维持一定的激励效果。

2) 主体出发时间选择差异：首先，非理性 HVs 智能体对奖励的直接敏感性较低，其更倾向于选择自己的固有出发时间或基于出行成本、拥堵分布等因素进行出发时间的选择，对奖励机制的适应性较弱，因此优化方案认为减少对其奖励

不会显著影响整体效果。其次，非理性 CAVs 智能体的预算削减也较大（降幅 41.3%），一定程度上表明了非理性 CAVs 智能体对于奖励激励的敏感性较低，其出发时间选择更依赖于对出行成本的自主优化，而非追求更高的外部激励；行为可预测性较高，优化方案可能通过算法调整，以较低成本维持其参与度。其次，非理性 HVs 智能体的预算亦大幅减少（降幅 53.9%）。最后，理性智能体的预算降幅相对较小（42.2%），说明其出发时间选择行为对奖励激励的依赖程度较高，但依然可以在其他出行者的出发时间调整后获益。

3) 奖励结构调整：相较于理性假设奖励下的奖励预算分配结构，非理性 HVs 智能体预算占比从 20.5%（理性假设）降至 17.0%（优化方案）。非理性 CAVs 智能体预算占比从 32.1%微升至 33.8%。理性智能体预算占比从 47.4%微升至 49.2%。说明优化方案更倾向于将预算分配给理性出行者和非理性 CAVs 智能体，可能因其行为更易通过算法优化。

（3）拥堵缓解效果分析

上述发现为多样化奖励策略的设计于实施提供了重要支撑。下一步将结合实验的具体目标——对拥堵的缓解效果，进一步分析优化方案的实际效果是否达到预期，探究奖励方案的实用性。

实施该奖励方案后，出行者的出发时间选择分布如图 5.13 所示。实施优化奖励方案后，异质主体的时间选择分布呈现出显著的均衡化特征。与理性假设下的优化奖励方案相比，该方案有效改善了出发时间分布的集中程度，使得各时段的出行量分配更为合理，从而证实了优化后的奖励策略在调节出行需求时间分布、有效缓解高峰时段出行压力方面的优势。




图 5.13 非理性 HVs、理性 CAVs 和 HVs、非理性 CAVs 共存情况下的出发时间选择

为量化评估不同奖励方案的实施效果，本研究对理性最优奖励方案与优化奖励方案实施后的系统总延误进行了对比分析，结果如图 5.14 所示：




图 5.14 奖励方案实施效果对比

基于图 5.14，本研究得出以下重要发现：

在收敛性能方面，优化奖励方案展现出显著优势。实验数据显示，该方案仅需较少迭代轮次即可使系统快速收敛并稳定维持在较低拥堵水平。相比之下，理性假设下的时变奖励方案的实施效果呈现出明显的波动性特征，其延误随实验轮次增加并未呈现显著下降趋势，表明该方案在系统稳定性方面存在不足。

就拥堵缓解效果而言，优化奖励方案同样表现优异。24 轮实验的平均数据显示，优化方案的平均延误为 1107 分钟，较理性假设下的奖励方案的 3346 分钟降低了 67%，较无奖励方案下的基准值 4303 分钟降低了 74.3%。这一结果充分证明了优化方案在交通需求管理方面的有效性。

从经济性角度分析，本研究针对奖励方案的投资回报率进行了分析。实验结果表明，理性假设下的奖励方案的单位轮次预算投入为 3612 元，对应 ROI 仅为 0.27 元/分钟；而优化方案以显著降低的预算水平（2012 元/轮）实现了更高的 ROI（1.59 分钟/元），投资回报率提升近 5 倍。这一发现为交通需求管理政策的成本效益评估提供了重要参考。

综合收敛速度、系统稳定性和经济性等多维度的评估结果，本研究提出的优化奖励方案在智能网联环境下的需求管理中展现出全面优势。该方案不仅能够快速实现系统稳定，而且在保证显著拥堵缓解效果的同时大幅提升了资金投资回报率，为解决城市交通拥堵问题提供了创新性的解决方案。

5.4.2.2 两类出行者（理性 CAVs 和 HVs、非理性 HVs）共存

研究在 5.3 节中分析了奖励方案实施后，含有非理性 CAVs 的异质主体环境的系统拥堵缓解效果，验证了非理性 CAVs 的协同决策机制在改善异质主体交通

环境系统效能方面的有效性。为进一步分析非理性 CAVs 引入对智能网联环境的影响,研究在理性 CAVs 和 HVs、非理性 HVs 两类出行者共存的基准场景下求解优化奖励方案,并与引入非理性 CAVs 后的情形进行对比分析。该两类主体情景下的优化奖励方案结果以及出发时间分布如图 5.15 所示:




图 5.15 非理性 HVs、理性 CAVs 和 HVs 共存情况下的优化奖励方案




图 5.16 非理性 HVs、理性 CAVs 和 HVs 共存情况下的出发时间选择

如图 5.15 所示,在优化后的奖励方案中,理性 CAVs 和 HVs 的奖励主要分布于高峰后半段,其形式与单理性 CAVs 和 HV 的奖励方案相似;而非理性 HVs 的奖励则集中于前半段。与三类出行者共存情景相比,CAVs 的引入对非理性 HVs 奖励方案的影响较小,但对理性 CAVs 和 HVs 的奖励方案产生了显著影响。对比图 5.13 和图 5.16 可知,非理性 CAVs 的引入重塑了系统出行模式:其倾向于在高峰前期出发的出行特征挤压了非理性 HVs 的出发时间选择空间,促使后者向高峰中后段转移,从而减少了诱导理性 CAVs 和 HVs 出发时间后移的急迫性和所需的预算投入。

在此奖励方案下,理性 CAVs 则分布在 7:00-9:30 AM 时段内,非理性 CAVs 则集中的 7:40-9:00AM 出发。平均每轮预算总额为 2275 元/轮,略大于三类出行者共存情况下的 2012 元/轮,其平均拥堵时间为 2314 分钟,较无奖励时段的基



准拥堵时间 3519 分钟降低了 34%。然而，该方案的投资回报率和实施效能均显著低于三类主体共存的情景。结果表明，引入非理性 CAVs 能够有效提升 IBTDM 的实施效果，验证了 CAVs 的算法优势能够有效提升 IBTDM 实施效果。

5.4.3 预算约束下的优化奖励方案

在现实交通管理场景中，预算约束会显著影响奖励方案的设计空间和实施效能。为此，本研究将系统性考察预算限制对奖励方案的结构特征、系统拥堵缓解效能以及出行者的行为选择模式等维度的影响。

基于 5.4.1 节建立的数学模型框架，考虑预算约束的贝叶斯优化模型形式化表达如下：

$$\min f(\mathcal{G}) \quad (5.20)$$

$$s.t. \sum_{k=1}^3 \sum_{i \in \mathcal{N}_k} r_k(x_i^*; \mathcal{G}) \leq M \quad (5.21)$$

为解决这一具有约束条件的优化问题，本研究采用二次罚函数法进行模型转化。相较于传统的拉格朗日乘子法，该方法算法实现更为简便，且可以通过自适应惩罚系数调整确保解的可行性，数值稳定性更优。

基于此，构建了如下改进的目标函数形式：

$$\tilde{f}(\mathcal{G}) = f(\mathcal{G}) + \lambda \cdot \max \left(0, \sum_{k=1}^3 \sum_{i \in \mathcal{N}_k} r_k(x_i^*; \mathcal{G}) - M \right)^2 \quad (5.22)$$

其中 λ 为惩罚系数，决定约束严格程度。

研究采用动态自适应调整策略对惩罚系数 λ 进行优化控制。在算法初始阶段，设置相对较小的惩罚系数值 λ_0 ，以允许在可行域边界附近进行适度探索，从而避免过早陷入局部最优解。当检测到约束条件违反时，系统根据预设的更新规则对惩罚系数进行动态调整，其数学表达如下所示：

$$\lambda_{t+1} = \lambda_t \cdot (1 + \alpha) \quad (5.23)$$

此渐进式强化策略在优化初期保留一定的约束违反容忍度，有助于全面搜索解空间，而随着迭代过程的推进，通过增大惩罚系数，可以确保算法最终收敛到严格满足预算约束的可行解。

基于上述流程，研究针对 IBTDM 有限预算的实施场景需求，分别考察了预算约束为 1500 元/轮和 1000 元/轮两种情境下的优化奖励方案，以提升 IBTDM 在智能网联环境中的适应性。

5.4.3.1 1500 元/轮预算约束下的优化奖励方案



将奖励方案的预算约束设置为 1500 元/轮，研究求解得到了预算约束下的奖励方案，并从奖励形式、奖励实施结果、拥堵缓解效果三方面进行系统分析。

(1) 奖励形式

1500 元/轮的预算约束下，奖励方案的主要参数如表 5.4 所示，具体形式如图 5.17 所示：

表 5.4 智能网联环境下的优化奖励方案参数结果

对象	RBF	奖励幅值 ω	中心点参数 c	宽度参数 b
非理性 HVs 智能体	RBF1	21.12	454.08	29.74
	RBF2	38.73	471.38	35.36
理性 CAVs 和 HVs 智能体	RBF1	8.50	491.04	33.58
	RBF2	38.15	460.03	14.19
非理性 CAVs 智 能体	RBF1	33.73	525.89	35.42
	RBF2	3.28	461.67	58.40




图 5.17 预算约束下的非理性 HVs、理性 CAVs 和 HVs、非理性 CAVs 共存情况下的优化奖励方案

根据图 5.17 的优化奖励方案分析结果，在 1500 元/轮预算约束条件下，三类主体的奖励方案呈现以下特征：

1) 理性智能体的奖励方案表现出“高强度、快衰减”模式，其奖励峰值出现在 7:40 AM，随后迅速衰减：在 7:30-7:50 AM 时段维持在 30 元以上水平（持续 20 分钟），在 7:25-8:05 AM 时段保持在 20 元以上（持续 40 分钟），在 7:15-8:15 AM 时段维持在 10 元以上（持续 60 分钟）。

2) 非理性 CAVs 智能体的奖励方案具有“峰值后移、长持续”特征。其 35 元的峰值出现在 8:45 AM，在 8:05-9:25 AM 时段维持在 20 元以上，在 7:45-9:30 AM 时段保持在 10 元以上（持续 105 分钟）。

3) 非理性 HVs 智能体的奖励方案呈现“长持续、缓衰减”特征。其峰值金



额达 58 元 (7:45 AM)，显著高于其他两类出行者。具体表现为：7:15-8:15 AM 时段保持在 40 元以上 (60 分钟)，7:00-8:40 AM 时段维持在 20 元以上 (100 分钟)，7:00-8:50 AM 时段保持在 10 元以上 (110 分钟)。

此外，相较于不考虑预算约束的奖励方案，预算约束的引入导致三类主体的奖励分配模式发生显著结构性调整，具体表现为：

1) 理性智能体奖励峰值强度降低，高奖励时段缩短：尽管峰值时刻保持不变，但由于预算限制，其最高奖励金额减少，且衰减速率加快。这一变化表明，在预算约束条件下，奖励分配策略趋于集中化，同时整体奖励强度有所减弱。

2) 非理性 CAVs 智能体高奖励时段整体后移约 1 小时，其持续时间延长：这一调整源于其独特的出发时间选择机制——由于对延误成本高度敏感，非理性 CAVs 智能体倾向于集中在高峰前段出行。在无预算约束时，最优策略是在高峰中前段设置短期高额奖励，以引导出发时间后移；而预算约束下，短期高奖励难以实施，因此改为在高峰后段提供持续但强度适中的奖励。这种调整具有双重作用：一是降低高峰前段出行者的激励成本，二是通过后段持续奖励促使出行者在激励收益与延误成本之间进行更精细的权衡，从而优化出发时间选择。

3) 非理性 HVs 峰值金额显著提升，但峰值时刻和持续时间保持不变：这一优化策略主要基于两方面因素：首先，非理性 HVs 智能体本身对早高峰前段出行积极性较低；其次，非理性 CAVs 智能体在高峰前段的出行偏好进一步抑制了非理性 HVs 智能体的早期出行意愿。因此，通过增强高峰前中段的奖励强度，可有效提升非理性 HVs 智能体在该时段出行的概率，从而优化整体出行分布。

(2) 奖励实施结果

进一步分析预算约束下的优化奖励方案实施结果，在 24 轮实验周期内，1500 元/轮预算约束的优化奖励方案的平均单轮总预算为 1356.02 元，非理性 HVs 智能体、非理性 CAVs 智能体和理性智能体的预算分配占比分别为 30.3% (411.08 元)、19.4% (262.80 元) 和 50.3% (682.13 元)。

与无预算约束方案及理性假设方案对比，研究发现预算约束导致三类主体的奖励分配呈现新的结构性特征——非理性 HVs 智能体预算占比从无约束方案的 17.0% 提升至 30.3%，增幅达 20.5%；非理性 CAVs 智能体预算锐减 61.4% (从 680.77 元降至 262.80 元)，占比从 33.8% 下降至 19.4%；理性智能体绝对金额降低 31.1% (从 990.29 元降至 682.13 元)，但占比仍保持最高 (50.3%)。这说明预算约束促使方案发生以下策略性调整：

- 1) 强化对非理性 HVs 智能体的奖励 (+20.5%)；
- 2) 大幅削减非理性 CAVs 智能体预算 (-61.4%)；
- 3) 保持理性智能体的主导地位，但通过降低峰值奖励 (-31.1%) 实现预算节

约。

此外，上述预算约束下的奖励方案形式表明，预算约束下的优化方案呈现出非对称调整特征：某些智能体（如非理性 HVs 智能体）的奖励强度不降反升。这一现象证实了仿真优化框架的有效性——算法能够突破传统参数搜索空间的限制，基于主体反馈调整奖励组合，而非简单地在峰值、持续期等维度进行线性约束，因而研究采用的优化框架能够在预算约束条件下实现奖励资源高效配置。

(3) 拥堵缓解效果

图 5.18 展示了实施优化奖励方案后的出行者出发时间选择分布特征，结果表明，该方案能有效优化系统出发时间分布，显著改善交通流均衡性。为进一步量化评估该奖励方案的实施效果，本研究采用系统总延误作为指标，对比了理性假设下的优化奖励方案、无预算限制下的优化奖励方案以及预算约束下的优化奖励方案（即本研究所提方案）的实施效果，具体对比结果如图 5.19 所示：




图 5.18 非理性 HVs、理性 CAVs 和 HVs、非理性 CAVs 共存情况下的出发时间选择




图 5.19 奖励方案实施效果对比图

基于图 5.19 发现，预算约束条件下的优化奖励方案展现出卓越的收敛特性，



其能够在有限迭代次数内实现系统快速收敛，并稳定维持于最优拥堵水平区间。这一特性表明，该方案具有较高的工程实用价值。

此外，在该单道路、小规模出行者的智能网联仿真场景中，优化方案的平均系统延误降至 1554 分钟，较理性假设下的方案（3346 分钟）实现 53.5% 的改善幅度，较基准无奖励方案（4303 分钟）更取得 63.9% 的显著提升。这一量化结果充分验证了该方案在交通需求管理方面的卓越效能。

最后，在预算约束条件下，该优化方案投资回报率达到 2.03 分钟/元，较无预算约束方案（1.59 分钟/元）提升了 27.7%。这一发现揭示了奖励机制存在的边际效用递减规律：在有限预算范围内，奖励投入能够实现较好的拥堵缓解效果；然而随着奖励预算的持续增加，其对拥堵改善的边际贡献呈现递减趋势。

5.4.3.2 1000 元/轮预算约束下的优化奖励方案

为了进一步探究奖励方案在小预算情况下的实施效果，研究进一步将预算约束下调为 1000 元/轮，得到奖励方案如图 5.20 所示。




图 5.20 1000 元/轮预算约束下的非理性 HVs、理性 CAVs 和 HVs、非理性 CAVs 共存情况下的优化奖励方案

由图 5.20 可得，进一步减少奖励方案预算后，优化奖励方案的主要调整思路为，系统性地降低对理性智能体和非理性 CAVs 智能体的奖励强度，奖励资源配置向非理性 HVs 智能体倾斜。其中，在 24 轮实验周期内，优化奖励方案的平均单轮总预算为 753.61 元，非理性 HVs 智能体、非理性 CAVs 智能体和理性智能体的预算分配占比分别为 64.65%（487.25 元）、0.05%（0.41 元）和 35.30%（265.95 元）。

为进一步量化评估该奖励方案的实施效果，本研究通过图 5.21 展示了实施该方案后的出行者出发时间选择分布特征；并将该方案与三个基准方案（理性假

设下的优化奖励方案、无预算约束方案及 1500 元/轮预算方案) 进行系统比较以揭示不同约束条件下的策略效能差异, 结果如图 5.22 所示。




图 5.21 非理性 HVs、理性 CAVs 和 HVs、非理性 CAVs 共存情况下的的出发时间选择




图 5.22 奖励方案实施效果对比图

由图 5.22 可得, 在 1000 元/轮的预算约束条件下, 奖励方案虽能有效降低系统延误, 但其收敛性能存在明显缺陷。具体而言, 该方案将系统平均延误降低至 1967 分钟, 较理性假设下的时变方案实现了明显改善, 同时投资回报率达到 3.10 分钟/元, 这一指标进一步优于 1500 元/轮预算约束下的方案表现。然而受限于预算约束, 该方案的行为诱导效果呈现出显著波动特征——在 24 轮的实验周期内未能形成稳定的收敛态势。

这一现象表明, 当预算约束过于严苛时, 优化过程可能以牺牲方案收敛性为代价来换取拥堵缓解效果, 从而导致方案的实际应用价值受限。基于此, 具有实践价值的奖励方案必须兼具理论严谨性和实践可行性: 既保证足够的奖励强度以维持行为调控的稳定性, 又在既定资源约束下实现系统效能的帕累托改进。



5.5 本章小结

本章引入非理性 CAVs 智能体,以模拟 CAVs 在信息不对称条件下的出发时间选择特征,并构建多智能体仿真模型,动态建模理性 CAVs 与 HVs、非理性 HVs 与非理性 CAVs 之间的认知偏差与出发时间选择行为耦合演化过程,在此基础上对奖励方案进行了效果评估与优化设计。该异质主体行为仿真与优化框架可进一步拓展至路径选择、出行方式转换等维度的 IBTDM 策略设计,为奖励机制构建提供方法借鉴与思路启示。主要研究发现如下:

(1) 三类主体的出发时间选择模式呈现异质性,且在三类主体共存的环境中,系统表现及个体行为并非各自独立行为模式的线性叠加。具体而言:1) 非理性 CAVs 智能体表现出明显的“早期偏好”;2) 非理性 HVs 智能体保持其固有的“中期偏好”;3) 理性 CAVs 和 HVs 智能体呈现“全高峰分布”特征。

(2) 三类主体共存场景下,行为效能存在显著不同:1) 理性 CAVs 和 HVs 智能体能有效缓解系统拥堵,是奖励最优目标群体,且非理性 CAVs 在完全信息下可进一步发挥协同选择优势,因而可构建 IBTDM-CAVs 协作机制,由 IBTDM 提供完全信息增强 CAVs 理性选择能力。2) 非理性 HVs 惯性较强,出发时间调整幅度较小,需对其采用强刺激表达与即时反馈诱导策略以增强干预效果。

(3) 采用基于智能增强的仿真优化方法,提出了基于多类型主体的奖励方案优化思路,在小规模出行者的智能网联场景中,优化奖励方案的预算投资回报率较理性假设方案提升近 5 倍。研究进一步发现:1) 理性 CAVs 和 HVs、非理性 HVs 共存情境中,理性主体奖励集中于高峰后段,非理性 HVs 奖励集中于前中段,因而可实施分时段奖励策略;2) 引入非理性 CAVs 后,不再需要在高峰末端施加高额奖励。

本章所优化的奖励方案在 100% 市场渗透率下实施,预算水平过低时行为诱导效果不稳定,这印证了第 3 章的全局-个体协调奖励方案的实践意义——在预算资源有限时,若仍试图将 IBTDM 覆盖全体出行者,易导致宣传资源浪费(激励成本难以调控项目用户的出发时间选择)。因此在预算受限时应当合理分配激励和宣传资源,实施面向部分主体的奖励方案,避免全覆盖模式的行为调控失效。





第6章 结论与展望

6.1 主要研究成果

本论文立足于智能网联环境下基于奖励的交通需求管理方案优化。鉴于改变出发时间策略在行为引导中的可行性与应用潜力,及其对智能网联环境的良好适应性和扩展性,研究聚焦于高峰通勤情境下的逐日出发时间选择行为。首先,通过瓶颈模型解析智能网联环境中理性主体(包含部分 HVs 和 CAVs)的出发时间选择机制,制定预算分配方案和理性假设下的时变奖励方案;然后,针对智能网联环境中的非理性 HVs,分析其在奖励影响下的出发时间选择特征,识别 IBTDM 目标用户,进而构建非理性 HVs 的出发时间选择行为预测模型。随后,整合理性主体(HVs 和 CAVs)出发时间选择机制和非理性 HVs 出发时间选择行为预测研究,引入非理性 CAVs 出发时间选择特征,构建智能网联环境下的基于智能体的仿真框架,再现异质主体交互过程并评估奖励方案的实施效能,最后,考虑主体异质性,提出基于主体类型的奖励优化方案,实现智能网联环境下 IBTDM 方案优化。本研究提出的出发时间维度的异质行为建模与仿真优化框架,可拓展至路径选择及出行方式转换等维度,为 IBTDM 方案设计提供行为建模基础与方法支持;所形成的基于主体类型的时变奖励机制,为智能网联环境下多维度交通需求管理策略的设计与融合实施提供可行路径,有助于提升 IBTDM 治理效能。主要研究成果总结如下:

(1)针对智能网联环境中的理性 CAVs 和 HVs,解析其个体出发时间选择机制,求解了仅存在理性 CAVs 和 HVs 时的最优预算分配方案及 IBTDM 全局约束下的最优时变奖励方案。

研究通过单起点-终点单瓶颈交通场景建模,系统考察了 IBTDM 全局约束(预算、渗透率等)与个体出发时间选择机制对理性 CAVs 和 HVs 交通需求管理效果的联合影响。首先,基于经典单瓶颈模型,构建适用于理性 CAVs 和 HVs 的出发时间选择行为框架,系统解析其在奖励影响下的出发时间选择机制。其次,考虑智能网联环境下 CAVs 和 HVs 的不同宣传方式及其难度导致的单位宣传成本差异,分析了奖励预算在宣传成本和激励成本之间的最优分配方案,以在预算约束下最小化系统总行驶时间,研究发现,奖励策略应该首先吸引单位宣传成本较低的 CAVs 用户;最优渗透率不会相对于总预算严格提高,因此 IBTDM 项目需要准确估算总预算以及人均宣传成本,以确定最优奖励策略;最后,将初始出发时间纳入理性 CAVs 和 HVs 出行成本评估体系,通过解析方法量化了其出



发时间选择的影响，设计了考虑初始出发时间的最优时变奖励方案，结果表明：用户的单位出发时间偏移量成本 θ 和单位行驶时间成本 α 的相对大小对最优奖励方案形式及拥堵缓解效果具有决定性影响。

(2) 针对智能网联环境中的非理性 HVs，开展问卷调查和长时交互实验获取其行为数据集，探究其逐日出发时间选择特征及影响因素，并采用 Transformer 架构构建出发时间选择行为预测模型。

为应对非理性 HVs 出发时间选择行为难预测挑战，研究依托高德平台开展了多样化奖励策略偏好调查，构建了涵盖出发时间调整与出行方式转换奖励策略的非理性 HVs 策略偏好数据集。通过结构方程模型分析发现：影响出发时间调整策略接受度的关键因素为公共交通倾向性、月收入与出行天数；而影响出行方式转换策略接受度的主要因素则为公共交通倾向性、私家车保有量与 OD 组合特征。然后，开展长时交互实验室实验获取用户在时变奖励方案下的出发时间逐日动态演化数据，运用面板数据分析、聚类 and 回归等方法识别个体出发时间选择关键影响因素。具体而言，非理性 HVs 的出发时间选择受月收入水平、年龄、教育程度、驾照持有状态、实验机制理解程度、通勤频率等关键变量影响。基于此，研究确定了预测变量体系，并采用 Transformer 架构建立了奖励影响下的非理性 HVs 出发时间选择行为预测模型，该模型在逐日出发时间预测准确度上相较于传统基准模型（如 LSTM 和神经网络）提升 35% 以上，以提升对异质、动态非理性行为的建模与预测能力。

(3) 针对智能网联环境中的全体主体（理性 CAVs 和 HVs、非理性 HVs 以及非理性 CAVs），构建了多智能体仿真框架，通过双层建模并结合贝叶斯优化算法，提出了基于主体类型的优化奖励方案。

针对智能网联环境下的早高峰逐日出发时间选择场景，研究构建了基于智能体的仿真建模框架，设计了三类主体——理性 CAVs 和 HVs 智能体、非理性 HVs 智能体、非理性 CAVs 智能体的动态出发时间选择机制，并刻画了其对交通环境及交互行为的感知能力。其次，基于上述建模设计，研究系统评估了不同智能体比例下奖励方案的实施效果以及各智能体的行为特征。分析表明，非理性 HVs 智能体表现出较强的出发时间偏好和较为保守的出发时间调整特征。特别地，理性 CAVs 和 HVs 智能体能有效降低系统拥堵，是实现智能网联环境下奖励最优效能的目标群体；非理性 CAVs 可在完全信息条件下，凭借协同选择能力缓解个体博弈带来的选择震荡和次优收敛，实现系统最优均衡。最后，研究提出了基于智能增强的奖励方案仿真优化方法：考虑主体出发时间异质选择机制，设计基于主体类型的奖励方案形式，构建双层模型，利用贝叶斯优化算法和多智能体仿真技术，通过持续学习历史仿真数据，明确参数优化方向，最终实现预算约束下智能网联



环境中的基于主体类型的奖励方案优化。在小规模出行者的智能网联场景中，优化奖励方案的优化后的方案在减少奖励预算的同时显著提升了系统效能——与理性假设下的奖励方案相比，系统总延误降低 60%以上；相较于无奖励基准场景，延误降幅超过 70%；同时，投资回报率较理性假设方案提高近 5 倍。

6.2 研究创新点与贡献

本研究面向 HVs 和 CAVs 共存的智能网联交通环境，针对早高峰出发时间选择场景，优化了基于奖励的交通需求管理策略，具体创新点和贡献可总结如下：

(1) 基于理性行为假设，将获取用户的宣传成本纳入预算框架，提出了宣传-激励成本优化分配方法，实现预算在“用户获取”与“行为引导”阶段的统筹配置。

鉴于 IBTDM 的非强制性特征，其实施需先通过宣传提高市场渗透率以扩大可调节人群范围，继而通过激励成本引导出行行为调整。现有研究普遍忽视用户获取阶段的宣传支出问题，易导致资源配置失衡——激励成本无法有效覆盖用户群体或者宣传投入不足导致用户基数过小，进而削弱奖励效能。为此，研究将宣传成本投入纳入 IBTDM 预算优化框架，提出了考虑理性 CAVs 与 HVs 异质性的资源配置方法。首先，引入市场渗透率作为中介变量，量化了宣传成本支出与可奖励用户规模的关系，系统揭示宣传投入对奖励效能的作用机制；其次，构建包含宣传与激励双重成本的预算配置模型，明确预算配置对 IBTDM 覆盖范围与行为调控效果的影响路径，并推导 CAVs 和 HVs 最优市场渗透率及激励成本分配的解析解，实现预算在“用户获取”与“行为诱导”两阶段的高效统筹配置。该方法有效规避了因宣传成本投入不足或浪费而导致的 IBTDM 失效风险，拓展了出行需求管理的研究视角，为智能网联环境下 IBTDM 设计提供理论与方法支撑。

(2) 设计了长时追踪与可控实验相结合的非理性 HVs 行为观测机制，提升非理性 HVs 的参与持续性，增强长时逐日行为数据的时序连续性和可靠性。

当前 IBTDM 研究中，非理性 HVs 的行为采集机制普遍采用短期集中式多轮选择方式，难以刻画奖励影响下的真实长时行为演化过程，限制了对非理性行为及其动态变化规律的识别。为应对该问题，本研究设计了包含“缺席成本惩罚—缺席奖励扣减—累计排名奖励”的逐日出发时间选择观测机制。首先，实验采用天为单位的選擇周期，克服了传统实验中思考时间受限所导致的行为失真问题，有效捕捉奖励对出发时间选择的长时影响。其次，为减少长周期实验中的样本流失，实验通过设定缺席轮次成本（205 元，即样本最大成本值），阶梯式缺席奖励扣减（缺席两天累计奖励扣减 5%，三天扣减 25%），以及依据累计出行成本排名统一发放奖励等方式，提升行为数据的真实性、稳定性及完整性。该实验设计突



破了以往非理性行为采集中存在的因受试者思考时间不足引起的行为波动、长时样本流失以及预算控制等关键挑战，为表征非理性 HVs 在 IBTDM 方案下的逐日出行行为选择提供了可靠数据支撑。

(3) 提出了基于智能增强的奖励方案仿真优化方法，提升奖励方案效能与系统长时稳定性。

当前异质主体环境下的奖励方案设计多依赖理性假设与静态建模框架，难以捕捉奖励策略在逐日出发时间选择情境中的效能动态变化，限制了其持续引导交通系统趋向最优状态的能力。针对上述问题，研究提出了融合 IBTDM 专家经验与智能算法的基于智能增强的仿真优化方法，在保留 IBTDM 决策可控的前提下，通过数据驱动的学习机制实现策略自适应优化。一方面，融合 IBTDM 仿真评估结果及先验知识，明确奖励形式与约束条件，并采用基函数分解方法将无限维的奖励曲线优化问题降维至有限参数空间，借助仿真模型评估不同参数组合的长时系统效能，有效降低问题维度与长时效能计算复杂度；另一方面，通过持续学习历史仿真结果并预测未来趋势，指导参数优化方向以实现奖励策略自适应优化，辅助管理部门调整 IBTDM 机制，不仅提升了奖励方案优化的效率、灵活性及其对动态复杂环境的适应能力，还保障了长时优化效能的稳定，增强了方案的可解释性与可实施性。

6.3 研究不足与展望

本研究虽然取得了部分成果，但尚有许多有待进一步深入进行的研究工作，总结如下：

(1) 宣传成本-用户规模关系与出行者参数同质性的建模拓展

当前理论模型及仿真模型构建均基于简化假设，例如宣传成本与用户规模（即固定群体中的渗透率）的线性关系，所有出行者具有相同的期望到达时间、单位延误成本等参数设定。然而，这些假设在刻画非理性行为和智能网联环境特征时存在局限性：首先，宣传效果在实际中往往呈现非线性特征；其次，出行者因通勤目的、工作时间等因素，其期望到达时间、出行偏好和成本感知存在显著差异。因而在后续研究中，研究需开展面向更广泛出行群体的问卷调查，量化分析边际宣传成本随渗透率的演化规律，建立更准确的宣传效果预测模型。同时，需考虑不同出行者的参数差异性，相应完善成本量化及出发时间选择机制，据此推导奖励方案。

(2) 智能网联环境下奖励预算配置方案深化

当前研究在理性行为假设下构建了宣传成本与激励成本的分配框架——通



过对 CAVs 与 HVs 群体设置异质宣传成本,影响 IBTDM 在异质群体中的市场渗透率,进而可以影响其覆盖范围与调控成效。然而,除宣传成本和用户规模可能存在非线性关系之外,智能网联环境中的出行者,特别是非理性 HVs,对 IBTDM 的接受度呈现出显著的个体差异性,导致个体层面的宣传响应和宣传成本难以预测;同时,现有研究尚缺乏关于 CAVs 宣传成本与非理性 HVs 宣传成本相对量级关系的实证数据支持。更为复杂的是,在宣传-激励成本配置时,宣传目标群体的确定仍需综合考虑出行行为、奖励敏感性与宣传成本之间的动态交互机制。因而,当前并未开展关于有限预算条件下激励-宣传成本分配的研究。未来研究可通过实验设计模拟参与者与非参与者共存的交通环境,重点探究三个关键问题:1) 在不完全市场渗透率下主体出发时间选择机制;2) 宣传成本的影响因素与量化;3) 预算约束下激励与宣传成本的最优分配策略,以提升智能网联环境下奖励策略的现实可行性。

(3) 非理性 HVs 行为分析中的问卷效度、实验机制与样本偏差问题

当前研究采用问卷调查与实验室实验相结合的方法,采集非理性 HVs 出发时间选择数据并分析其特征,仍在问卷设计、实验机制及样本一致性等方面存在不足,需进一步深入探索与完善:首先,在问卷调查设计上,需进一步提升方法学严谨性,特别要加强对社会偏好行为(如利他主义、公平意识等)、引导性偏差以及功利性决策倾向的系统性评估,从而提高实验数据的可靠性。其次,在实验验证方面,当前研究采用了长时逐日选择实验,但未来仍需将此实验数据与短时多轮次实验的实际选择行为进行对比,以评估时间维度对决实验设计的影响。此外,受限于数据采集条件,本研究存在样本一致性问题:问卷调查数据通过高德平台获取,更关注样本是否具有 IBTDM 实际经验,以缓解实验场景真实性带来的选择偏差;而实验数据则通过线下宣传招募获得,两类样本并不相同。后续研究应优化样本招募策略,确保问卷调查与实验被试群体的一致性,以增强研究结论的可靠性。

(4) 考虑出行路径选择、出行模式等的 IBTDM 策略优化

本研究目前基于单瓶颈模型开展出发时间选择的奖励策略优化研究,虽然该方法能够有效解析基础行为机理并构建适用于简单场景的奖励方案,但在实际交通系统应用中仍存在模型简化过度 and 策略维度单一等局限性。为提升研究成果的实际应用价值,后续研究亟需在以下维度进行拓展:首先,将研究框架拓展至交通网络环境,获取更贴近真实世界的大规模出行选择数据,以支持奖励方案在实际路网中的设计优化;其次,需要将研究范畴从出发时间选择延伸至路径选择和出行模式转换等行为,考察奖励机制对各类出行行为转变的影响。特别是出行路径选择问题可以实现与 CAVs 技术更好的耦合,充分发挥 CAVs 在提升系统效能



方面的技术优势。

(5) 用户规模与奖励预算的关系拓展

本研究在建模过程中将预算强度视为与时间相关的外生变量，未考虑用户渗透率对预算的动态影响，这一假设适用于奖励预算来源于固定拨款的试点阶段。然而，随着 IBTDM 系统的规模化部署，其预算主要来源（如政府财政支持、平台广告收入及匿名数据交易）均与用户规模密切相关，现有模型未能充分反映这一耦合关系。未来研究可进一步构建预算与用户规模的双向反馈机制，量化广告收益弹性、数据价值评估及政府投入对预算的影响，从而揭示更符合现实情境的预算形成逻辑。在此基础上，可探索面向长期投资优化、阶段性推广策略及用户增长场景的 IBTDM 方案。

(6) IBTDM 策略的实际落地推进

本研究基于仿真验证了基于奖励的出发时间调控策略的有效性，但在现实推广中，仍存在奖励资金持续性不足、公众长期参与积极性下降、用户隐私数据采集的合法合规性，以及缺乏明确法律政策支持等问题。未来研究可进一步结合真实试点数据，探索政府财政与企业共建相结合的资金机制，设计具有反馈奖励和积分成长等机制的持续参与方案，同时引入“知情同意”与“数据最小化”等隐私保护策略，并推动 IBTDM 相关政策法规的制度化建设，以增强研究成果的落地可行性与政策指导价值。



参考文献

- [1] Youn H, Gastner M T, Jeong H. Price of anarchy in transportation networks: Efficiency and optimality control[J]. *Physical Review Letters*, 2008, 101(12): 128701.
- [2] Morandi V. Bridging the user equilibrium and the system optimum in static traffic assignment: a review[J]. *4OR*, 2024, 22(1): 89-119.
- [3] Roughgarden T, Tardos É. How bad is selfish routing?[J]. *Journal of the ACM*, 2002, 49(2): 236–259.
- [4] Vickrey W S. Congestion theory and transport investment[J]. *The American economic review*, 1969, 59(2): 251-260.
- [5] Guo Q, Ban X, Aziz H M A. Mixed traffic flow of human driven vehicles and automated vehicles on dynamic transportation networks[J]. *Transportation Research Part C: Emerging Technologies*, 2021, 128: 103159.
- [6] Zhang K, Nie Y. Mitigating the impact of selfish routing: An optimal-ratio control scheme (ORCS) inspired by autonomous driving[J]. *Transportation Research Part C: Emerging Technologies*, 2018, 87: 75-90.
- [7] Houshmand A, Wollenstein-Betech S, Cassandras C G. The penetration rate effect of connected and automated vehicles in mixed traffic routing[C]//*Proceedings of the 2019 IEEE Intelligent Transportation Systems Conference (ITSC)*, 2019.
- [8] Chen Z, Lin X, Yin Y, et al. Path controlling of automated vehicles for system optimum on transportation networks with heterogeneous traffic stream[J]. *Transportation Research Part C: Emerging Technologies*, 2020, 110: 312-329.
- [9] Hu X, Yi-Chang C, and Shelton J. Development of a behaviorally induced system optimal travel demand management system[J]. *Journal of Intelligent Transportation Systems*, 2017, 21(1): 12-25.
- [10] Jahn O, Möhring R H, Schulz A S, et al. System-optimal routing of traffic flows with user constraints in networks with congestion[J]. *Operations Research*, 2005, 53(4): 600-616.
- [11] Levy N, Klein I, Ben-Elia E. Emergence of cooperation and a fair system optimum in road networks: A game-theoretic and agent-based modelling approach[J]. *Research in Transportation Economics*, 2018, 68: 46-55.
- [12] 陈艳艳. 国外有哪些可供借鉴的交通需求管理经验[J]. *汽车与安全*, 2018, (11): 76-81.
- [13] Hau D T. Electronic road pricing: developments in Hong Kong 1983-1989[J]. *Journal of Transport Economics and Policy*, 1990, 24(2): 203-214.
- [14] Hu X, Zhu X, Chiu Y-C, et al. Will information and incentive affect traveler's day-to-day departure time decisions?—An empirical study of decision making evolution process[J]. *International Journal of Sustainable Transportation*, 2020, 14(6): 403-412.
- [15] Pan Y, Wu Y, Xu L, et al. The impacts of connected autonomous vehicles on mixed traffic flow: A comprehensive review[J]. *Physica A: Statistical Mechanics and its Applications*, 2024, 635: 129454.
- [16] Li J, Yu C, Shen Z, et al. A survey on urban traffic control under mixed traffic environment with connected automated vehicles[J]. *Transportation Research Part C: Emerging Technologies*, 2023, 154: 104258.



参考文献

- [17] Rouwendal J, Verhoef E T, Knockaert J. Give or take? Rewards versus charges for a congested bottleneck[J]. *Regional Science and Urban Economics*, 2012, 42(1-2): 166-176.
- [18] Sun J, Wu J, Xiao F, et al. Managing bottleneck congestion with incentives[J]. *Transportation Research Part B: Methodological*, 2020, 134: 143-166.
- [19] Wu J, Tian Y, Sun J, et al. Public or private? Optimal organization for incentive-based travel demand management[J]. *Transportation Research Part E: Logistics and Transportation Review*, 2023, 174: 103137.
- [20] Lemp J D, Kockelman K M, Damien P. The continuous cross-nested logit model: Formulation and application for departure time choice[J]. *Transportation Research Part B: Methodological*, 2010, 44(5): 646-661.
- [21] Arian A, Ermagun A, Zhu X, et al. Chapter Six - An empirical investigation of the reward incentive and trip purposes on departure time behavior change[M]//SHIFTAN Y, KAMARGIANNI M. *Advances in Transport Policy and Planning*. Academic Press. 2018: 145-167.
- [22] Shen Q, Wang Y, Gifford C. Exploring partnership between transit agency and shared mobility company: an incentive program for app-based carpooling[J]. *Transportation*, 2021, 48(5): 2585-2603.
- [23] Li R, Liu X, Nie Y. Managing partially automated network traffic flow: Efficiency vs. stability[J]. *Transportation Research Part B: Methodological*, 2018, 114: 300-324.
- [24] Zhao L, Guo J, Lei C, et al. Effect of dynamic route guidance on urban traffic network under Connected Vehicle environment[J]. *European Journal of Transport and Infrastructure Research*, 2019, 19: 142-159.
- [25] Bauer J, Bedsole L, Snyder K, et al., Expanding Traveler Choices Through the Use of Incentives: A Compendium of Examples[R]: United States. Federal Highway Administration, 2018.
- [26] Hu X, Chiu Y-C, Zhu L. Behavior insights for an Incentive-Based Active Demand Management platform[J]. *International Journal of Transportation Science and Technology*, 2015, 4(2): 119-133.
- [27] Seilabi S E, Pourgholamali M, Homem de Almeida Correia G, et al. Robust design of CAV-Dedicated lanes considering CAV demand uncertainty and lane reallocation policy[J]. *Transportation Research Part D: Transport and Environment*, 2023, 121: 103827.
- [28] Ettema D, Knockaert J, Verhoef E. Using incentives as traffic management tool: empirical results of the "peak avoidance" experiment[J]. *Transportation Letters*, 2010, 2(1): 39-51.
- [29] Merugu D, Prabhakar B S, Rama N. An incentive mechanism for decongesting the roads: A pilot program in Bangalore[C]//*Proceedings of the Workshop on the Economics of Networks, Systems and Computation*, California, USA, 2009.
- [30] Land Transport Authority[EB/OL]. 2019. <https://www.lta.gov.sg/>.
- [31] Fujii S, Kitamura R. What does a one-month free bus ticket do to habitual drivers? An experimental analysis of habit and attitude change[J]. *Transportation*, 2003, 30(1): 81-95.
- [32] Bamberg S, Ajzen I, Schmidt P. Choice of travel mode in the theory of planned behavior: The roles of past behavior, habit, and reasoned action[J]. *Basic and applied social psychology*, 2003, 25(3): 175-187.
- [33] Currie G. Free fare incentives to shift rail demand peaks--medium-term impacts[C]//*Proceedings of the Transportation Research Board 90th Annual Meeting*, Washington DC, USA, 2011.
- [34] Dickinson J E, Ghali K, Cherrett T, et al. Tourism and the smartphone app: capabilities, emerging



参考文献

- practice and scope in the travel domain[J]. *Current Issues in Tourism*, 2012, 17(1): 84-101.
- [35] 张健钦, 王刚, 刘纯波. 基于 GPS 智能手机的交通信息实时采集与服务研究[J]. *交通世界(运输车辆)*, 2007, 2007(02X): 82-84.
- [36] Zhu C, Yue J S, Mandayam C V, et al. Reducing road congestion through incentives: a case study[C]. *Transportation Research Board 94th Annual Meeting*. Washington DC, USA, 2015.
- [37] Ben-Elia E, Ettema D. Carrots versus sticks: Rewarding commuters for avoiding the rush-hour—a study of willingness to participate[J]. *Transport Policy*, 2009, 16(2): 68-76.
- [38] Donovan S. Introducing Spitsmijden—experiments with peak avoidance incentives in the Netherlands[C]. *Transportation Research Board 89th Annual Meeting*. Washington DC, USA, 2010.
- [39] Pluntke C, Prabhakar B. INSINC: A platform for managing peak demand in public transit[J]. *JOURNEYS*, Land Transport Authority Academy of Singapore, 2013, 2013(2013): 31-39.
- [40] Greene-Roesel R, Castiglione J, Guiriba C, et al. BART perks: using incentives to manage transit demand[J]. *Transportation Research Record*, 2018, 2672(8): 557-565.
- [41] Amadori M, Liguori G, Bristow C. Game of Phones[J]. *Thinking Cities*, 2017, 4(2): 48-51.
- [42] Lee C, Winters P, Pino J, et al., Improving the Cost Effectiveness of Financial Incentives in Managing Travel Demand Management (TDM)[R], 2013.
- [43] IncenTrip[EB/OL]. 2019. <https://www.incentrip.org/>.
- [44] 生态环境部宣传教育中心, 北京绿普惠网络科技有限公司, 中国碳普惠发展与实践案例研究报告[R], 2023.
- [45] Srinivasan A. Leveraging smartphones to incentivize city-wide, energy efficient transportation[D]; Massachusetts Institute of Technology, 2017.
- [46] Pigou A C. The economics of welfare[M]. London, UK, 1920.
- [47] Arnott R. Congestion tolling with agglomeration externalities[J]. *Journal of Urban Economics*, 2007, 62(2): 187-203.
- [48] Friesz T L, Bernstein D, Kydes N. Dynamic congestion pricing in disequilibrium[J]. *Networks and Spatial Economics*, 2004, 4(2): 181-202.
- [49] 史峰, 李志纯. 网络扩容和拥挤道路使用收费的组合模型及求解算法[J]. *中国公路学报*, 2003, 16(2): 90.
- [50] Arnott R, De Palma A, Lindsey R. The welfare effects of congestion tolls with heterogeneous commuters[J]. *Journal of Transport Economics and Policy*, 1994, 28(2): 139-161.
- [51] Verhoef E T. Second-best congestion pricing in general networks. Heuristic algorithms for finding second-best optimal toll levels and toll points[J]. *Transportation Research Part B: Methodological*, 2002, 36(8): 707-729.
- [52] Liu Z, Wang S, Meng Q. Optimal joint distance and time toll for cordon-based congestion pricing[J]. *Transportation Research Part B: Methodological*, 2014, 69: 81-97.
- [53] 李志纯, 丁晶. 基于活动方法的瓶颈模型与拥挤收费问题研究[J]. *管理科学学报*, 2017, 20: 93-101.
- [54] Arnott R, de Palma A, Lindsey R. Economics of a bottleneck[J]. *Journal of Urban Economics*, 1985, 27(1): 111-130.
- [55] Chakraborty S, D. Rey and S. T. Waller. A linear programming formulation for Incentive-based Travel Demand Management[C]//*Proceedings of the 7th International Symposium on Dynamic Traffic Assignment*, Hong Kong, China, 2018.



参考文献

- [56] Wu J, Tian Y, Sun J. A bilevel programming framework for determining the optimal Incentive-Based Traffic Demand Management strategy[C]//Proceedings of the 19th COTA International Conference of Transportation Professionals, 2019.
- [57] Cohen Y. Commuter welfare under peak-period congestion tolls: Who gains and who loses?[J]. International Journal of Transport Economics/Rivista internazionale di economia dei trasporti, 1987, 14(3): 239-266.
- [58] Arnott R, de Palma A, Lindsey R. A structural model of peak-period congestion: A traffic bottleneck with elastic demand[J]. The American economic review, 1993, 83(1): 161-179.
- [59] Arnott R, de Palma A, Lindsey R. Schedule delay and departure time decisions with heterogeneous commuters[J]. Transportation Research Record, 1988, 1197: 56-67.
- [60] Noland R B, Cowart W A, Fulton L M. Travel demand policies for saving oil during a supply emergency[J]. Energy Policy, 2006, 34(17): 2994-3005.
- [61] Caulfield B. Estimating the environmental benefits of ride-sharing: A case study of Dublin[J]. Transportation Research Part D Transport & Environment, 2009, 14(7): 527-531.
- [62] Brownstone D, Golob T F. The effectiveness of ridesharing incentives: Discrete-choice models of commuting in Southern California[J]. Regional Science and Urban Economics, 1992, 22(1): 5-24.
- [63] Agatz N, Erera A, Savelsbergh M, et al. Optimization for dynamic ride-sharing: A review[J]. European Journal of Operational Research, 2012, 223(2): 295-303.
- [64] 李梦, 黄海军. 考虑共享出行的用户均衡交通分配模型[J]. 系统工程理论与实践, 2019, 39: 10.
- [65] 孙剑, 吴纪葵, 李政, 等. 市场渗透率约束下的拼车奖励方案优化模型[J]. 华南理工大学学报(自然科学版), 2024, 52(6): 12-23.
- [66] Wu J, Tian Y, Sun J. Managing ridesharing with incentives in a bottleneck model[J]. Research in Transportation Economics, 2023, 101: 101349.
- [67] 杜宁睿, 许宁. 试论以公共交通为导向的城市发展[J]. 规划师, 2003, 2003(11): 94-95.
- [68] 张小宁. 鼓励公交出行的综合管理对策[J]. 交通与运输, 2012, 2012(01): 1-3.
- [69] 曾秋霖. 城市公交补贴模型及补贴机制研究[D]. 陕西; 长安大学, 2017.
- [70] 宋凤. 我国城市公交补贴方法研究[D]. 北京; 北京交通大学, 2012.
- [71] 章玉. 公共交通补贴的效率与机制研究[D]. 重庆; 重庆交通大学, 2017.
- [72] 覃运梅, 石琴. 出租车合乘模式的探讨[J]. 合肥工业大学学报(自然科学版), 2006, 2006(01): 77-79.
- [73] 汤黎明, 刘其华. 邻里合乘——社区拼车常态化的探索[J]. 城市交通, 2010, 2010(06): 29-33.
- [74] 景鹏, 隗志才, 查奇芬. 考虑心理潜变量的出行方式选择行为模型[J]. 中国公路学报, 2014, 27(11): 88-92, 108.
- [75] Ünal A B, Steg L, Granskaya J. "To support or not to support, that is the question". Testing the VBN theory in predicting support for car use reduction policies in Russia[J]. Transportation Research Part A: Policy and Practice, 2019, 119: 73-81.
- [76] Selmoune A, Cheng Q, Wang L, et al. Influencing factors in congestion pricing acceptability: A literature review[J]. Journal of Advanced Transportation, 2020, 2020: 4242964.
- [77] Giuliano G. An assessment of the political acceptability of congestion pricing[J]. Transportation, 1992, 19(4): 335-358.
- [78] Sommer S, Mattauch L, Pahle M. Supporting carbon taxes: The role of fairness[J]. Ecological



- Economics, 2022, 195: 107359.
- [79] Jia N, Zhang Y, He Z, et al. Commuters' acceptance of and behavior reactions to license plate restriction policy: A case study of Tianjin, China[J]. *Transportation Research Part D: Transport and Environment*, 2017, 52: 428-440.
- [80] Luo M, Ma Z, Zhao W, et al. An ex-post evaluation of the public acceptance of a license plate-based restriction policy: A case study of Xi'an, China[J]. *Transportation Research Part A: Policy and Practice*, 2022, 155: 259-282.
- [81] 秦焕美, 高建强, 和士辉, 等. 基于奖罚措施的小汽车通勤者出行行为研究[J]. *交通运输系统工程与信息*, 2018, 18(1): 115-120.
- [82] Bueno P C, Gomez J, Peters J R, et al. Understanding the effects of transit benefits on employees' travel behavior: Evidence from the New York-New Jersey region[J]. *Transportation Research Part A: Policy and Practice*, 2017, 99: 1-13.
- [83] Lin B, Yang M. Choosing the right policy: Factors influencing the preferences of consumption-side personal carbon reduction policies[J]. *Journal of Environmental Management*, 2023, 326: 116706.
- [84] Bulteau J, Feuillet T, Dantan S, et al. Encouraging carpooling for commuting in the Paris area (France): which incentives and for whom?[J]. *Transportation*, 2023, 50(1): 43-62.
- [85] Cools M, Moons E, Creemers L, et al. Changes in travel behavior in response to weather conditions: Do type of weather and trip purpose matter[J]. *Transportation Research Record*, 2010, 2157(1): 22-28.
- [86] Lowe W U A, Piantanakulchai M. Investigation of behavioral influences of carpool adoption for educational trips – A case study of Thammasat University, Thailand[J]. *Case Studies on Transport Policy*, 2023, 12: 100970.
- [87] Si H, Li N, Duan X, et al. Understanding the public's willingness to participate in the Carbon Generalized System of Preferences (CGSP): An innovative mechanism to drive low-carbon behavior in China[J]. *Sustainable Production and Consumption*, 2023, 38: 1-12.
- [88] Rey D, Dixit V V, Ygnace J L, et al. An Incentive-based mechanism to promote the use of Off-peak periods in congested networks[C]. *Transportation Research Board 94th Annual Meeting*. Washington DC, USA, 2015.
- [89] Helbing D, Schönhof M, Kern D. Volatile decision dynamics: experiments, stochastic description, intermittency control and traffic optimization[J]. *New Journal of Physics*, 2002, 4(1): 33.
- [90] Selten R, Chmura T, Pitz T, et al. Commuters route choice behaviour[J]. *Games and Economic Behavior*, 2007, 58(2): 394-406.
- [91] Chorus C G. Risk aversion, regret aversion and travel choice inertia: an experimental study[J]. *Transportation Planning and Technology*, 2014, 37(4): 321-332.
- [92] Iida Y, Akiyama T, Uchida T. Experimental analysis of dynamic route choice behavior[J]. *Transportation Research Part B: Methodological*, 1992, 26(1): 17-32.
- [93] Yang H, Hai-Jun H. Analysis of the time-varying pricing of a bottleneck with elastic demand using optimal control theory[J]. *Transportation Research Part B: Methodological*, 1997, 31(6): 425-440.
- [94] Liu Q, Lu D, Jiang R, et al. Departure time choice behavior in commute problem with stochastic bottleneck capacity: experiments and modeling[J]. *Transportmetrica A: Transport Science*, 2023, 19(2): 1978590.
- [95] Sun X, Han X, Bao J-Z, et al. Decision dynamics of departure times: Experiments and modeling[J].



参考文献

- Physica A: Statistical Mechanics and its Applications, 2017, 483: 74-82.
- [96] Anderson L, Holt C, Reiley D. Congestion pricing and welfare: an entry experiment[J]. Environmental Economics, Experimental Methods, 2008, : 280-292.
- [97] Aziz H A, Ukkusuri S V, Romero J. Understanding short-term travel behavior under personal mobility credit allowance scheme using experimental economics[J]. Transportation Research Part D: Transport and Environment, 2015, 36: 121-137.
- [98] Tian Y, Chiu Y-C, Sun J. Understanding behavioral effects of tradable mobility credit scheme: An experimental economics approach[J]. Transport Policy, 2019, 81: 1-11.
- [99] Rey D, Dixit V V, Ygnace J-L, et al. An endogenous lottery-based incentive mechanism to promote off-peak usage in congested transit systems[J]. Transport Policy, 2016, 46: 46-55.
- [100] Tian Y, Li Y, Sun J. Stick or carrot for traffic demand management? Evidence from experimental economics[J]. Transportation Research Part A: Policy and Practice, 2022, 160: 235-254.
- [101] Tian Y, Li Y, Sun J, et al. Characterizing favored users of incentive-based traffic demand management program[J]. Transport Policy, 2021, 105: 94-102.
- [102] Azevedo C L, Seshadri R, Gao S, et al. Tripod: Sustainable travel incentives with prediction, optimization, and personalization[C]//Proceedings of the Transportation Research Board 97th Annual Meeting, Washington DC, USA, 2018.
- [103] Zhu X, Wang F, Chen C, et al. Personalized incentives for promoting sustainable travel behaviors[J]. Transportation Research Part C: Emerging Technologies, 2020, 113: 314-331.
- [104] Javaudin L, Araldo A, de Palma A. Personalised incentives with constrained regulator's budget[J]. Transportmetrica A: Transport Science, 2023, 2023: 1-43.
- [105] Van Vuren T, Van Vliet D, Smith M J. Combined equilibrium in a network with partial route guidance[C]//Proceedings of the The 5th NG Foundation conference, santa barbara, Californi, USA, 1990.
- [106] Van Vuren T, Watling D. Multiple user class assignment model for route guidance[J]. Transportation Research Record, 1991, 1306: 22-31.
- [107] Yang H. Multiple equilibrium behaviors and advanced traveler information systems with endogenous market penetration[J]. Transportation Research Part B: Methodological, 1998, 32(3): 205-218.
- [108] Yang H, Huang H-J. Modeling user adoption of advanced traveler information systems: a control theoretic approach for optimal endogenous growth[J]. Transportation Research Part C: Emerging Technologies, 2004, 12(3): 193-207.
- [109] Zhou B, Xu M, Meng Q, et al. A day-to-day route flow evolution process towards the mixed equilibria[J]. Transportation Research Part C: Emerging Technologies, 2017, 82: 210-228.
- [110] Klein I, Levy N, Ben-Elia E. An agent-based model of the emergence of cooperation and a fair and stable system optimum using ATIS on a simple road network[J]. Transportation Research Part C: Emerging Technologies, 2018, 86: 183-201.
- [111] Chen Z, He F, Yin Y, et al. Optimal design of autonomous vehicle zones in transportation networks[J]. Transportation Research Part B: Methodological, 2017, 99: 44-61.
- [112] Bagloee S, Sarvi M, Patriksson M, et al. A mixed user-equilibrium and system-optimal traffic flow for connected vehicles stated as a complementarity problem: Mixed user-equilibrium and



参考文献

- system-optimal traffic flow[J]. *Computer-Aided Civil And Infrastructure Engineering*, 2017, 32(7): 562-580.
- [113] Wang J, Peeta S, He X. Multiclass traffic assignment model for mixed traffic flow of human-driven vehicles and connected and autonomous vehicles[J]. *Transportation Research Part B: Methodological*, 2019, 126: 139-168.
- [114] 考虑自动驾驶专用车道的混合交通分配模型[J]. *中国公路学报*, 2023, 36: 317-327.
- [115] Guo Z, Wang D Z W, Wang D. Managing mixed traffic with autonomous vehicles – A day-to-day routing allocation scheme[J]. *Transportation Research Part C: Emerging Technologies*, 2022, 140: 103726.
- [116] Amirgholy M, Shahabi M, Oliver Gao H. Traffic automation and lane management for communicant, autonomous, and human-driven vehicles[J]. *Transportation Research Part C: Emerging Technologies*, 2020, 111: 477-495.
- [117] Chellapilla H, Sivanandan R, Chilukuri B R, et al. A trade-off between user-equilibrium and system optimal traffic assignments for congestion mitigation in city networks[J]. *Transportation Research Procedia*, 2023, 69: 384-391.
- [118] Liang Q, Li X-a, Chen Z, et al. Day-to-day traffic control for networks mixed with regular human-piloted and connected autonomous vehicles[J]. *Transportation Research Part B: Methodological*, 2023, 178: 102847.
- [119] Zhang F, Lu J, Hu X. Integrated path controlling and subsidy scheme for mobility and environmental management in automated transportation networks[J]. *Transportation Research Part E: Logistics and Transportation Review*, 2022, 167: 102906.
- [120] Saw K, Katti B K, Joshi G. Literature review of traffic assignment: Static and dynamic[J]. *International Journal of Transportation Engineering*, 2015, 2(4): 339-347.
- [121] Hu T-Y, Tong C-C, Liao T-Y, et al. Dynamic route choice behaviour and simulation-based dynamic traffic assignment model for mixed traffic flows[J]. *KSCE Journal of Civil Engineering*, 2018, 22(2): 813-822.
- [122] Fakhrmoosavi F, Saedi R, Zockaie A, et al. Impacts of connected and autonomous vehicles on traffic flow with heterogeneous drivers spatially distributed over large-scale networks[J]. *Transportation Research Record: Journal of the Transportation Research Board*, 2020, 2674: 036119812094099.
- [123] Mansourianfar M H, Gu Z, Waller S T, et al. Joint routing and pricing control in congested mixed autonomy networks[J]. *Transportation Research Part C: Emerging Technologies*, 2021, 131: 103338.
- [124] Bonabeau E. Agent-based modeling: Methods and techniques for simulating human systems[J]. *Proceedings of the National Academy of Sciences*, 2002, 99(suppl_3): 7280-7287.
- [125] Wojtusiak J, Warden T, Herzog O. Machine learning in agent-based stochastic simulation: Inferential theory and evaluation in transportation logistics[J]. *Computers & Mathematics with Applications*, 2012, 64(12): 3658-3665.
- [126] Püschel J, Barthelmes L, Kagerbauer M, et al. Comparison of discrete choice and machine learning models for simultaneous modeling of mobility tool ownership in agent-based travel demand models[J]. *Transportation Research Record*, 2024, 2678(7): 376-390.
- [127] Huang J, Cui Y, Zhang L, et al. An overview of agent-based models for transport simulation



参考文献

- and analysis[J]. *Journal of Advanced Transportation*, 2022, 2022(1): 1252534.
- [128] Hörl S. Agent-based simulation of autonomous taxi services with dynamic demand responses[J]. *Procedia Computer Science*, 2017, 109: 899-904.
- [129] Rounaq B, Andrea A, Arun Prakash A, et al. Automated mobility-on-demand vs. Mass Transit: A multi-modal activity-driven agent-based simulation approach[J]. *Transportation Research Record*, 2018, 2672(8): 608-618.
- [130] Kaddoura I, Nagel K. Agent-based congestion pricing and transport routing with heterogeneous values of travel time savings[J]. *Procedia Computer Science*, 2016, 83: 908-913.
- [131] Kaddoura I, Nagel K. Congestion pricing in a real-world oriented agent-based simulation context[J]. *Research in Transportation Economics*, 2019, 74: 40-51.
- [132] Karaaslan E, Noori M, Lee J, et al. Modeling the effect of electric vehicle adoption on pedestrian traffic safety: An agent-based approach[J]. *Transportation Research Part C: Emerging Technologies*, 2018, 93: 198-210.
- [133] Amaran S, Sahinidis N V, Sharda B, et al. Simulation optimization: a review of algorithms and applications[J]. *Annals of Operations Research*, 2016, 240(1): 351-380.
- [134] Osorio C, Bierlaire M. A simulation-based optimization framework for urban transportation problems[J]. *Operations Research*, 2013, 61(6): 1333-1345.
- [135] Forrester A, Sobester A, Keane A. *Engineering design via surrogate modelling: a practical guide*[M]. : John Wiley & Sons, 2008.
- [136] Jones D R, Schonlau M, Welch W J. Efficient global optimization of expensive black-box functions[J]. *Journal of Global Optimization*, 1998, 13(4): 455-492.
- [137] Williams C K, Rasmussen C E. *Gaussian processes for machine learning*[M]. : MIT press Cambridge, MA, 2006.
- [138] Chen D. Research on traffic flow prediction in the big data environment based on the improved RBF neural network[J]. *IEEE Transactions on Industrial Informatics*, 2017, 13(4): 2000-2008.
- [139] Chen X, Xiong C, He X, et al. Time-of-day vehicle mileage fees for congestion mitigation and revenue generation: A simulation-based optimization method and its real-world application[J]. *Transportation Research Part C: Emerging Technologies*, 2016, 63: 71-95.
- [140] He X, Chen X, Xiong C, et al. Optimal time-varying pricing for toll roads under multiple objectives: A simulation-based optimization approach[J]. *Transportation Science*, 2016, 51(2): 412-426.
- [141] Chong L, Osorio C. A simulation-based optimization algorithm for dynamic large-scale urban transportation problems[J]. *Transportation Science*, 2017, 52(3): 637-656.
- [142] Li Z-C, Huang H-J, Yang H. Fifty years of the bottleneck model: A bibliometric review and future research directions[J]. *Transportation Research Part B: Methodological*, 2020, 139: 311-342.
- [143] Liu L N, McDonald J F. Economic efficiency of second-best congestion pricing schemes in urban highway systems[J]. *Transportation Research Part B: Methodological*, 1999, 33(3): 157-188.
- [144] Rouwendal J, Verhoef E T. Second best pricing for imperfect substitutes in urban networks[J]. *Research in Transportation Economics*, 2004, 9(1): 27-60.
- [145] Yang F, Yin Y, Lu J. Steepest descent day-to-day dynamic toll[J]. *Transportation Research Record*, 2007, 2039(1): 83-90.
- [146] Yang F. Day-to-day dynamic optimal tolls with elastic demand[C]//*Proceedings of the*



参考文献

- Transportation Research Board 87th Annual Meeting, Washington DC, USA, 2008.
- [147] Bernstein D. Congestion pricing with tolls and subsidies[C]//Proceedings of the Pacific Rim TransTech Conference—Volume II: International Ties, Management Systems, Propulsion Technology, Strategic Highway Research Program, 1993.
- [148] Tsirimpa A, Polydoropoulou A, Pagoni I, et al. A reward-based instrument for promoting multimodality[J]. Transportation Research Part F: Traffic Psychology and Behaviour, 2019, 65: 121-140.
- [149] Wang G, Jia H, Feng T, et al. Modelling the dual dynamic traffic flow evolution with information perception differences between human-driven vehicles and connected autonomous vehicles[J]. Physica A: Statistical Mechanics and its Applications, 2024, 640: 129667.
- [150] Small K A. A discrete choice model for ordered alternatives[J]. Econometrica, 1987, 55(2): 409-424.
- [151] Sivasubramaniyam R D, Sargisson R J, Charlton S G. Satisfaction from satisficing: Understanding commuters' satisficing tendencies[J]. Transportation Research Interdisciplinary Perspectives, 2020, 6: 100158.
- [152] Manca F, Sivakumar A, Polak J W. Capturing the effect of multiple social influence sources on the adoption of new transport technologies and services[J]. Journal of Choice Modelling, 2022, 42: 100344.
- [153] Lo S H, van Breukelen G J P, Peters G-J Y, et al. Proenvironmental travel behavior among office workers: A qualitative study of individual and organizational determinants[J]. Transportation Research Part A: Policy and Practice, 2013, 56: 11-22.
- [154] Yang Y. A dynamic framework on travel mode choice focusing on utilitarian walking based on the integration of current knowledge[J]. Journal of Transport & Health, 2016, 3(3): 336-345.
- [155] Zhu J, Fan Y. Daily travel behavior and emotional well-being: Effects of trip mode, duration, purpose, and companionship[J]. Transportation Research Part A: Policy and Practice, 2018, 118: 360-373.
- [156] 艾媒研究院, 艾媒网. 2022 年度中国 APP 月活排行榜 [EB/OL]. 2023. <https://www.iimedia.cn/c880/91597.html>.
- [157] 苏州日报. 苏州公共交通服务质量全省首位 [EB/OL]. 2022. <https://www.suzhou.gov.cn/szrmzf/szyw/202209/c50e1ba052244ed085e72e5884e1ec23.shtml>.
- [158] 苏州本地宝. 2023 苏州限行最新规定 [EB/OL]. 2023. <http://suzhou.bendibao.com/traffic/2018116/67079.shtm>.
- [159] 苏州市交通运输局. 完善绿色出行服务体系 低碳生活让城市更美好[EB/OL]. 2022. <http://jtj.suzhou.gov.cn/szjt/lscxdtsh/lscxdtsh.shtml>.
- [160] Kumar V, Bhat C R, Pendyala R M, et al. Impacts of incentive-based intervention on peak period traffic: Experience from the Netherlands[J]. Transportation Research Board of the National Academies, 2016, (2543):
- [161] Tian Y, Li Y, Sun J, et al. Characterizing favored users of incentive-based traffic demand management program[J]. Transport Policy, 2021, 105(6): 94-102.
- [162] Qi H, Jia N, Qu X, et al. Investigating day-to-day route choices based on multi-scenario laboratory experiments, Part I: Route-dependent attraction and its modeling[J]. Transportation Research Part A: Policy and Practice, 2023, 167: 103553.



参考文献

- [163] Han X, Sun Q, Xing Y, et al. Reducing strategic uncertainty in transportation networks by personalized routing advice: A route-choice laboratory experiment[J]. *Travel Behaviour and Society*, 2024, 34: 100701.
- [164] Chen H, Yan X, Liu X, et al. Exploring the operational performance discrepancies between online ridesplitting and carpooling transportation modes based on DiDi data[J]. *Transportation*, 2022, 50(5): 1923-1958.
- [165] Neoh J G, Chipulu M, Marshall A. What encourages people to carpool? An evaluation of factors with meta-analysis[J]. *Transportation*, 2017, 44(2): 423-447.
- [166] Saedi R, Khademi N. Travel time cognition: Exploring the impacts of travel information provision strategies[J]. *Travel Behaviour and Society*, 2019, 14: 92-106.
- [167] Vosough S, Roncoli C. Achieving social routing via navigation apps: User acceptance of travel time sacrifice[J]. *Transport Policy*, 2024, 148: 246-256.
- [168] Pan L, Yao E, MacKenzie D. Modeling EV charging choice considering risk attitudes and attribute non-attendance[J]. *Transportation Research Part C: Emerging Technologies*, 2019, 102: 60-72.
- [169] Peduzzi P, Concato J, Feinstein A R, et al. Importance of events per independent variable in proportional hazards regression analysis II. Accuracy and precision of regression estimates[J]. *Journal of Clinical Epidemiology*, 1995, 48(12): 1503-1510.
- [170] Peduzzi P, Concato J, Kemper E, et al. A simulation study of the number of events per variable in logistic regression analysis[J]. *Journal of Clinical Epidemiology*, 1996, 49(12): 1373-1379.
- [171] Vittinghoff E, McCulloch C E. Relaxing the rule of ten events per variable in Logistic and Cox regression[J]. *American Journal of Epidemiology*, 2007, 165(6): 710-718.
- [172] Chetty R, Looney A. Consumption smoothing and the welfare consequences of social insurance in developing economies[J]. *Journal of public Economics*, 2006, 90(12): 2351-2356.
- [173] Haushofer J, Fehr E. On the psychology of poverty[J]. *Science*, 2014, 344(6186): 862-867.
- [174] Fu M C. Optimization for simulation: Theory vs. practice[J]. *Informatics Journal on Computing*, 2002, 14(3): 192-215.
- [175] Meketon M S. Optimization in simulation: A survey of recent results[C]//*Proceedings of the Proceedings of the 19th conference on Winter simulation*, 1987.
- [176] Sadiku M N O, Musa S M. Augmented Intelligence[M]//SADIKU M N O, MUSA S M. *A Primer on Multiple Intelligences*. Springer International Publishing. 2021: 191-199.



致谢

2019 年盛夏，我怀揣着对未知的好奇与对科研的憧憬，开启了一段漫长而深刻的求学旅程。六年时光悄然流转，当 2025 年的蝉鸣再次响起，我的博士毕业论文也终于定稿。回首这段经历，感慨万千，更多的是心中那份沉甸甸的感谢。

衷心感谢我的导师孙剑老师。在整个博士阶段，孙老师以博大的胸怀接纳我，以深厚的学识指引我，以温和坚定的力量支持我。在每一个关键节点上，孙老师都悉心把关，为我在迷雾中点亮方向，使我得以在复杂问题中保持定力、在科研道路上坚定前行。从学术理想到科研精神，从治学态度到为人之道，孙老师的引导与教诲，已化作我人生旅途中最宝贵的精神财富，将始终陪伴我前行。

深深感谢田野老师对我的悉心指导。从最初对科研的陌生，到逐渐掌握研究方法，再到最终完成博士毕业论文，我的每一点进步都离不开田老师的培养与帮助。无论是不厌其烦的论文修改，还是科研瓶颈时的点拨，田老师始终关怀、支持着我。我所取得的每一项成果、每一篇论文，背后都凝聚着田老师的智慧与付出。正是在田老师的引导下，我才能顺利完成学业，在学术道路上不断前行。

感谢 TOPS 课题组的倪颖老师、杭鹏老师、岳李圣飒老师、孙杰老师以及秦国阳师兄。组会上的每一次深入交流，都给予我宝贵的启发，使我能从多元的视角审视问题，在学术思考中拓展视野、打磨思路。在老师们的引领下，TOPS 课题组严谨而自由的学术氛围、包容而互助的科研文化，深深感染并激励着我，使我在潜移默化中不断成长。

感谢 TOPS 课题组的各位同门，是大家的陪伴让我在科研旅途中不再孤单。在无数个交织着焦虑与希望的日夜，是大家的鼓励与分享，让我感受到同行的力量与集体的温暖。特别感谢张赫、王诗菡，自入学以来六年相知相伴，我们共同走过从宿舍到课题组的每一段路程，分担科研中的压力，也分享生活中的欢喜。这些点点滴滴，都是我人生中最珍贵的回忆。

最深的感谢，献给始终在我身后默默支持的父母和姐姐，她们是我最坚实的依靠。无论何时，她们总是耐心倾听、无私包容，急我之所急，乐我之所乐，给予我理解与鼓励，让我有勇气乐观地面对科研之路上的种种挑战。

博士阶段的句点，不是终点，而是更辽阔旅程的起点。我将带着这段经历的积淀与大家的支持，继续前行，坚定地走好人生的下一程。

肖琳

2025 年 7 月

同济大学嘉定校区



个人简历、在读期间发表的学术成果

个人简历：

肖琳，女，1996年7月生。

2015.06-2017.07 北京交通大学 交通工程专业 获学士学位。

2019.09-2021.03 同济大学 交通运输工程专业 硕士研究生

2021.03 至今 同济大学 交通运输工程专业 攻读博士学位

已发表论文：

- [1] **Xiao L**, Wu J, Sun J, Tian Y. Money is Power: Carpooling Stimulus with Evidence from an Interactive Long-term Laboratory Experiment [J]. Transport Policy, 2024.
- [2] **Xiao L**, Liao J, Wu S, Sun J, Tian Y. Understanding the Attitudes of Travelers towards Incentive-based Travel Demand Management Strategies in Suzhou, China [J]. Travel Behaviour & Society, 2024.
- [3] **Xiao L**, Wu J, Tian Y, Sun J. Collaborate or compete? Time-varying incentives versus tolling in a parallel bottleneck [J]. Journal of Advanced Transportation, 2023.
- [4] **Xiao L**, Wu J, Tian Y, Sun J, Lei C, Fang Y. Optimizing Budget Allocation for Incentive-Based Active Travel Demand Management Solutions [J]. Transportation Research Record, 2021.
- [5] 付全路, **肖琳**, 田野, 孙剑. 基于交互实验的长时拼车决策演变及非理性行为[J]. 交通运输工程与信息学报, 2025, 23(2): 71-85.

待发表论文：

- [1] **肖琳**, 吴纪葵, 孙剑, 田野. 考虑出行行为偏移的奖励方案优化模型 [J]. 同济大学学报（自然科学版）.（已接收）

参与科研项目：

- [1] 科技创新 2030-“新一代人工智能”重大项目（2022ZD0115602）：交通系统全息感知与可计算模型构建，2022-2025
- [2] 国家自然科学基金杰出青年基金（52125208）：交通系统建模与优化，2021-2025
- [3] 国家自然科学基金委青年项目（52002279）：基于奖励的交通需求管理奖励机制设计与方案优化研究，2021.1-2023.12



同济大学学位论文原创性声明

本人郑重声明：所提交的学位论文《智能网联环境下基于奖励的交通需求管理方案优化》，是本人在导师指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本学位论文的研究成果不包含任何他人创作的、已公开发表或者没有公开发表的作品的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。本学位论文原创性声明的法律责任由本人承担。

学位论文作者签名：肖琳

日期：2025 年 7 月 31 日

同济大学学位论文版权使用授权书

本人完全了解同济大学关于收集、保存、使用学位论文的规定，同意如下各项内容：按照学校要求提交学位论文的印刷本和电子版本；学校有权保存学位论文的印刷本和电子版，并采用影印、缩印、扫描、数字化或其它手段保存论文；学校有权提供目录检索以及提供本学位论文全文或者部分的阅览服务；学校有权按有关规定向国家有关部门或者机构送交论文的复印件和电子版；允许论文被查阅和借阅。学校有权将本学位论文的全部或部分内容授权编入有关数据库出版传播，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

本学位论文属于（在以下方框内打“√”）：

☐ 保密，在_____年解密后适用本授权书。

☒ 不保密。

学位论文作者签名：肖琳

指导教师签名：孙剑

日期：2025 年 7 月 31 日

日期：2025 年 7 月 31 日



七、学位答辩委员会决议

姓名	肖琳	学号	2110195	学科专业	交通运输工程
指导教师	孙剑	答辩日期	2025 年 7 月 28 日	答辩地点	通达馆 517 会议室
题目	智能网联环境下基于奖励的交通需求管理方案优化				
答辩委员会共 <u>6</u> 人，经表决，<u>6</u> 人同意，<u>0</u> 人不同意，<u>0</u> 人弃权。根据《同济大学学位授予工作细则》^[注 1]，本次答辩（在□内划“√”）： ☒ 通过。 ☐ 不通过。 ☐ 不通过，申请人可在两年内修改，重新申请答辩一次。 ☐ 未达到博士学位水平，但已达到硕士学位水平，经申请人_____同意^[注 2]，建议授予硕士学位。					
是否推荐为同济大学优秀博士学位论文或实践成果： ☐ 是 ☒ 否					
论文聚焦于智能网联环境下的基于奖励的交通需求管理方案优化问题，选题具有重要的理论意义和应用价值。 论文系统分析理性 CAV/HV、非理性 HV、非理性 CAV 在奖励作用下的出发时间选择行为，并提出奖励优化策略。论文主要创新成果为：1）基于理性行为假设，提出了宣传-激励成本优化分配方法，实现了预算的统筹配置；2）设计了长时追踪与可控实验相结合的非理性 HV 行为观测机制，提升了非理性 HV 的参与持续性；3）提出了基于智能增强的奖励方案仿真优化方法，提升了奖励方案效能与系统长时稳定性。 论文结构严谨，逻辑清晰，研究方法科学合理，实验设计与图表规范，文字表达准确严谨，表明该学生具有扎实理论功底与良好科研素养，具备独立从事科学研究的能力。 答辩中汇报详实、表述清晰，能准确理解和回应提出的问题。经答辩委员会无记名投票表决，一致同意通过博士论文答辩。 答辩委员会主席签名：  2025 年 7 月 28 日					



七、学位答辩委员会决议

答辩委员会组成人员名单					
答辩委员会	职务	姓名	职称	工作单位	签名
	主席	赵靖	教授	上海理工大学	
	委员	沈峰	正高级工程师	上海电科智能系统股份有限公司	
	委员	朱政	研究员	浙江大学	
	委员	孙剑	教授	同济大学	
	委员	田野	教授	同济大学	
	委员	倪颖	副教授	同济大学	
	委员				
	委员				
	委员				
答辩秘书		岳李圣飒	副教授	同济大学	

注 1：根据《同济大学学位授予工作细则》第十九条规定：申请人获得全体答辩专家三分之二以上（含本数）同意票，答辩通过；获得全体答辩专家三分之二以下（不含本数）同意票，答辩不通过，经答辩委员会同意，可在两年内修改，重新申请答辩一次。博士学位答辩委员会认为申请人的学位论文或实践成果虽未达到博士学位的水平，但已达到硕士学位的水平，且申请人尚未获得过学校该学科、专业硕士学位的，经申请人同意，可作出建议授予硕士学位的决议，报学位分委会审定。申请人接受博士学位答辩委员会建议授予硕士学位决议的，不得再次申请博士学位。

注 2： 学位申请人签名。